

Calculus Methodos

第零部分——引言

封面

无算之策

Larrtroffen

链接认识论
方法论
与操作化

回归不归
独家专栏合集

首个系统梳理计算社科方法之指北
代码 GitHub 开源

AI时代，比技能更重要的是智能，是能动。



回归不归

封面

引言

目录

.

- |—— 引言——计算视角下的社会科学新图景
- |—— 第一节
 - |—— 时代变革下的社会科学：研究疆域的重塑与范式困境
- |—— 第二节
 - |—— 智识的积淀与汇聚：计算社会科学的多元思想源泉
 - |—— 计算社会科学的界定：以四大核心研究任务为导向的范式整合
- |—— 第三节
 - |—— 任务一：CSS 赋能的描述——绘制数字社会的全景图
 - |—— 任务二：CSS 赋能的预测——把握社会脉搏与未来轨迹
 - |—— 任务三：CSS 赋能的因果推断——在复杂世界中探寻“为什么”
 - |—— 任务四：CSS 赋能的模拟——人工社会中的涌现与机制
 - |—— 四大任务驱动下的计算社会科学核心特征与性质
- |—— 第四节
 - |—— 无算之策——编排思路与结构
 - |—— 第一部分：基础先行
 - |—— 第二部分：任务驱动

第一节——时代变革下的社会科学：研究疆域的重塑与范式困境

我们正经历一个以数字技术为核心驱动力的深刻社会转型期，其广度、深度和速度或许只有工业革命可堪比拟。这场并非仅仅是技术层面的革新，更是一场关乎人类存在方式、社会组织形态与文化意义系统的根本性变迁 (Castells, 2000; Van Dijk, 2005)。从早期静态网页到如今万物互联的智能生态，从偶发的在线互动到社交媒体深度嵌入日常生活的肌理，从物理空间与数字空间的分离到两者日益融合形成的“数字孪生社会”图景，技术的渗透力以前所未有的态势重塑着我们赖以生存的时空结构与社会关系网络。这一历史性转变最为显著的特征之一，便是人类行为、社会交往、信息传播乃至情感表达的过程，越来越多地被各类数字系统所捕捉、记录、存储和处理，形成了一个规模空前、种类繁多、瞬息万变的数字化信息集合——通常被笼统地称为“大数据” (Lazer et al., 2009; Mayer-Schönberger & Cukier, 2013)。

这一“数据化”(Datafication) 的趋势，即社会现象被持续不断地转化为可计算数据的过程，不仅为定量分析提供了看似无穷尽的原材料，更重要的是，它改变了社会现象“显现”和“被观察”的方式。 这些被动产生的“数字足迹”或“数字痕迹”(digital footprints/traces)，覆盖了个体微观的在线决策、群体的网络互动模式，乃至宏观的社会经济脉动与文化变迁轨迹 (Pentland, 2014; Salganik, 2019)，它们构成了观察社会的一面崭新却又充满复杂性的“透镜”。

然而，我们必须清醒地认识到，这面透镜并非完美无瑕。其所映照的社会现实，是经过技术基础设施、平台设计逻辑、商业模式、用户自我呈现策略以及算法中介等多重棱镜折射后的结果 (Tufekci, 2014)。这意味着数据本身就内嵌了特定的社会结构与权力关系，可能带有系统性的偏差，例如“数字鸿沟”导致的选择性偏差与代表性不足 (Schradie, 2018)，以及平台效应塑造下的行为同质化。更深层次地看，数据的生成和收集过程本身，就可能改变被观察现象的性质，并引发深刻的隐私与伦理困境 (boyd & Crawford, 2012; Zimmer, 2010; Lazer et al., 2021)。

因此，这个数据充裕的新时代，带给社会科学的不仅是前所未有的机遇，更是对我们认识论和方法论基础的严峻拷问：我们如何理解这个日益被数据化和算法化的社会？我们既有的理论框架和研究工具，是否足以穿透数据的表象，把握其背后的社会实质与复杂机制？

社会科学的核心使命——理解社会结构、解释社会变迁、洞察人类行为——在这样一个全新的经验场域中，面临着怎样的挑战与调适需求？对这些根本性问题的回应，构成了我们探讨社会科学未来发展方向，特别是审视计算社会科学兴起必要性的逻辑起点。

面对这样一个被数字技术深刻重塑的研究疆域，以及由此产生的海量、新型、同时也充满陷阱的数据环境，传统社会科学历经百年发展所积淀下来的研究范式与方法论体系，正经历着前所未有的审视与考验。

无可否认，无论是强调深度理解、情境嵌入的定性研究传统（如民族志、深度访谈、历史文献分析），还是追求客观测量、统计推断与理论检验的定量研究范式（以调查研究、实验设计、抽样理论、标准统计推断为支柱），都在各自的领域内取得了辉煌的成就，为我们理解社会世界的复杂性贡献了不可磨灭的智慧，并且在今天依然保有其独特的价值与适用性 (Groves et al., 2009)。

然而，当我们将这些经典方法论直接应用于数字时代特有的研究对象和数据形态时，其固有的边界和局限性便日益清晰地暴露出来。例如，经典的抽样理论旨在通过对有限样本的精确测量来推断总体特征，这在数据稀缺时代是科学认知的重要基石，但在一个可能获得接近总体规模数据的时代，其必要性和解释力则面临新的考量 (Salganik, 2019)。更重要的是，这些数据往往并非为研究而“设计”，而是社会活动自然产生的“副产品”，其复杂性、非结构化程度（如海量文本、图像、网络关系数据）以及动态性，常常超出了传统统计模型（如依赖线性、正态分布、独立同分布等假设的回归模型）的处理能力范畴。

传统的调查问卷擅长测量态度和意向，但对于捕捉瞬息万变的真实行为、隐藏在互动模式中的社会结构、或者大规模信息传播的动力学过程，则显得力不从心。实验方法虽然在建立因果关系上具有优势，但在数字场域中进行大规模、符合伦理规范且具有良好外部效度的社会实验，依然面临诸多挑战与争议 (Kramer et al., 2014; Bond et al., 2012)。定性研究方法，如民族志，虽然能够提供丰富的、情境化的理解，但在面对规模庞大、地理分散的在线社群或需要系统性分析海量文本数据时，其传统的观察和分析方式在效率和覆盖面上也遇到了瓶颈。

进一步而言，传统方法论在处理社会系统的内在复杂性——如个体异质性、行动者之间的非线性互动、跨层级的反馈循环、以及宏观现象的涌现性——方面，往往采取简化策略（如假设同质性、理性选择、均衡状态），这固然有助于建立简洁的理论模型或进行统计控制，但也可能牺牲了对真实世界复杂动态过程的深入理解。因此，我们面临的并非是对传统方法的全盘否定，而是对其适用范围和能力限度的深刻反思：在新的时代条件下，这些久经考验的方法论框架，在捕捉社会现实的某些新维度、处理新型数据、回答某些新兴或被放大的研究问题时，是否显现出结构性的“短板”？**这种方法论上的张力，构成了推动社会科学寻求范式革新和工具拓展的内在驱动力。**

正是基于对数字时代社会现实的深刻变革以及传统社会科学方法论局限性的双重认知，一种强烈的需求应运而生：社会科学需要系统性地拓展和深化其核心研究能力，以更有效地应对新挑战、把握新机遇，从而保持其作为理解和引导社会发展的知识体系的活力与相关

性。这种需求并非仅仅指向对新技术的零星应用，而是关乎社会科学研究范式在根本目标和实现路径上的潜在演进。

具体而言，这种方法论上的拓展需求集中体现在社会科学研究的四个核心支柱性任务上。其一，是对社会现象进行描述 (Description) 的能力提出了更高要求。我们需要超越基于抽样和简单统计摘要的传统描述，发展出能够在全景式、大规模数据中，以更精细的粒度、更动态的视角，揭示复杂（包括网络、时空、文本）社会结构、模式与趋势的方法论 (Savage & Burrows, 2007; Watts, 2014)。这意味着需要工具来“导航”和“测绘”数字社会的复杂地形，而不仅仅是估计总体的平均值或比例。

其二，是对社会结果进行预测 (Prediction) 的能力需求日益凸显。随着数据丰富度和算法能力的提升，对个体行为、群体动态和社会趋势进行更准确、及时、甚至个性化的预测成为可能，并且在政策制定、风险管理等领域具有巨大的应用潜力 (Molina & Garip, 2019; Hofman et al., 2021)。这要求社会科学重新评估预测在知识体系中的地位，探索能够有效处理高维复杂数据、兼顾准确性与可解释性、并负责任地应对伦理挑战的预测方法论 (Shmueli, 2010; Mullainathan & Spiess, 2017)。

其三，是对因果关系进行推断 (Causal Inference) 的方法论提出了精化的迫切需求。在普遍依赖观测性数据且混淆因素日益复杂的数字环境中，我们需要超越传统回归分析的局限，发展出更稳健、更少依赖模型假设、更能有效利用（准）实验机会、并能深入探究异质性处理效应和作用机制的因果推断框架 (Athey & Imbens, 2017; Pearl, 2009; Abadie, 2021)。这要求方法论上的创新，以在“相关性”的汪洋大海中更可靠地打捞“因果性”的珍珠。

其四，是对理解社会过程的生成性机制 (Generative Mechanisms) 提出了模拟复杂性的探索需求。面对社会系统普遍存在的复杂适应性特征（如涌现、反馈、非线性），我们需要超越静态分析和过度简化的模型，发展能够通过计算模拟“自下而上”地复现宏观社会模式、探索微观互动规则如何生成系统动态的方法论工具，以实现对社会过程更深层次的“生成性理解” (Epstein & Axtell, 1996; Sawyer, 2005)。

这四个维度的能力拓展需求，共同指向了一个核心议题：社会科学需要拥抱新的思维方式和研究工具，特别是那些能够驾驭数据复杂性、模拟动态过程、并可能在理论与经验之间建立新型对话模式的计算方法。这种由时代背景、研究对象变化以及传统方法论局限性共同催生的方法论拓展需求，为一种整合社会科学洞察与先进计算能力的跨学科研究范式的兴起——即计算社会科学的登场——铺设了历史的舞台，并赋予了其核心的学术使命。

接下来的章节，将深入探讨这一新兴领域的缘起、内涵及其如何系统性地回应并实践这四大核心研究任务。

第二节——计算社会科学的缘起： 智识汇流、领域界定与范式确立

智识的积淀与汇聚：计算社会科学的多元思想源泉

计算社会科学（Computational Social Science, CSS）作为一个新兴的跨学科研究领域，其诞生并非一蹴而就或凭空创造，而是深深植根于社会科学内部寻求精确化、形式化和经验化的长期努力，并广泛受益于与数学、统计学、计算机科学、物理学、工程学乃至复杂性科学等多个学科长达数十年的交叉渗透、智识交流与方法借鉴。理解 CSS 的智识谱系，有助于我们把握其核心关切、方法论取向以及与传统社会科学的继承与革新关系。其发展脉络中，既包含了社会科学自身内部的演进动力，也吸收融合了来自外部学科的理论视角、分析工具和计算思维。我们可以将这些多元的源流大致归纳为以下几个相互关联的方面：

社会科学内部的定量化与形式化传统

早在计算机普及之前，社会科学内部就存在着强烈的追求科学化、精确化和模型化的潮流。

- 经典量化社会科学 (Classical Quantitative Social Science): 这是 CSS 最直接的基础和对话对象。以调查研究方法论（抽样、问卷设计、测量）、实验设计原则、概率论与统计推断（假设检验、置信区间）、回归分析及其扩展（如广义线性模型、多层模型、结构方程模型）、以及计量经济学（Econometrics）为代表的经典量化方法，为社会科学研究提供了严谨的数据收集、分析和推断框架。CSS 正是在这一坚实基础上，试图利用新的数据和计算能力来克服其局限性，拓展其边界。例如，CSS 中的许多预测和因果推断问题，仍然是在经典统计推断的框架内进行思考，但使用了更复杂的模型和算法。
- 数学社会学与形式理论 (Mathematical Sociology and Formal Theory): 自 20 世纪中叶以来，许多学者致力于运用数学工具（如图论、博弈论、微分方程、线性代数等）来形式化地表达社会理论，构建抽象模型以分析社会结构、互动过程和集体行为的逻辑。这种对理论进行精确化、公理化表达的追求，培养了社会科学中的形式化思维和模型化取向，为后来接受计算模型奠定了基础 (Coleman, 1964; Fararo, 1989)。
- 早期社会网络分析 (Early Social Network Analysis, SNA): 对社会关系结构进行形式化和定量化研究的传统可以追溯到 Jacob Moreno 的社会测量学 (Sociometry) (Moreno, 1934) 以及后来在社会学和人类学中发展起来的基于图论的结构分析方法。Linton Freeman, Mark Granovetter, Barry Wellman 等学者开创性地发展了网络中心性、结构洞、强弱连接等核心概念和测量方法，奠定了将社会关系视为可分析的网络结构的基础 (Freeman, 1978; Granovetter, 1973; Wasserman & Faust, 1994)。现代网络科学在社会领域的应用，

正是在早期 SNA 的基础上，借助强大的计算能力处理更大规模、更复杂网络而发展起来的。

- 定量地理学与地理信息科学 (Quantitative Geography and GIScience): 地理学中的“计量革命”以及随后地理信息系统 (GIS) 和空间统计学 (Spatial Statistics) 的发展，为分析人类行为、社会现象和人地关系的空间维度提供了强大的理论框架和技术工具。对空间自相关、空间异质性、空间互动模式的关注，以及处理和可视化地理空间数据的方法，对 CSS 中涉及地理位置、移动性、城市研究等领域产生了重要影响 (Goodchild, 2007; Anselin, 1995)。

早期计算应用与模拟思想的萌芽

在大型计算机开始出现的时代，一些富有远见的社会科学家就已经开始探索利用计算能力进行研究。

- 早期计算社会模拟 (Early Computational Social Simulation): 经济学家 Guy Orcutt 在 20 世纪 50 年代就提出了微观模拟 (Microsimulation) 的思想，试图通过模拟大量个体单位（家庭、公司）的行为及其加总来预测宏观经济指标 (Orcutt, 1957)。社会学家和政治学家也开始尝试使用计算机模拟来研究投票行为、组织决策、国际关系等。这些早期探索虽然受限于当时的计算能力和数据可用性，但孕育了通过计算来“生成”社会过程以进行理解和预测的思想种子。计算经济学 (Computational Economics) 领域后来也发展出基于智能体的计算经济学 (Agent-Based Computational Economics, ACE) 等重要分支 (Tesfatsion & Judd, 2006)。
- 赫伯特·西蒙 (Herbert A. Simon) 的跨学科遗产: 作为诺贝尔经济学奖得主和图灵奖得主，赫伯特·西蒙是一位横跨心理学、经济学、管理学、计算机科学和人工智能的巨人。他提出的有限理性 (Bounded Rationality) 概念，挑战了新古典经济学的完全理性假设，强调人类决策是在认知局限下进行的启发式搜索过程 (Simon, 1955)。他倡导将人类个体和组织视为信息处理系统 (Information Processing Systems)，并探索了使用计算机程序来模拟人类问题解决和决策过程的研究。他对人工智能、组织理论、复杂系统建模的开创性贡献，深刻影响了后来 CSS 中对个体行为建模、组织模拟以及复杂性思维的应用 (Simon, 1996)。

来自相关科学与工程领域的理论与方法输入

进入 20 世纪末和 21 世纪初，一系列新兴交叉学科的崛起和关键计算技术的成熟，极大地催化了 CSS 的形成。

- 复杂性科学 (Complexity Science): 兴起于圣塔菲研究所 (Santa Fe Institute) 等地的复杂性科学，提供了一套理解和分析复杂适应系统 (CAS) 的跨学科理论框架和方法论。它

关注系统的涌现 (Emergence)、自组织 (Self-organization)、反馈 (Feedback)、非线性 (Non-linearity)、网络结构 (Network Structure) 和适应性行为 (Adaptive Behavior) 等共性特征。复杂性科学不仅为理解社会系统的内在复杂性提供了新的理论视角，也极大地推广了基于主体的建模 (Agent-Based Modeling, ABM) 作为研究复杂系统动力学的核心工具 (Holland, 1995; Mitchell, 2009; Miller & Page, 2007)。Axelrod (1997) 关于合作演化的研究、Epstein 和 Axtell (1996) 的“糖域”(Sugarscape) 人工社会模型等，都是利用 ABM 研究社会现象的经典范例，深刻影响了 CSS 的模拟传统。

- 网络科学 (Network Science, Modern): 在早期 SNA 的基础上，融合了统计物理学（如研究相变、标度律）、计算机科学（如图算法、大规模数据处理）和社会科学的洞察，现代网络科学作为一个独立领域在世纪之交蓬勃发展起来。以 Watts 和 Strogatz (1998) 的“小世界”模型、Barabási 和 Albert (1999) 的“无标度”网络模型为代表的研究，揭示了现实世界中各种复杂网络（包括社会网络、信息网络、技术网络、生物网络）普遍存在的非平凡拓扑结构特征及其形成机制。网络科学发展出了一整套分析大规模网络结构（如度分布、聚类、社群结构、中心性）、功能（如信息传播、韧性）和演化动力学的强大理论与计算工具，成为 CSS 研究社会关系、互动和传播现象的核心方法论支柱 (Newman, 2018; Barabási, 2016)。
- 数据科学、机器学习与人工智能 (Data Science, Machine Learning, AI): 正如第一部分所述，计算机科学中的这些领域提供了处理和分析大规模、高维、异构数据的核心算法、工具和工程实践。机器学习（特别是深度学习）、自然语言处理、数据挖掘、模式识别等技术，为 CSS 提供了强大的描述性分析能力（如从文本中提取主题、从行为数据中发现模式）、预测能力（如预测用户行为、社会趋势）乃至辅助因果推断的能力（如用 ML 处理高维混淆）。数据科学强调从数据中学习、以预测为导向、以及处理现实世界 messy data 的整个工作流程（数据收集、清洗、探索、建模、评估、部署），其思维方式和技术栈对 CSS 的实践产生了深远影响 (Hastie et al., 2009; Murphy, 2022; Provost & Fawcett, 2013)。

表 1 计算社会科学的关键思想源流与学科基础

领域/方向	对 CSS 的贡献与关联	关键概念/方法列举
经典量化社会科学	提供研究设计基础、测量理论、统计推断框架、回归分析等核心方法论；构成 CSS 拓展和应对新挑战的起点。	Survey Methodology, Experimental Design, Inferential Statistics, Regression Analysis, Econometrics, Measurement Theory
数学社会学与形式理论	强调理论的形式化表达、逻辑推演和数学建模；培养形式化思维和模型化取向。	Mathematical Sociology, Formal Theory, Rational Choice Models, Game Theory

社会网络分析 (SNA)	开创对社会关系结构进行量化、可视化分析；奠定现代网络科学在社会领域应用的基础。	Sociometry, Network Concepts (Centrality, Cliques, Structural Holes, Weak Ties)
定量地理学/GIScience	发展处理和分析空间数据的方法与技术；关注空间依赖性、异质性和互动；提供 GIS 工具。	GIS, Spatial Statistics, Geovisualization, Spatial Interaction Models, Tobler's First Law of Geography
早期计算模拟/计算经济学	探索使用计算机模拟研究经济社会过程；孕育基于计算的建模思想和微观模拟方法。	Microsimulation, Early Macroeconomic Models, Computational Economics, Agent-Based Computational Economics (ACE)
复杂性科学	提供理解复杂适应系统（涌现、自组织、反馈）的理论框架；推广基于主体的建模（ABM）等核心方法论。	Complexity Theory, Agent-Based Modeling (ABM), Emergence, Self-Organization, Chaos Theory, Networks
网络科学 (现代)	融合多学科视角，发展分析大规模复杂网络结构、功能、演化的强大理论与计算工具。	Network Science, Small-World Networks, Scale-Free Networks, Community Detection, Network Dynamics, Link Prediction
数据科学/机器学习/AI/NLP	提供处理大规模、高维、异构（含文本）数据，进行模式识别、预测建模、自然语言理解的先进算法、工具、工程实践	Machine Learning (Supervised, Unsupervised, Deep Learning), NLP, Data Mining, Statistical Learning, Data Science

这些来自不同学科的智识源流，如同众多支流，在数字时代提供的海量数据和强大算力这一历史性机遇的催化下，开始加速汇聚、交叉、碰撞、融合，最终共同塑造了计算社会科学这一新兴研究领域的理论基础、方法论工具箱和核心议题。特别是复杂性科学、网络科学和数据科学/人工智能这三大领域的蓬勃发展，极大地促进了不同学科背景的研究者之间的对话、合作与方法共享，使得运用计算思维和工具来系统性地研究人类行为和社会系统成为可能，并逐渐形成了一个具有共同身份认同的研究共同体。

计算社会科学的界定：以四大核心研究任务为导向的范式整合

尽管存在着长期的智识积累和跨学科融合的趋势，计算社会科学 (Computational Social Science, CSS) 作为一个具有明确学科身份、独特研究议程和广泛学术影响力的研究领域得以正式确立并迅速兴起，其公认的里程碑事件是 2009 年，由 David Lazer 领衔的一组跨学

科研究者在《科学》(Science) 杂志上发表的开创性论文《计算社会科学》

(Computational Social Science) (Lazer et al., 2009)。这篇文章的影响力不仅在于它为这个新兴领域提供了一个简洁响亮的名字，更重要的是，它系统性地论证了利用因数字技术

(尤其是互联网和移动通信) 而产生的海量人类行为数据(他们称之为“关于我们是谁、我们做什么以及我们为何如此行事的惊人细节的数字面包屑”)，结合先进的计算方法(如网络分析、机器学习、自然语言处理、模拟)，来研究个体行为、社会互动和社会组织的巨大潜力与时代必要性。这篇文章如同一声号角，迅速在全球范围内激发了关于 CSS 的研究热潮、学术会议、项目资助、课程设立和范式讨论，有力地推动了该领域的建制化进程。

在此之后，领域内的学者们(如 Conte et al., 2012; Cioffi-Revilla, 2017; Watts, 2014; Pentland, 2014; Salganik, 2019; Edelman et al., 2020; 等)不断从不同角度深化、拓展和反思对 CSS 的理解。例如，Conte 等人(2012)发表的《计算社会科学宣言》(Manifesto of Computational Social Science)，进一步明确了该领域的议程，特别强调了超越数据挖掘和模式发现，致力于通过构建生成性计算模型(generative computational models)(尤其是 ABM)来理解社会现象背后的机制，实现对社会过程的“生成性解释”。Cioffi-Revilla(2017)在其著作《计算社会科学导论》(Introduction to Computational Social Science)中，系统地梳理了 CSS 的历史渊源、核心概念(如计算、信息、网络、复杂性、模拟)、方法论(数据驱动、模型驱动)以及应用领域，试图勾勒出一个相对完整的学科版图。Matthew Salganik(2019)在其广受欢迎的著作《比特与原子：数字时代的社会研究》(Bit by Bit: Social Research in the Digital Age)中，虽然未使用“计算社会科学”作为核心标签，但其对利用数字痕迹数据(他称之为“发现的数据”found data，区别于“设计的数据”designed data)、进行在线实验、开展大规模合作等新型研究方式的系统阐述和深刻反思，实际上构成了对 CSS 核心实践的重要贡献和指南。Duncan Watts(2016)则强调，CSS 的真正价值在于它能够帮助社会科学解决那些因规模、复杂性或数据限制而长期未能解决的“大问题”，并提出需要发展一种“计算社会科学的常识”，即理解何时以及如何有效地运用计算工具来增强社会科学洞察。

国内学者也对 CSS 的定义和范围进行了探讨。黄萃(2020)通过文献计量对比了国内外“社会计算”与“计算社会科学”的概念与研究热点，指出两者既有联系也有区别，需厘清范围。俞立平(2023)和吕鹏(2024)则尝试构建 CSS 的学科框架和体系，将其视为融合社会科学各分支(如计算社会学、计算政治学、计算经济学、计算传播学、计算法学、计算管理学、计算历史学、计算心理学、计算语言学等)与计算/数据科学方法的交叉领域集合。综合这些发展和论述，并结合第一部分对数字时代社会科学研究面临的挑战和任务拓展需求的分析，我们可以将计算社会科学(Computational Social Science, CSS)定义为：一个致力于深度整合社会科学(包括社会学、政治学、经济学、心理学、传播学、人类学、地理学、法学、历史学、管理学等)的理论洞察、研究问题与方法论传统，与计算机科学、数据科学、统计学、网络科学、复杂性科学、人工智能等领域的先进计算思维、算法工具和数据处理能力的跨学科研究领域。它利用日益强大的计算能力和爆炸式增长的大规模、多来源、高维度、动态变化的数据，旨在系统性地、以前所未有的规模和精度，执行并拓展社会科学研究四大核心任务：(1)对日益复杂的社会现象进行更深入、更精细、更动态的

描述；(2) 对社会结果和人类行为进行更准确、更及时、更具个性化的预测；(3) 在大规模观测数据和复杂系统中进行更稳健、更具机制性、更能处理异质性的因果推断；(4) 通过构建和分析计算模型（尤其是基于主体的模型）来模拟社会过程、探索微观机制如何生成宏观涌现模式，并深化对社会系统动态的生成性理解。

CSS 的最终目标是，通过这种整合与创新，突破传统方法的局限，在数据驱动（第四范式）和智能驱动（第五范式）下，深化我们对社会运行基本规律的认识，增强我们理解、预测和应对现实世界中重大社会挑战（如不平等、冲突、极化、传染病、气候变化、技术伦理、社会治理复杂性等）的能力，并为制定更有效、更公平的公共政策和社会干预提供基于证据的洞见和解决方案。

这一定义具有以下几个关键特征：

- 强调跨学科整合 (Interdisciplinary Integration): CSS 不是计算机科学在社会领域的简单应用，也不是社会科学对新工具的被动接受，而是两者的深度融合与相互塑造。它需要研究者同时具备社会科学的理论素养、问题意识和批判性思维，以及计算科学的技术能力、算法理解和工程实践。
- 以数据和计算为核心驱动力 (Data and Computation as Core Drivers): 海量、新型的数据资源和强大的计算能力是 CSS 得以兴起的物质基础和核心引擎。CSS 研究通常是数据密集型 (Data-intensive) 和计算密集型 (Computation-intensive) 的，处在第四范式向第五范式过渡的阶段。
- 聚焦四大核心研究任务 (Focus on Four Core Research Tasks): 该定义明确地将描述 (Description)、预测 (Prediction)、因果推断/解释 (Causal Inference/Explanation)、模拟/生成性理解 (Simulation/Generative Understanding) 这四大任务置于计算社会科学的核心地位。CSS 的独特性和价值，很大程度上就体现在它如何利用新的数据和计算工具，极大地拓展和深化了社会科学执行这四大基本研究功能的能力。这四大任务构成本书后续章节展开的核心框架，也是吕鹏（2024）总结的 CSS 学科使命的重要体现。
- 问题驱动与解决方案导向 (Problem-driven and Solution-oriented): CSS 的发展不仅是为了智识上的好奇，也常常与解决现实社会问题紧密相连 (Watts, 2017)。它致力于将社会科学的洞察力应用于理解和应对紧迫的社会挑战，服务于社会治理现代化。
- 方法论的多元性与创新性 (Methodological Pluralism and Innovation): CSS 并非单一方法论的代名词，而是包含了一系列利用计算手段进行社会研究的方法集合，并且鼓励在方法论层面的持续创新与交叉融合。它既包括对传统方法的计算化改造（如大规模问卷分析、计算文本分析），也包括引入全新的方法（如网络科学、机器学习、ABM、在线实验）。
- 内含伦理与社会反思 (Embedded Ethics and Social Reflection): 随着 CSS 能力的增强，其潜在的社会影响和伦理风险也日益凸显。对数据隐私、算法偏见、数据垄断、研究伦理、技术滥用等问题的关注和反思，以及数据治理体系的建设，是 CSS 健康发展不可或缺的内在组成部分。可以说，计算社会科学的诞生，标志着社会科学研究范式的一

次重要演进，是从主要依赖“小数据”、传统统计和简化模型的范式，向一个能够拥抱“大数据”、运用先进计算和模拟复杂性的新范式的转型。这一转型仍在进行中，且新旧范式并非完全取代关系，而是共存、互补与融合，形成了理论、数据、模型之间的“三角对话”。理解 CSS 的核心理念、智识根源和基本界定，是进入这个快速发展的领域的第一步。接下来的部分，我们将聚焦于支撑这一定义的四大核心研究任务，详细阐述它们在 CSS 框架下如何被重新定义、拓展和实现。

第三节——计算社会科学的四大支柱： 核心任务、解决的问题与领域特性

计算社会科学作为一个新兴的、充满活力的研究领域，其独特性和核心贡献可以通过它如何系统性地、创新性地执行社会科学研究四大基本任务来体现。这四大任务——描述、预测、因果推断和模拟——构成了计算社会科学研究实践的四大支柱，它们不仅界定了领域的主要活动范围，也塑造了其方法论特征和知识追求的目标。正是围绕这四大任务，计算社会科学整合了新的数据资源、计算能力和跨学科的理论视角，以应对数字时代提出的新挑战，并深化我们对复杂社会世界的理解。本部分将逐一深入探讨这四大核心任务在计算社会科学框架下的内涵、所解决的关键问题、所依赖的核心方法，以及这些任务共同塑造的计算社会科学的鲜明特征与性质。

任务一：CSS 赋能的描述——绘制数字社会的全景图

任务内涵与目标

描述性研究旨在回答“是什么？”的问题，即对社会现象的特征、分布、结构、模式和随时间的变化进行准确、全面、深入的刻画。它是所有科学探索的基础，为理论构建、假设提出和后续的解释或预测提供经验起点。在计算社会科学的语境下，描述性任务的目标是利用大规模、多样化、高粒度的数字数据和先进的计算分析与可视化技术，超越传统描述方法的局限，揭示出那些在小规模、静态、结构化数据中难以或不可能观察到的复杂社会图景。其目标是绘制出数字社会更为全面、精细、动态和结构化的“地图”或“画像”。

解决的关键问题

传统的描述性社会科学研究（如基于调查的社会概览、基于官方统计的人口结构分析）虽然重要，但在面对数字时代的复杂社会现象时，往往难以回答以下层次的问题：

- 在一个拥有数百万甚至数十亿节点和连接的在线社交网络中，真实的社群结构是怎样的？哪些是核心社群，哪些是边缘社群？它们之间如何互动连接？(e.g., Newman & Girvan, 2004)

- 一场大规模的在线社会运动或信息疫情，其信息传播的实际路径、速度、范围和关键节点是什么？信息是如何跨越不同平台和人群进行扩散的？(e.g., Centola, 2010; Vosoughi et al., 2018)
- 海量的用户生成内容（如推文、博客、评论）中，公众对于某个特定政策、事件或社会议题的集体情绪状态（如喜悦、愤怒、恐惧）是如何随时间动态演变的？存在哪些主要的意见派别或话语框架？(e.g., Bollen et al., 2011; DiMaggio et al., 2013) 国内学者如汪静莹等（2016）也基于微博数据分析情绪变化。
- 基于大规模移动定位数据或在线地理标记信息，城市内部的居民活动模式、功能区域划分、通勤流动网络以及社会隔离的空间格局呈现出怎样的细微特征？(e.g., Blumenstock et al., 2015; Shelton et al., 2015)
- 在庞大的学术引用网络或企业合作网络中，知识传播的核心路径、学科交叉的结构特征、创新产生的关键位置在哪里？(e.g., Uzzi et al., 2013)
- 大规模的在线行为数据（如购物、浏览、搜索）揭示了哪些消费模式、文化品味或生活方式的群体性差异与集聚？这些模式如何与传统的社会分层因素（如阶级、教育）相关联？(e.g., Goel et al., 2010)。
 这些问题都需要能够处理海量、复杂（网络、文本、时空）数据的描述性方法才能有效回答。

核心赋能方法

计算社会科学通过引入一系列计算工具和方法（俞立平，2023；吕鹏，2024），极大地增强了描述能力：

- 网络分析 (Network Analysis): 利用图论算法和网络科学原理，对大规模关系数据（社交网络、通信网络、引用网络、交易网络等）进行结构分析和可视化。包括计算各种网络度量（中心性、聚类系数、路径长度）、进行社群检测（Community Detection）、识别关键节点和连接（如桥接点、结构洞）、可视化网络布局等，以揭示隐藏的社会结构。
- 自然语言处理 (Natural Language Processing, NLP): 应用于大规模文本语料（社交媒体帖子、新闻、评论、政治文献、历史档案等）。包括文本预处理、词频统计、关键词提取；更高级的技术如情感分析（Sentiment Analysis）来量化文本中的情绪倾向；主题建模（Topic Modeling, 如 LDA）来发现文本集合中隐藏的主题结构；命名实体识别（NER）和关系抽取（RE）来提取关键信息；词嵌入（Word Embeddings, 如 Word2Vec, GloVe）和句子/文档嵌入（如 BERT, GPT 等大模型）来捕捉词语和文本的语义关系，进而分析话语模式、意识形态差异等。

- 地理空间分析 (Geospatial Analysis) 与地理可视化: 利用 GIS 技术和空间统计方法, 分析带有地理位置信息的数据 (如手机信令数据、GPS 轨迹、社交媒体签到数据)。包括绘制热力图 (Heatmaps) 展示密度分布、计算空间自相关 (Spatial Autocorrelation) 检验集聚模式、进行空间聚类 (Spatial Clustering) 识别区域、可视化流动模式 (Flow Maps) 等, 以揭示社会现象的空间维度。
- 数据可视化 (Data Visualization): 利用先进的计算可视化技术 (如图形库 D3.js, Plotly, Gephi 等) 将大规模、高维度的数据转化为直观、可交互的图形表示。不仅包括传统的统计图表, 更强调对复杂结构 (如网络、层次、时空动态) 的有效呈现, 帮助研究者探索数据、发现模式、交流发现。
- 大规模数据处理与挖掘 (Large-scale Data Processing and Mining): 利用分布式计算框架 (如 Spark) 和数据库技术处理海量数据; 应用聚类 (Clustering)、降维 (Dimensionality Reduction, 如 PCA, t-SNE, UMAP)、关联规则挖掘 (Association Rule Mining) 等数据挖掘算法来发现数据中未知的模式和结构。

通过综合运用这些方法, CSS 能够提供对社会现象前所未有的“全景式”(panoramic)、“细粒度”(granular) 和“动态性”(dynamic) 描述。这种描述不再局限于抽样样本的统计推断, 而是能够直接呈现大规模系统 (有时甚至是全样本, 即萨尔加尼克所说的“N=all”的可能性) 的复杂性和异质性, 为社会科学理论提供了更丰富、更精确的经验基础。

任务二：CSS 赋能的预测——把握社会脉搏与未来轨迹

任务内涵与目标

预测性研究旨在回答“将会怎样?”或“属于哪类?”的问题, 即利用历史和当前的数据来预测未来的社会结果、个体行为或对未观测到的案例进行分类。在 CSS 语境下, 预测任务的目标是利用大规模、高维度的数字痕迹数据和机器学习等先进算法, 显著提升对某些社会现象预测的准确性、时效性和粒度, 超越传统预测模型的局限。其目标不仅在于获得准确的预测本身 (这在许多应用场景下具有直接价值), 也在于通过预测实践来检验我们对社会过程的理解深度, 并为理解预测模型背后的社会逻辑 (或偏差) 提供契机。国内研究如陈云松等 (2020) 也强调了基于机器学习的预测作为一种新研究范式的重要性。

解决的关键问题

- 个体行为预测: 基于用户的历史行为、社交网络、个人属性等信息, 预测其未来可能做出的选择, 如是否会点击某个广告、购买某件商品、阅读某篇文章、从某个平台流失、参与某项政治活动 (如投票、捐款)、甚至出现某些健康风险 (如抑郁倾向, de Choudhury et al., 2014; 白朔天等, 2014) ? (e.g., Kleinberg et al., 2015; Backstrom et al., 2010)
- 群体动态与集体行为预测: 预测某条信息 (新闻、谣言、模因) 在社交网络上的流行度或传播范围? 某个话题的舆论热度会如何演变? 金融市场的价格波动趋势如何? 某个地区的犯罪率或失业率在下一周期会上升还是下降? (e.g., Preis et al., 2013; Glaeser et al., 1996; Perry, 2013)
- 宏观社会结果预测: 预测选举结果 (候选人得票率、政党获胜概率)? 流行病的爆发规模和地理扩散模式? 经济衰退或复苏的信号? 国际冲突的风险? (e.g., Beauchamp, 2017; Vespignani, 2009; Choi & Varian, 2012; Chadeaux, 2014)
- 分类与识别: 对个体或内容进行分类, 如识别网络水军或机器人账号? 判断文本的情感极性或是否为虚假信息? 根据消费行为划分用户群体? 根据卫星图像识别贫困地区? (e.g., Ferrara et al., 2016; Pang & Lee, 2008; Jean et al., 2016)
这些预测任务往往涉及高维特征、复杂的非线性关系、海量数据以及对实时性的要求, 是传统统计模型难以胜任的。

核心赋能方法

CSS 主要借助机器学习 (Machine Learning) 和数据科学 (Data Science) 工具箱来执行预测任务:

- 监督学习 (Supervised Learning): 这是预测任务的核心方法。给定一组带有已知标签 (结果) 的训练数据, 算法学习一个从输入特征到输出标签的映射函数。
- 分类 (Classification): 预测离散类别标签 (如投票给 A 或 B, 是/否垃圾邮件)。常用算法包括逻辑回归 (Logistic Regression)、支持向量机 (Support Vector Machines, SVM)、朴素贝叶斯 (Naive Bayes)、决策树 (Decision Trees)、随机森林 (Random Forests)、梯度提升机 (Gradient Boosting Machines, 如 XGBoost, LightGBM)、神经网络 (Neural Networks) 等。
- 回归 (Regression): 预测连续数值结果 (如信息流行度、股价、得票率)。除了线性回归, 还包括岭回归 (Ridge)、LASSO、以及上述多种算法的回归版本。
- 深度学习 (Deep Learning): 作为机器学习的一个分支, 利用深层神经网络 (如 CNNs, RNNs, LSTMs, Transformers) 在处理具有复杂结构的数据 (如图像、文本、时间序列、网络) 时表现出色, 尤其在自然语言处理和计算机视觉相关的预测任务中取得了突破性进展。

- 特征工程 (Feature Engineering): 从原始数据中提取、构造和选择对预测目标最有用的特征变量。在大数据背景下, 这可能涉及处理高维稀疏数据、文本表示 (如 TF-IDF, embeddings)、网络特征 (如中心性度量)、时空特征等。好的特征工程往往对预测性能至关重要。
- 模型评估与选择 (Model Evaluation and Selection): 使用恰当的评估指标 (如准确率、精确率、召回率、F1 分数、AUC 用于分类; RMSE、MAE、 R^2 用于回归) 和交叉验证 (Cross-validation) 等技术来评估模型在未见数据上的泛化能力, 并选择最优模型。
- 时间序列预测 (Time Series Forecasting): 针对具有时间依赖性的数据 (如股价、舆论指数), 使用 ARIMA、指数平滑、向量自回归 (VAR)、以及基于 RNN/LSTM/Transformer 的深度学习模型进行预测。

CSS 赋能的预测, 其优势在于能够处理海量、高维、异构数据, 自动发现复杂的非线性模式, 并可能达到比传统模型更高的预测精度。 然而, 预测任务在 CSS 中也面临诸多挑战: 社会系统的内在随机性和复杂性使得精确预测极为困难; 模型的预测性能可能随时间推移而衰减; 预测结果往往缺乏直观的因果解释 (“黑箱”问题); 以及前述的公平性、问责性和透明性 (FAT/FAccT) 等伦理问题。因此, CSS 领域的预测研究不仅追求精度提升, 也日益关注模型的可解释性 (Explainable AI, XAI)、稳健性 (Robustness)、公平性 (Fairness) 以及预测与理论解释之间的关系。

任务三：CSS 赋能的因果推断——在复杂世界中探寻“为什么”

任务内涵与目标

因果推断旨在回答“为什么?” (探寻原因) 和“如果...会怎样?” (评估干预效果) 的问题, 即识别变量之间的因果关系, 并量化原因对结果的影响程度。这是科学研究 (尤其是社会科学和政策评估) 的核心目标, 因为它关乎我们对世界运行机制的理解以及采取有效行动改变世界的能力。在 CSS 语境下, 因果推断任务的目标是利用大规模数字数据 (包括实验数据和观测数据) 以及融合了统计学、计量经济学和机器学习思想的先进方法, 在日益复杂的数据环境 (高维混淆、非线性关系、异质性效应) 中进行更稳健、更可信、更细致的因果效应识别与估计。

解决的关键问题

CSS 致力于在以下方面增强社会科学的因果推断能力，以回答诸如此类的问题：

- 评估大规模干预的效果: 某项在线教育计划是否真的提高了学生的学习成绩？社交媒体平台上的某种信息干预（如事实核查标签）能否有效减少虚假信息的传播？政府发放的电子消费券对刺激地方经济有多大作用？这些问题可以通过大规模在线实验（A/B测试）或利用数字痕迹数据进行准实验评估来回答。（e.g., Kohavi et al., 2020; Coppock et al., 2021）
 - 处理观测数据中的高维混淆: 在研究社交媒体使用对心理健康（如抑郁、幸福感）的影响时，如何控制大量潜在的混淆因素（如用户的个性特征、线下社交活动、生活压力事件等——这些因素可能部分反映在用户的数字足迹中）？（e.g., Orben & Przybylski, 2019; Braghieri et al., 2022）
 - 识别异质性处理效应 (HTE): 某项就业培训政策对不同背景（如年龄、性别、教育程度、先前工作经历）的失业者效果是否不同？理解HTE有助于设计更具针对性和公平性的政策。大规模数据为估计HTE提供了可能性。（e.g., Athey & Imbens, 2016; Davis & Heller, 2017）。
 - 利用网络数据进行因果推断: 个体的行为（如采纳新技术、参与抗议）是否受到其社交网络邻居的影响（社会传染或同伴效应）？如何区分影响是源于社会互动（因果效应）还是仅仅因为相似的人倾向于连接在一起（同质性混淆）？网络结构本身（如中心性位置）是否对个体的结果（如职业成功）有因果影响？这需要处理网络依赖性（干扰/溢出效应）和网络形成内生性等复杂问题。（e.g., Shalizi & Thomas, 2011; Aronow & Samii, 2017; Ugander et al., 2012）
 - 打开机制的“黑箱”: 不仅要估计处理的总体效果，还要理解效果是通过哪些中介机制（mediating mechanisms）产生的。例如，一项旨在提高投票率的短信提醒，是通过提高信息获取度起作用，还是通过激活社会规范？利用丰富的过程数据（process data）可能有助于进行因果中介分析（causal mediation analysis）。（e.g., Imai et al., 2011）
- 这些问题都要求超越传统的回归分析框架，采用更精密的因果推断设计和方法。

核心赋能方法

CSS 在因果推断方面的发展，体现了对传统因果推断思想（如图模型、潜在结果框架）的继承，以及与新数据类型和机器学习方法的融合：

- 大规模在线实验 (Large-scale Online Experiments / A/B Testing): 利用互联网平台作为“实验室”，对大量用户进行随机分组，测试不同版本的网页、产品、算法或信息干预的效果。这是在真实世界环境中获得可靠因果证据的强大途径，但需关注其伦理、外部效应（平台效应、样本代表性）和长期效应问题。

- 准实验设计 (Quasi-experimental Designs) 的深化应用: 利用大规模、细粒度数据, 更精确地识别和利用自然发生或政策形成的“准随机性”来源。例如, 利用精确的时间戳和地理边界进行更可信的断点回归 (RDD); 利用面板数据和事件研究法进行更精细的双重差分 (DiD) 及其扩展; 利用丰富的控制变量构建更可信的合成控制组 (SCM); 寻找更有效的工具变量 (IV)。
- 因果图模型 (Causal Graphical Models): 使用有向无环图 (DAGs) 来清晰地表达关于变量间因果关系的假设, 并基于图论准则 (如 d-分离) 来识别需要控制哪些变量 (调整集) 以消除混淆偏差, 从而指导模型设定。这有助于使因果假设更透明、更系统化。
- 因果机器学习 (Causal Machine Learning): 这是一个快速发展的交叉领域, 旨在将机器学习的灵活性和预测能力用于因果推断任务, 以克服传统方法的局限性 (如对模型形式的强假设、处理高维数据的困难)。关键方向包括:
 - 使用 ML 估计“干扰参数”(Nuisance Parameters): 如使用机器学习模型 (随机森林、梯度提升、神经网络等) 来估计倾向得分 (Propensity Score) 或条件结果期望 (Conditional Outcome Expectations), 然后将这些估计值代入半参数化的因果效应估计量 (如 IPTW、双重稳健估计 Double Robust Estimation、匹配 Matching) 中, 以获得对平均处理效应 (ATE) 或条件平均处理效应 (CATE) 的更稳健估计。Double Machine Learning (DML) 是其中的代表性框架。
 - 使用 ML 估计异质性处理效应 (HTE): 开发专门的机器学习算法 (如 Causal Trees, Causal Forests, Bayesian Additive Regression Trees - BART) 来直接估计处理效果如何随个体特征变化, 并发现哪些子群体对处理反应最强烈或最微弱。
 - 结合因果发现 (Causal Discovery) 与 ML: 探索能否从观测数据中 (在一定假设下) 自动学习因果结构 (如 DAG), 但这仍然是一个极具挑战性的前沿领域。

CSS 赋能的因果推断, 其核心追求是在日益复杂的数据世界中, 获得更可靠、更细致、更少依赖主观臆断的因果结论。 它强调研究设计的重要性, 透明化因果假设, 以及利用机器学习的优势来处理数据复杂性 (如高维、非线性), 同时要警惕机器学习本身可能引入的新问题 (如过拟合、可解释性差、算法偏差)。成功的因果推断需要社会科学理论的指导、严谨的方法论思维和娴熟的计算技能的紧密结合。

任务四：CSS 赋能的模拟——人工社会中的涌现与机制

任务内涵与目标

模拟性研究旨在回答“如何发生？”(How does it happen?) 或“生成机制是什么？”(What are the generative mechanisms?) 的问题，即通过构建运行于计算机上的形式化模型来复现（或“生长”出）我们观察到的社会现象，从而理解其背后的微观基础和动态过程。在 CSS 语境下，模拟任务，特别是基于主体的建模 (Agent-Based Modeling, ABM)，被视为理解复杂社会系统（充满互动、异质性、适应性、反馈和涌现）的核心工具。其目标是超越对变量间相关性或因果效应的静态分析，致力于对社会过程的生成性理解 (Generative Understanding)，即理解宏观模式是如何从微观单元的互动规则中内生性地涌现出来的。

解决的关键问题

计算模拟，尤其是 ABM，特别适合探索以下类型的问题，这些问题往往难以用传统的分析模型或实证方法完全解答：

- 宏观模式的微观基础: 社会规范（如合作、信任、歧视）是如何在个体互动中形成、传播和演变的？城市中的居住隔离模式是如何仅仅基于个体微弱的偏好而自发形成的？金融市场中的泡沫和崩溃是如何从交易者的有限理性和羊群行为中产生的？(e.g., Axelrod, 1997; Schelling, 1971; Lux & Marchesi, 1999)
- 过程与机制的探索: 信息或疾病在不同类型的社会网络结构中是如何传播的？网络结构本身如何影响传播的效率和结果？社会影响 (social influence) 和同质性 (homophily) 这两种机制在塑造群体行为（如意见动态、技术采纳）中各自扮演什么角色？(e.g., Centola & Macy, 2007; Macy & Willer, 2002)
- 反事实思考与政策实验: 如果我们改变个体的行为规则（如提高利他主义倾向），或者改变环境的结构（如调整网络拓扑、实施某种政策干预），会对系统的宏观行为产生什么影响？ABM 可以作为一种进行“虚拟实验” (in silico experiments) 的平台，探索不同干预措施的潜在后果，尤其是在真实世界实验不可行或成本过高的情况下。(e.g., Gilbert, 2008)。
- 理论的形式化与检验: 将模糊的语言性社会理论转化为精确的计算模型，可以检验理论的内部逻辑一致性、假设的充分性，并推导出理论的经验可检验含义。ABM 可以作为连接理论与经验数据的桥梁。(e.g., Manzo, 2014)
- 理解复杂性本身: 探索非线性、反馈、临界点 (tipping points)、路径依赖等复杂系统特性在社会过程中的作用。ABM 能够自然地容纳这些特性，帮助我们理解为何社会系统常常表现出难以预测和控制的行为。

核心赋能方法

计算社会科学中的模拟主要依赖于以下方法和实践：

- 基于主体的建模 (Agent-Based Modeling, ABM): 这是 CSS 中最具代表性的模拟方法。研究者定义构成系统的“智能体” (Agents, 可以是人、家庭、公司、国家等), 赋予它们内部状态 (State)、感知能力 (Perception)、行为规则 (Rules) 和学习/适应机制 (Learning/Adaptation)。这些智能体被放置在一个模拟的环境 (Environment, 可以是空间网格、社会网络、市场等) 中进行互动。通过在计算机上运行模拟, 观察从大量智能体互动中涌现出的系统级模式。
- 系统动力学 (System Dynamics, SD): 另一种模拟方法, 侧重于使用反馈循环、存量和流量的数学模型来表示系统变量之间的关系, 并模拟系统随时间的行为。虽然通常比 ABM 更宏观、更聚合, 但在某些问题 (如资源管理、组织学习) 上也有应用。
- 网络动力学模拟 (Network Dynamics Simulation): 将 ABM 的思想应用于网络结构上, 模拟信息、疾病、行为等在网络中的传播过程 (如 SIR/SIS 模型、阈值模型等), 或者模拟网络结构本身的演化 (如优先连接模型)。
- 模型设计与规范 (Model Design and Specification): 构建一个好的模拟模型需要仔细思考: 模型的目的 (KISS 原则 - Keep It Simple, Stupid vs. KIDS 原则 - Keep It Descriptive, Stupid)、智能体的构成和行为规则 (基于理论、经验数据还是启发式)、环境的表示、时间步长的设定等。ODD 协议 (Overview, Design concepts, Details) 提供了一个描述 ABM 的标准框架, 以提高模型的透明度和可重复性。
- 模型校准、验证与确认 (Model Calibration, Validation, and Verification): 如何确保模拟模型是可信的? 这涉及到验证 (Verification) (模型是否正确地实现了设计者的意图? 代码有无 bug?)、校准 (Calibration) (调整模型参数使其输出能拟合已知的经验数据模式)、确认 (Validation) (模型是否能复现未用于校准的其他经验模式? 模型是否对现实世界具有解释力或预测力?)。这是一个复杂且持续的过程, 需要结合定量比较和定性判断。
- 模拟实验设计与分析 (Simulation Experiment Design and Analysis): 如何从模拟运行中获得洞见? 这需要系统性地设计模拟实验 (如参数扫描 Parameter Sweeping、敏感性分析 Sensitivity Analysis、多因子实验设计), 并运用统计方法和可视化工具来分析模拟输出的大量数据, 理解参数对结果的影响、模型的稳健性以及涌现模式的特征。

css 赋能的模拟, 其核心价值在于提供了一种“生成性”的理解途径, 帮助我们打开社会过程的“黑箱”, 理解微观机制如何“自下而上”地导致宏观现象。 它是一种强大的理论构建和检验工具, 也是一种进行虚拟政策实验的“计算实验室”。然而, 模拟方法也面临挑战: 模型的构建往往需要大量假设, 其结果对假设的敏感性可能很高; 模型的验证和确认通常很困难; 复杂模型的计算成本可能很高; 如何将模拟结果与现实世界的复杂性进行有效关联也是一个持续的议题。

四大任务驱动下的计算社会科学核心特征与性质

计算社会科学之所以被视为一个新兴的、具有独特性的研究范式，正是因为它系统性地致力于执行上述四大核心任务，并在这一过程中展现出了一系列鲜明的特征（吕鹏，2024）。这些特征并非孤立存在，而是执行描述、预测、因果推断和模拟这四大任务所必需的条件或自然产生的结果：

- **深度跨学科性 (Profound Interdisciplinarity):** 成功地执行任何一项 CSS 核心任务，都离不开社会科学与计算/数据科学/AI 等领域的知识融合。例如，进行有意义的描述性网络分析，需要社会学关于关系结构的理论指导，也需要计算机科学的图算法和可视化技术。进行有效的预测，需要理解预测目标的社会背景（领域知识），也需要掌握机器学习的建模技能。进行稳健的因果推断，需要社会科学的因果理论框架（如潜在结果模型）和对混淆的敏感性，也可能需要统计学和机器学习的前沿估计方法。构建可信的模拟模型，需要社会理论来设定智能体的行为规则，也需要编程能力来实现模型并进行分析。因此，跨学科合作或具备跨学科素养成为 CSS 研究者的必备条件。
- **数据密集型与智能驱动范式 (Data-Intensive & AI-Driven Paradigm):** CSS 研究在很大程度上是由大规模、多样化的新型数据资源（尤其是数字痕迹）以及日益强大的 AI 算法所驱动和塑造的。这些数据和算法为描述提供了前所未有的细节和广度，为预测提供了丰富的特征信息和模式识别能力，为因果推断（尤其是在观测研究中）提供了处理复杂性的可能性和进行大规模实验的基础，也为模拟模型的校准、验证和行为规则设定提供了经验依据和智能体能力。对数据特性（规模、速度、多样性、关系性）和缺陷（偏差、噪音、代表性）以及算法特性（黑箱、偏见）的深刻理解和审慎处理，贯穿于所有四大任务的实践中。
- **计算方法与理论的整合 (Integration of Computational Methods and Theory):** 先进的计算方法是提升 CSS 执行四大任务能力的关键引擎。然而，CSS 并非仅仅是方法的应用，而是强调计算方法与社会科学理论的深度融合。如周涛等（2022）提出的“三角对话”框架，理论指导数据挖掘和模型构建，而数据和模型的结果又反过来验证、修正或启发理论。苏毓淞（2021）也指出，CSS 并非“理论的终结”，而是为理论发展提供了新机遇。CSS 研究者需要具备计算素养（Computational Literacy），更需要具备在理论指导下运用和批判性评估这些方法的能力。
- **对复杂性的深刻关注 (Engagement with Complexity):** 社会系统本质上的复杂性（非线性、反馈、涌现、异质性、适应性等）是 CSS 研究的核心关切之一。模拟任务直接致力于理解和生成这种复杂性。而在描述任务中，需要能够刻画复杂的网络结构和动态模式。在预测任务中，需要能够捕捉复杂的非线性关系。在因果推断任务中，需要考虑处理效应的异质性以及潜在的网络溢出效应。对复杂性的关注促使 CSS 发展和运用能够处理这些特征的方法论。

- 跨尺度分析与整合能力 (Cross-Scale Analysis and Integration): CSS 致力于在不同分析层级（个体、群体、组织、网络、社会）之间建立联系。例如，描述可能涉及刻画跨层级的网络结构。预测可能旨在预测个体行为如何汇聚成群体趋势。因果推断可能研究宏观政策对微观个体的影响，或者微观互动如何产生宏观效应。模拟的核心目标就是连接微观机制与宏观涌现。这种跨尺度整合能力是理解复杂社会系统的关键。
- 模型作为核心认知与实践工具 (Models as Core Epistemic and Practical Tools): 在 CSS 的所有四大任务中，“模型”都扮演着核心角色，无论是用于描述的统计模型或网络模型，用于预测的机器学习模型，用于因果推断的因果模型，还是用于模拟的计算模型。CSS 强调对模型本身的理解——包括其假设、能力、局限性、适用范围以及潜在的偏差。模型不仅是认识世界的工具，也是干预世界（通过预测或政策模拟）的基础。因此，对模型的构建、评估、解释和批判性使用是 CSS 方法论训练的重要组成部分。
- 强化的伦理关切与治理需求 (Heightened Ethical Concerns and Governance Needs): 由于处理大规模个人数据和利用强大算法进行预测与干预，CSS 面临着比传统研究更严峻的伦理挑战和治理需求。数据隐私保护、算法公平性、透明度、问责制、数据垄断以及潜在的社会操纵等问题，成为 CSS 研究不可回避的议题。建立完善的数据治理框架和伦理规范是其可持续发展的保障。

因此，计算社会科学之所以被视为一个新兴的、具有独特性的研究范式，并不仅仅在于它采用了新颖的技术手段，更深层次的原因在于，它围绕着社会科学研究的四大核心基石性任务——描述、预测、因果推断与模拟——进行了系统性的拓展与革新。**正是这种以任务为导向的驱动力，塑造了计算社会科学深度跨学科、数据密集与智能驱动、强调理论与计算方法整合、深刻关注复杂性、致力于跨尺度分析、以模型作为核心认知与实践工具、并内含强烈伦理关切与治理需求的鲜明特征与内在性质。**这四大任务及其伴生的特征，共同构成了计算社会科学的骨架与灵魂。掌握这四大任务核心理念、方法论脉络、前沿进展以及它们之间错综复杂的内在联系，并理解其背后所蕴含的认识论预设与伦理考量，是深入学习、批判性思考和创造性实践计算社会科学的关键所在，也是应对数字时代社会研究所面临挑战的必然要求。

为了帮助读者系统性地构建这种理解和能力，本书接下来的编排将紧密围绕这些核心要素展开，旨在提供一条从认知基础到任务实践的清晰路径。这并非寻求一种可以包罗万象、一劳永逸的“万能算法”，而是希望通过结构化的指引，赋予读者一种驾驭复杂性的“无算之策”，从而能够在计算社会科学这片充满机遇与挑战的新疆域中，“尽算万事”，洞察社会运行的深层逻辑。

第四节——无算之策：编排思路与结构

本书旨在为步入或深化探索计算社会科学这一交叉学科前沿领域的读者，精心绘制一幅系统的思想地图与实践蓝图。计算社会科学的蓬勃发展，既是数字时代赋予社会科学的深刻机遇，也是对其提出的严峻挑战。它要求我们将社会科学悠久的理论洞察、敏锐的问题意识，与计算机科学、数据科学、复杂性科学等领域的前沿工具及思维范式进行深度融合。这一新兴领域围绕着一系列核心研究任务，如描述复杂现象、预测未来趋势、推断因果机制、模拟社会过程、解析文本意义、驾驭网络结构、利用大型语言模型以及整合多元信息等，展现出独特的知识景观与实践范式。面对这样一个知识体系日益庞大、技术方法快速迭代、且蕴含深刻伦理意涵的领域，如何才能避免陷入对零散技术工具的盲目追逐，或是理论思考与实践应用相脱节的困境，从而系统性地把握其精髓？这正是本书编排结构所要着力回应的核心关切。我们深信，真正的“无算之策”，并非寄望于某种只言片语的方法教学，而是植根于对基础原理的透彻理解、对核心能力的系统培养、对问题意识的持续砥砺，以及对研究实践逻辑的清晰把握。基于此，本书的整体结构设计遵循一套内在的逻辑脉络，力求引导读者循序渐进、由表及里、理论与实践紧密结合，从而稳健地构建起计算社会科学的知识框架与研究能力。

第一部分：基础先行

本书的编排逻辑，首要遵循基础先行的原则。全书的第一部分将致力于构建后续所有研究所需的坚实基础。在深入探讨具体的计算方法及其在特定任务中的应用之前，我们认为必须为读者铺设一个涵盖研究思维范式、通用方法论原则以及基础技术操作环境的共享平台。这部分内容旨在为后续所有关于具体任务和方法的学习与实践，提供一个统一的出发点和参照基准。

在认识论与思维范式层面，我们将超越对技术的表面介绍，深入剖析计算社会科学背后的认知基础，包括计算思维（如抽象、分解、模式识别、算法设计）如何赋能社会科学洞察，如何将模糊的社会议题转化为可计算问题，以及如何在理论驱动与数据驱动之间寻求平衡。我们还将引导读者深刻理解社会数据的本质，认识到数据作为现实的“代理”

（proxies）所固有的间接性、选择性与潜在偏误，特别是数字足迹数据的独特性及其对数据质量的严苛要求。同时，我们将探讨模型作为理解世界的核心工具，强调明确模型目标（描述、预测、解释、模拟）的重要性，并审视模型的内在属性（假设、局限性、适用范围）以及算法本身所嵌入的社会性与伦理考量（如偏见、公平性、透明度）。

在通用方法论原则层面，本部分将系统梳理计算社会科学研究的迭代流程，从问题形成、数据获取与评估，到数据预处理、探索性分析、模型构建、执行与评估，直至结果解

释、理论关联与沟通复现。我们将重点阐述概念化与操作化的关键过程，即如何将抽象的社会科学构念转化为可测量、可计算的指标，特别是在数字环境下寻找代理变量、构建指标以及评估其信效度的挑战。此外，还将介绍社会科学研究中常见的数据多样性，包括结构化、非结构化、半结构化以及网络、地理空间等特定结构数据的特点，并讨论数据获取的策略、技术及其伴随的伦理与法律规范（如知情同意、隐私保护、伦理审查）。

最后，在操作基础层面，本部分将为读者搭建通往实践的技术桥梁，介绍核心的编程语言（重点是 Python 及其数据科学生态）与环境管理工具，强调版本控制（Git/GitHub）对于研究规范性与可复现性的关键作用，并概述常用的数据存储格式、数据库基础（特别是 SQL）以及核心的开发与分析工具（如 Jupyter, IDEs）和云计算平台的基本概念。可以说，这一“基础先行”的部分，构成了整座知识大厦的地基，其坚实与否，直接决定了后续学习研究所能企及的深度与广度。

第二部分：任务驱动

在坚实的认知与技术基础之上，本书的主体内容——第二部分——将围绕任务驱动的核心原则展开。我们认为，计算社会科学的独特价值与贡献，最清晰地体现在它如何系统性地赋能、拓展乃至革新社会科学研究所需执行的一系列核心分析任务。

因此，我们将以这些关键的研究任务作为组织本书核心章节的经络，而非简单地按照某种特定技术或某个特定子学科来划分。这种以任务为导向的组织结构具有显著优势：它直接回应了前文所述社会科学在数字时代面临的核心能力需求，使内容编排与领域发展的内在驱动力保持高度一致；它有助于读者理解，各种看似纷繁复杂的计算方法并非孤立的技术点，而是服务于特定研究目标的有机工具集。

例如，在“描述社会现象”的任务下，我们会整合统计描述、探索性数据分析、以及针对时间序列、地理空间、网络、文本等特定数据类型的描述技术；在“预测社会结果”的任务下，会系统介绍机器学习中的监督学习范式及其核心算法（从线性模型到集成树再到深度学习）；“解释社会机制”则聚焦于因果推断的逻辑框架与方法（从随机实验到准实验再到基于观测数据的建模和因果机器学习）。

通过将相关方法置于对应的任务框架内进行系统阐述，读者能够更清晰地洞察不同方法在达成同一研究目标时的优劣、适用场景及内在关联，从而能够基于具体的研究问题，更富洞察力地选择、组合与运用方法。此外，这种结构设计亦有助于打破传统研究范畴中有时存在的壁垒，展现计算社会科学如何在更高层次上整合描述、预测、解释、模拟等多元目标，例如，利用精细描述发现预测变量，借助预测性能评估因果理解，或通过模拟探索机制并生成可预测模式。

因此，本书的核心部分将逐一深入探讨这八大任务在计算社会科学语境下的新内涵、关键挑战、核心方法论、经典与前沿应用，以及实践中的关键考量。

与任务驱动原则深度融合的是对问题导向的持续强调。本书并非一本远离现实关怀的纯粹方法论汇编，其根本旨归在于助力读者运用计算社会科学的工具与思维，去探究和理解真实的社会科学问题。因此，在每一个以任务驱动原则组织的核心章节内部，我们将始终秉持问题导向的理念。这意味着，我们不仅仅是介绍一种技术（例如，主题建模或因果森林），更会着重阐明：这项技术能够帮助我们解答哪些类型的社会科学疑问？一个具体的社会科学议题是如何被巧妙地“翻译”或“转化”（translate/transform）为一个能够运用特定计算方法加以探究的研究问题的？这个关键的转化过程涉及到哪些核心的抽象步骤、必要的假设设定以及具体的操作化策略？

我们将借助贯穿全书的、涵盖社会学、政治学、经济学、传播学、心理学、历史学等多元学科领域的丰富案例研究，生动展示从社会科学问题提出到计算解决方案设计的完整思维链条。我们期望读者在习得方法“工具箱”的同时，更能涵养一种将深厚的理论素养、敏锐的现实关怀与严谨的计算实践融为一体的“计算社会科学思维模式”。这种思维模式的核心能力在于：能够精准识别哪些社会科学难题最能从计算方法的介入中获益；能够创造性地设计出利用数据与计算探索这些难题的新颖路径；并能够批判性地解读计算分析结果背后所蕴含的社会意义及其固有的局限性。故而，问题导向不仅是内容遴选的圭臬，更是贯穿全书的一种思维训练方式，旨在确保技术学习始终服务于有意义的社会科学探究。

最后，为了确保理论思考的深度、方法选择的严谨性与实践操作的可行性三者之间的有机统一，本书在整体结构规划以及每一个主要部分（尤其是第二部分中以任务驱动组织的各章节）的内部叙事逻辑上，都力求清晰地展现并遵循一个贯穿始终的核心链条：认识论 (Epistemology) → 方法论 (Methodology) → 操作化 (Operationalization)。这个 **E-M-O 结构** 构成了本书方法论阐释的内在骨架，旨在引导读者在学习每一个核心概念或方法时，都能经历一个从探究“为何如此” (Why — 知识基础、目标设定、哲学预设、伦理意涵)、到理解“如何思考” (How to think — 核心原理、逻辑推演、关键假设、适用条件、评估标准)、再到掌握“如何操作” (How to do — 具体步骤、实现工具、代码示例、结果解读、常见陷阱) 的完整认知与实践循环。


具体来说，在认识论层面，我们将审视与特定任务或核心方法相关的基本知识假设、目标界定、价值取向及其局限性。例如，预测任务下的预测与解释的关系，因果推断任务下的反事实逻辑与识别假设，文本分析中的语言理解挑战，LLM 的能力边界与风险，网络分析中的结构观，模拟研究中的生成性理解，以及数据融合中的整体性追求与潜在偏差。

这一层面的探讨旨在培养读者对计算社会科学知识生产过程本身进行反思性批判的能力。在方法论层面，我们将聚焦于支撑特定任务的核心方法的内在原理、逻辑演绎和适用条件，这是连接理论思考与技术实践的关键桥梁。我们将深入讲解各类算法的核心机制、关键假设、评估指标以及选择标准，使读者不仅知其然，更能知其所以然，从而能够灵活运用和审慎评估方法。在操作化层面，我们将提供具体的实践指引，辅以代码示例（主要基于 Python 生态）、工具介绍和案例演示，帮助读者将抽象的方法论知识转化为可执行的操

作技能，涵盖数据处理、模型实现、结果解读、可视化呈现以及实践中常见问题的应对策略，确保读者具备将所学应用于研究或工作的实际能力。**值得注意的是，不同于其他的方法教学书籍，在生成式人工智能的时代背景下，本书的重点将放在认识论与方法论之上，而非具体的操作化。**我相信，顺应时代发展的编排将会给读者一些不同的体验。

通过系统地坚持这一从认识论到方法论再到操作化的 E-M-O 逻辑链条，并将其无缝融入基础奠定、任务驱动和问题导向的整体结构之中，本书期望能够超越传统教材可能存在的理论与实践、方法介绍与问题应用相互割裂的局限，为读者营造一个既富理论深度、又具方法广度，同时还兼备实践指导意义的沉浸式、综合性学习体验。**我们期盼，读者在完成本书的学习旅程之后，不仅能娴熟掌握计算社会科学的一系列“术”，更能深刻领悟其背后的“道”，形成一种整合性的学术视野和研究能力，从而真正具备运用“无算之策”去探索、理解并审慎介入我们所处的日益复杂的社会世界的巨大潜力。**

参考文献



白朔天, 郝碧波, 李昂, 等, 2014. 微博用户的抑郁和焦虑预测[J]. 中国科学院大学学报, 31(6): 814-820.

陈云松, 吴晓刚, 胡安宁, 等, 2020. 社会预测: 基于机器学习的研究新范式[J]. 社会学研究, 35(3): 94-117, 244.

范如国, 2018. 公共管理研究基于大数据与社会计算的方法论革命[J]. 中国社会科学(9): 74-91+205.

高见, 周涛, 2016. 大数据揭示经济发展状况[J]. 电子科技大学学报, 45(4): 625-633.

韩军徽, 2020. 计算社会科学中“守旧”与“维新”的方法论探讨[J]. 理论探索(4): 11-17.

黄萃, 杨超, 2020. “计算社会科学”与“社会计算”概念辨析与研究热点比较分析[J]. 信息资源管理学报, 10(6): 4-19.

酆全民, 2019. 计算社会科学的哲学透视[J]. 河北学刊, 39(5): 98-104.

凌昀, 李伦, 2020. 计算社会科学研究: 范式转换与伦理问题[J]. 江汉论坛(9): 26-31.

吕鹏, 2024. 计算社会科学: 学科体系与领域演进[J]. 求索(4): 84-94.

孟小峰, 张祎, 2019. 计算社会科学促进社会科学研究转型[J]. 社会科学(7): 3-10.

苏毓淞, 刘江锐, 2021. 计算社会科学与研究范式之争: 理论的终结?[J]. 复旦学报(社会科学版), 63(2): 189-196.

俞立平, 冉嘉睿, 罗宇舟, 等, 2023. 计算社会科学发展演变及学科框架与学科结构[J]. 重庆大学学报(社会科学版), 29(2): 124-139.

汪静莹, 甘硕秋, 赵楠, 等, 2016. 基于微博用户的情绪变化分析[J]. 中国科学院大学学报, 33(6): 815-824.

王芳, 王宣艺, 陈硕, 2020. 经济学研究中的机器学习: 回顾与展望[J]. 数量经济技术经济研究, 37(4): 146-164.

周涛, 高馨, 罗家德, 2022. 社会计算驱动的社会科学研究方法[J]. 社会学研究, 37(5): 130-155, 228-229.

Anon, 1978. Centrality in social networks conceptual clarification[J]. *Social Networks*, 1(3): 215-239.

Anon, 2011. Twitter mood predicts the stock market[J]. *Journal of Computational Science*, 2(1): 1-8.

Anon, 2021. Benthic fauna contribute to microplastic sequestration in coastal sediments[J]. *Journal of Hazardous Materials*, 415: 125583.

Abadie A, 2021. Using Synthetic Controls: Feasibility, Data Requirements, and Methodological Aspects[J]. *Journal of Economic Literature*, 59(2): 391-425.

Angrist J D, Pischke J S, 2009. *Mostly Harmless Econometrics: An Empiricist's Companion*[M]. Princeton University Press.

Anselin L, 1995. Local Indicators of Spatial Association—LISA[J]. *Geographical Analysis*, 27(2): 93-115.

Armburst M, View Profile, Fox A, et al., 2010. A view of cloud computing[J]. *Communications of the ACM*, 53(4): 50-58.

Aronow P M, Samii C, 2017. Estimating average causal effects under general interference, with application to a social network experiment[J]. *The Annals of Applied Statistics*, 11(4): 1912-1947.

Athey S, Imbens G, 2016. Recursive partitioning for heterogeneous causal effects[J]. *Proceedings of the National Academy of Sciences*, 113(27): 7353-7360.

Athey S, Imbens G W, 2017. *The State of Applied Econometrics: Causality and Policy Evaluation*[J]. *Journal of Economic Perspectives*, 31(2): 3-32.

Axelrod R, 1997. The Dissemination of Culture: A Model with Local Convergence and Global Polarization[J]. *The Journal of Conflict Resolution*, 41(2): 203-226.

Barabási A L, Albert R, 1999. Emergence of Scaling in Random Networks[J]. *Science*.

Barabási A L, Pósfai M, 2016. *Network Science*[M]. 1st edition. Cambridge, United Kingdom: Cambridge University Press.

Barocas S, Hardt M, Narayanan A, 2018. Fairness and machine learning limitations and opportunities[C].

Barocas S, Hardt M, Narayanan A, 2023. *Fairness and Machine Learning: Limitations and Opportunities*[M]. Cambridge, Massachusetts: The MIT Press.

Beauchamp N, 2017. Predicting and Interpolating State-Level Polls Using Twitter Textual Data[J]. *American Journal of Political Science*, 61(2): 490-503.

Belloni A, Chernozhukov V, Hansen C, 2014. High-Dimensional Methods and Inference on Structural and Treatment Effects[J]. *Journal of Economic Perspectives*, 28(2): 29-50.

Blumenstock J, Cadamuro G, On R, 2015. Predicting poverty and wealth from mobile phone metadata[J]. *Science*.

Bond R M, Fariss C J, Jones J J, et al., 2012. A 61-million-person experiment in social influence and political mobilization[J]. *Nature*, 489(7415): 295-298.

Borgatti S P, Mehra A, Brass D J, et al., 2009. Network Analysis in the Social Sciences[J]. *Science*.

Boyd D, Crawford K, 2012. Critical questions for big data: Provocations for a cultural, technological, and scholarly phenomenon[J]. *Information, Communication & Society*, 15(5): 662-679.

Braghieri L, Levy R, Makarin A, 2022. Social Media and Mental Health[J]. *American Economic Review*, 112(11): 3660-3693.

Castells M, 2000. Toward a Sociology of the Network Society[J]. *Contemporary Sociology*, 29(5): 693-699.

Centola D, 2010. The Spread of Behavior in an Online Social Network Experiment[J]. *Science*.

Centola D, Macy M, 2007. Complex Contagions and the Weakness of Long Ties[J]. *American Journal of Sociology*, 113(3): 702-734.

Chadefaux T, 2014. Early warning signals for war in the news[J]. *Journal of Peace Research*.

Chernozhukov V, Chetverikov D, Demirer M, et al., 2018. Double/debiased machine learning for treatment and structural parameters[J]. *The Econometrics Journal*, 21(1): C1-C68.

Choudhury M D, De S, 2014. Mental Health Discourse on reddit: Self-Disclosure, Social Support, and Anonymity[J]. *Proceedings of the International AAAI Conference on Web and Social Media*, 8(1): 71-80.

Cioffi-Revilla C, 2017. *Introduction to Computational Social Science: Principles and Applications*[M]. 2nd ed. 2017 edition. New York, NY: Springer.

Cioffi-Revilla C, 2017. *Computation and Social Science*[M]//Cioffi-

Revilla C. Introduction to Computational Social Science: Principles and Applications. Cham: Springer International Publishing: 35-102.

Conte G L, Arnegard M E, Peichel C L, et al., 2012. The probability of genetic parallelism and convergence in natural populations[J]. Proceedings of the Royal Society B: Biological Sciences, 279(1749): 5039-5047.

Conte R, Gilbert N, Bonelli G, et al., 2012. Manifesto of computational social science[J]. The European Physical Journal Special Topics, 214(1): 325-346.

Davis J M V, Heller S B, 2017. Using Causal Forests to Predict Treatment Heterogeneity: An Application to Summer Jobs[J]. American Economic Review, 107(5): 546-550.

Deaton A, Cartwright N, 2018. Understanding and misunderstanding randomized controlled trials[J]. Social Science & Medicine (1982), 210: 2-21.

Edelmann A, Wolff T, Montagne D, et al., 2020. Computational Social Science and Sociology[J]. Annual Review of Sociology, 46(1): 61-81.

Epstein J M, Axtell R, 1996. Growing artificial societies: Social science from the bottom up[M]. Cambridge, MA, US: The MIT Press: xv, 208.

Fagiolo G, Moneta A, Windrum P, 2007. A Critical Guide to Empirical Validation of Agent-Based Models in Economics: Methodologies, Procedures, and Open Problems[J]. Computational Economics, 30(3): 195-226.

Fararo T J, 1989. The Meaning of General Theoretical Sociology: Tradition and Formalization[M]. Cambridge ; New York: Cambridge University Press.

FerraraEmilio, VarolOnur, DavisClayton, et al., 2016. The rise of social bots[J]. Communications of the ACM.

Fisher R A, 1935. The design of experiments[M]. Oxford, England: Oliver & Boyd: xi, 251.

Foster I, Ghani R, Jarmin R S, et al., 2016. Big Data and Social Science: A Practical Guide to Methods and Tools[M]. 1st edition. Boca Raton, FL: Chapman and Hall/CRC.

Gilbert N, 2008. Researching social life[M]//Researching social life. Sage Publications Ltd.

Ginsberg J, Mohebbi M H, Patel R S, et al., 2009. Detecting influenza epidemics using search engine query data[J]. Nature, 457(7232): 1012-1014.

Glaeser E L, Sacerdote B, Scheinkman J, 1996. Crime and Social Interactions[J]. The Quarterly Journal of Economics, 111(2): 507-548.

González-Bailón S, Borge-Holthoefer J, Rivero A, et al., 2011. The Dynamics of Protest Recruitment through an Online Network[J]. Scientific Reports, 1(1): 197.

Goodchild M F, 2007. Citizens as sensors: the world of volunteered geography[J]. GeoJournal, 69(4): 211-221.

Granovetter M S, 1973. The Strength of Weak Ties[J]. American Journal of Sociology, 78(6): 1360-1380.

Grimmer J, Roberts M E, Stewart B M, 2021. Machine Learning for Social Science: An Agnostic Approach[J]. *Annual Review of Political Science*, 24(Volume 24, 2021): 395-419.

Grimmer J, Stewart B M, 2013. Text as Data: The Promise and Pitfalls of Automatic Content Analysis Methods for Political Texts[J]. *Political Analysis*, 21(3): 267-297.

Groves R M, Jr F J F, Couper M P, et al., 2009. *Survey Methodology*[M]. 2nd edition. Somerset: Wiley.

Hastie T, Tibshirani R, Friedman J, 2009. Overview of Supervised Learning[M]//Hastie T, Tibshirani R, Friedman J. *The Elements of Statistical Learning: Data Mining, Inference, and Prediction*. New York, NY: Springer: 9-41.

Hilbert M, 2016. Big Data for Development: A Review of Promises and Challenges[J]. *Development Policy Review*, 34(1): 135-174.

Hofman J M, Watts D J, Athey S, et al., 2021. Integrating explanation and prediction in computational social science[J]. *Nature*, 595(7866): 181-188.

Holland J H, 1996. *Hidden Order: How Adaptation Builds Complexity*[M]. Cambridge, Mass.: Basic Books.

Howison J, Wiggins A, Crowston K, 2011. Validity Issues in the Use of Social Network Analysis with Digital Trace Data[J]. *Journal of the Association for Information Systems*, 12(12).

IMAI K, KEELE L, TINGLEY D, et al., 2011. Unpacking the Black Box of Causality: Learning about Causal Mechanisms from Experimental and Observational Studies[J]. *American Political Science Review*, 105(4): 765-789.

J. A. V. Dijk, 2005. *The Deepening Divide: Inequality in the Information Society*[M]. 2455 Teller Road, Thousand Oaks California 91320 United States: SAGE Publications, Inc.

Jean N, Burke M, Xie M, et al., 2016. Combining satellite imagery and machine learning to predict poverty[J]. *Science*.

Jurafsky D, Martin J H, 2025. *Speech and language processing: An introduction to natural language processing, computational linguistics, and speech recognition with language models*[M]. 3rd version.

Kitchin R, 2014. Big Data, new epistemologies and paradigm shifts[J]. *Big Data & Society*, 1(1): 2053951714528481.

Kohavi R, Tang D, Xu Y, 2020. *Trustworthy Online Controlled Experiments: A Practical Guide to A/B Testing*[M].

Kramer A D I, Guillory J E, Hancock J T, 2014. Experimental evidence of massive-scale emotional contagion through social networks[J]. *Proceedings of the National Academy of Sciences of the United States of America*, 111(24): 8788-8790.

L. Manzo, P. Devine -Wright, 2020. *Place Attachment : Advances in Theory, Methods and Applications*[M]. Routledge.

Lazer D, Kennedy R, King G, et al., 2014. Big data. The parable of Google Flu: traps in big data analysis[J]. *Science (New York, N.Y.)*, 343(6176): 1203-1205.

Lazer D, Pentland A, Adamic L, et al., 2009. *Computational Social*

Science[J]. *Science*, 323(5915): 721-723.

LeCun Y, Bengio Y, Hinton G, 2015. Deep learning[J]. *Nature*, 521(7553): 436-444.

Liu D M, Salganik M J, 2019. Successes and Struggles with Computational Reproducibility: Lessons from the Fragile Families Challenge[J]. *Socius*, 5: 2378023119849803.

Lux T, Marchesi M, 1999. Scaling and criticality in a stochastic multi-agent model of a financial market[J]. *Nature*, 397(6719): 498-500.

M. Newman, 2018. *Network search*[M]. Oxford University Press.

Macy M W, Willer R, 2002. From Factors to Actors: Computational Sociology and Agent-Based Modeling[J]. *Annual Review of Sociology*, 28(Volume 28, 2002): 143-166.

Manzo L, Devine-Wright P, 2013. *Place Attachment: Advances in Theory, Methods and Applications*[M]. London: Routledge.

Mayer-Schönberger V, Cukier K, 2013. *Big data: A revolution that will transform how we live, work, and think*[M]. Boston, MA: Houghton Mifflin Harcourt: 242.

Miller J H, Page S E, 2007. *Complex adaptive systems: An introduction to computational models of social life*[M]. Princeton, NJ, US: Princeton University Press: xix, 263.

Mitchell J M, Bogenschutz M, Lilienstein A, et al., 2021. MDMA-assisted therapy for severe PTSD: a randomized, double-blind, placebo-controlled phase 3 study[J]. *Nature Medicine*, 27(6): 1025-1033.

Mitchell M, 2011. *Complexity: A Guided Tour*[M]. 1st edition. New York, NY: Oxford University Press.

Mitchell R K, Agle B R, Chrisman J J, et al., 2011. Toward a Theory of Stakeholder Salience in Family Firms[J]. *Business Ethics Quarterly*, 21(2): 235-255.

Molina M, Garip F, 2019. *Machine Learning for Sociology*[A]. Rochester, NY: Social Science Research Network.

Molnar C, 2022. *Interpretable Machine Learning: A Guide For Making Black Box Models Explainable*[M]. Munich, Germany: Independently published.

Moreno J L, 1934. *Who shall survive?: A new approach to the problem of human interrelations*[M]. Washington, DC, US: Nervous and Mental Disease Publishing Co: xvi, 441.

Mullainathan S, Spiess J, 2017. Machine Learning: An Applied Econometric Approach[J]. *Journal of Economic Perspectives*, 31(2): 87-106.

Murphy K P, 2022. *Probabilistic Machine Learning: An Introduction*[M]. Cambridge, Massachusetts London, England: The MIT Press.

Neal B, 2020. *Introduction to Causal Inference*[J]. Course Lecture Notes (draft), 132.

Newman M E J, Girvan M, 2004. Finding and evaluating community structure in networks[J]. *Physical Review E*, 69(2): 026113.

Oliver N, Lepri B, Sterly H, et al., 2020. Mobile phone data for informing public health actions across the COVID-19 pandemic life cycle[J]. *Science Advances*.

Urban A, Przybylski A K, 2019. The association between adolescent well-being and digital technology use[J]. *Nature Human Behaviour*, 3(2): 173-182.

Orcutt G H, 1957. A New Type of Socio-Economic System[J]. *The Review of Economics and Statistics*, 39(2): 116-123.

Pang B, Lee L, 2008. Opinion mining and sentiment analysis[M].

Pearl J, 2009. *Causality: Models, Reasoning and Inference*[M]. 2nd edition. Cambridge, U.K. ; New York: Cambridge University Press.

Perry G, 2013. Behind the shock machine: The untold story of the notorious Milgram psychology experiments[M]. New York, NY, US: New Press: x, 340.

Preis T, Moat H S, Stanley H E, 2013. Quantifying Trading Behavior in Financial Markets Using Google Trends[J]. *Scientific Reports*, 3(1): 1684.

Provost F, Fawcett T, 2013. Data Science and its Relationship to Big Data and Data-Driven Decision Making[J]. *Big Data*, 1(1): 51-59.

Radicchi F, Fortunato S, Markines B, et al., 2009. Diffusion of scientific credits and the ranking of scientists[J]. *Physical Review E*, 80(5): 056103.

Rubin D B, 1974. Estimating causal effects of treatments in randomized and nonrandomized studies[J]. *Journal of Educational Psychology*, 66(5): 688-701.

Rudin C, 2019. Stop explaining black box machine learning models for high stakes decisions and use interpretable models instead[J]. *Nature Machine Intelligence*, 1(5): 206-215.

Salganik M J, 2017. *Bit by Bit: Social Research in the Digital Age*[M]. Illustrated edition. Princeton Oxford: Princeton University Press.

Savage M, Burrows R, 2007. The Coming Crisis of Empirical Sociology[J]. *Sociology*, 41(5): 885-899.

Sawyer R K, 2005. *Social Emergence*[M]. Cambridge University Press.

Schelling T H, 1971. Dynamic models of segregation[J]. *Journal of Mathematical Sociology*.

Shalizi C R, Thomas A C, 2011. Homophily and contagion are generically confounded in observational social network studies[J]. *Sociological Methods & Research*, 40(2): 211-239.

Shelton T, Zook M, Wiig A, 2015. The "Actually Existing Smart City"[A]. Rochester, NY: Social Science Research Network.

Shmueli G, 2010. To Explain or to Predict?[J]. *Statistical Science*, 25(3): 289-310.

Simon H A, 1955. A Behavioral Model of Rational Choice[J]. *The Quarterly Journal of Economics*, 69(1): 99-118.

Simon H A, 1996. *The Sciences of the Artificial - 3rd Edition*[M]. 3rd edition. Cambridge, Mass.: MIT Press.

Tesfatsion L, Judd K L, 2006. *Handbook of Computational Economics, Volume 2: Agent-Based Computational Economics*[M]. Amsterdam, The Netherlands: Elsevier.

Tufekci Z, 2014. Social Movements and Governments in the Digital Age: Evaluating a Complex Landscape[J]. *Journal of International Affairs*, 20(1): 1-10.

Q1: 为何要做这一系列?

00(1). 1-10.

Ugander J, Backstrom L, Marlow C, et al., 2012. Structural diversity in social contagion[J]. Proceedings of the National Academy of Sciences, 109(16): 5962-5966.

Uzzi B, Mukherjee S, Stringer M, et al., 2013. Atypical Combinations and Scientific Impact[J]. Science.

Vosoughi S, Roy D, Aral S, 2018. The spread of true and false news online[J]. Science.

Wager S, Athey S, 2018. Estimation and Inference of Heterogeneous Treatment Effects using Random Forests[J]. Journal of the American Statistical Association.

Wasserman S, Faust K, 1994. Social network analysis: Methods and applications[M]. New York, NY, US: Cambridge University Press: xxxi, 825.

Watts D J, Strogatz S H, 1998. Collective dynamics of 'small-world' networks[J]. Nature, 393(6684): 440-442.

Watts S, 2014. User Skills for Qualitative Analysis: Perspective, Interpretation and the Delivery of Impact[J]. Qualitative Research in Psychology, 11(1): 1-14.

Zimmer M, 2010. "But the data is already public": on the ethics of research in Facebook[J]. Ethics and Information Technology, 12(4): 313-325.

教授的《Introduction to Computational Social Science: Principles and Applications》等。这些著作体系严谨、逻辑清晰、内容翔实，堪称典范。然而，纸质书籍在传播广度、灵活性与内容更新（例如，整合LLM赋能的新方法）方面难免存在局限。

同时，在互联网环境中，碎片化传播使得网络资源往往难以兼顾方法理论的深度阐释、手把手的操作指导以及基础知识的系统梳理，形成所谓的“不可能三角”。这并非创作者学识不周，实乃平台篇幅与流量导向所限，导致国内互联网缺乏孕育系统化、结构化开源知识的理想土壤。而我为何仍愿为此努力？这便引出了我对学科发展的一些思考。

谈及学科定位，借鉴国内多位学者近年来在《社会学研究》等期刊的论述，我深以为计算社会科学的内涵不应局限于复杂科学、网络科学与仿真建模等特定领域。它更应与社会学理论、计量经济学等传统社会科学分支深度融合。唯有如此，方能降低广大研究者的学习门槛，推动“计算社会科学”（以“计算”为方法，“社会科学”为旨归）跳出“小圈子”，迈向更广阔的融通发展之路。其次，在生成式人工智能时代，我更坚信，引导读者理解如何进行研究设计与方法“操作化”远比传授具体软件操作更为关键。此外，也有些个人“私心”：为避免荒废先前学习计量经济学的积累，我决定将两方面内容整合，一并梳理呈现。


综上所述，本系列的核心优势在于：不受篇幅所限，力求将相关知识点尽可能全面、深入地呈现，以满足偏好系统性、逻辑性学习的读者需求。这或许是碎片化时代下，一种“不合

时宜”的便利。内容初步计划以GitBook结合Jupyter Notebook等交互形式部署于网页，同时提供PDF版本。

Q2：能否预览一下后面的方法内容都是什么样的结构？

没问题，之后的方法内容基本上还是遵循 E-M-O 框架进行阐述，力争打破篇幅限制，把每一种方法都讲清楚。下面以社会网络分析法（SNA）为例，给各位读者看一看大致的大纲（只是大纲而已，后面还需重构，并且按照任务分离）。


方法源流



- +-- 早期社会理论：结构视角（19世纪末-20世纪初）
 - | |-- 代表人物：G. Simmel, E. Durkheim, M. Weber
 - | +-- 核心问题：如何超越个体属性，从关系模式概念化和分析社会结构及其对个体行为的影响？
- +-- 社会计量学（Sociometry）（20世纪30年代）
 - | |-- 代表人物：J. Moreno, H. Jennings (1934, *Who Shall Survive?*)
 - | |-- 解决问题：
 - | | |-- 如何系统测量和可视化人际关系与群体结构？(e.g., Sociogram 社会关系图)
 - | | +-- 如何将个体心理状态（如选择、吸引、排斥）与其所处的社会结构相关联？
- +-- 方法发展相对沉寂期（"Dark Age"）（约20世纪40年代-60年代）
 - | +-- 面临挑战：
 - | |-- 缺乏处理复杂关系数据的有效数学工具和理论框架。
 - | +-- 计算能力限制了对大规模网络的分析。
- +-- 现代社会网络分析兴起与发展（20世纪60/70年代至今）
 - | |-- 驱动力：数学（图论、矩阵代数）与计算科学发展，社会科学内部对结构解释的需求。
 - | |-- 核心目标：系统化地分析复杂的关系模式，并解释这些模式如何产生及带来何种后果。
 - | |-- 主要分支/贡献：
 - +-- 数学形式化：
 - | |-- 引入图论（Graph Theory）和矩阵代数（Matrix Algebra）
 - | +-- 解决问题：为网络结构提供精确的形式化表达、量化测量和数学运算基础。
 - +-- 关键概念发展：
 - | |-- 结构对等（Structural Equivalence）与块模型（Blockmodeling）(H. White et al., 1970s)
 - | | +-- 解决问题：如何识别网络中功能/角色相似的行动者群体或位置？
 - | |-- 中心性（Centrality）概念深化（L. Freeman, P. Bonacich et al., 1970s+）
 - | | +-- 解决问题：如何量化节点在网络结构中的重要性、影响力或资源控制能力？
 - | |-- 弱连接强度（Strength of Weak Ties）(M. Granovetter, 1973)
 - | | +-- 解决问题：解释非冗余信息传播、社会流动、创新扩散中“桥接性”弱关系的关键作用。
 - | |-- 结构洞（Structural Holes）(R. Burt, 1992)
 - | | +-- 解决问题：解释占据网络“空隙”位置（中介者）所带来的信息和控制优势。
 - +-- 网络推断模型：
 - | |-- 指数随机图模型（ERGM / p^* ）(Holland & Leinhardt, Wasserman, Pattison, Robins, Snijders, Hunter et al.)
 - | | +-- 解决问题：如何基于网络微观结构（如边、星、三角）的出现概率来统计建模网络宏观结构，并检验结构形成机制？克服关系数据非独立性问题。
 - | |-- 随机行动者导向模型（SAOM）(T.A.B. Snijders et al.)
 - | | +-- 解决问题：如何建模行动者基于自身目标和网络环境进行关系选择，从而解释网络随时间的动态演化？
 - | |-- 时间性指数随机图模型（TERGM）(Hanneke, Fu, Xing, Robins, Lusher, Koskinen et al.)
 - | | +-- 解决问题：如何在ERGM框架下显式地处理网络面板数据，分析网络结构的时间依赖性和演化机制？
 - +-- 网络因果推断（21世纪初至今）
 - | |-- 驱动：对识别网络真实影响（区分选择与影响）的需求增强。

+- - 解决问题：如何运用实验设计（RCTs）、准实验或改进的观测数据方法（如结合潜在结果框架）来估计网络干预或网络位置的因果效应？

方法重要学者（节点）



- +-- 奠基与早期发展
 - | +-- J. Moreno (1934) - 社会计量学创始人, Sociogram
 - | +-- H. Jennings (1934) - 社会计量学合作者
 - | +-- 早期人类学家 (e.g., Radcliffe-Brown, Barnes) - 应用网络思想于亲属、社区研究
- +-- 哈佛大学学派 (Harvard University) - 现代SNA重镇
 - | +-- H. White - 结构对等, Blockmodeling, 关键推动者
 - | | +-- P. Bearman
 - | | +-- R. Breiger
 - | | +-- M. Granovetter (1973) - 弱连接强度
 - | +-- G. Homans - 影响早期网络思想
 - | +-- P. Bonacich - 中心性度量
 - | +-- B. Wellman - 社区网络
 - | +-- C. Fischer - 个人网络
- +-- 密歇根大学学派 (University of Michigan - UMich) - 侧重政策过程、社会分层
 - | +-- E. Laumann
 - | +-- D. Knoke
 - | +-- P. Marsden
 - | +-- R. Burt - (1992, 结构洞理论)
 - | +-- J. Galaskiewicz
- +-- 加州大学尔湾分校学派 (University of California, Irvine - UCI) - 网络研究中心
 - | +-- L. Freeman - 中心性概念整合与软件 (UCINET早期)
 - | +-- H. White
 - | +-- R. Burt
 - | +-- S. Wasserman - (与Faust 合著 *Social Network Analysis*, 1994)
 - | +-- K. Faust
 - | +-- S. Borgatti - UCINET软件主要开发者
 - | +-- P. Doreian
 - | +-- M. Everett
 - | +-- T.A.B. Snijders - SAOM模型
- +-- 模型开发者
 - | +-- P. Holland & S. Leinhardt - p* (ERGM前身) 模型
 - | +-- T.A.B. Snijders - SAOM (RSiena软件)
 - | +-- `statnet` 开发团队 (UW, Penn State, Oxford, UMass et al.) - ERGM, TERGM (核心成员如 M. Morris, M. Handcock, D. Hunter, C. Butts, S. Goodreau, J. Moody)
- +-- 重要理论贡献者
 - | +-- J. Coleman (1988) - 社会资本, 科尔曼之舟 (理论连接)
 - | +-- P. Bourdieu & J.C. Passeron (1970) - 再生产理论 (结构视角关联)
 - | +-- P. Hedström & R. Swedberg (1998) - 社会机制方法论 (理论连接)
 - | +-- 赵鼎新 (2020) - 结构/机制叙事与时间/事件叙事 (认识论框架)
- +-- 代表性应用研究者
 - +-- K. Ingold & P. Leifeld (2016) - ERGM/TERGM应用于政策网络影响力分析
 - +-- L. Beaman, A. BenYishay, J. Magruder & A. M. Mobarak (2021) - 网络RCT用于技术扩散研究
 - +-- F. Shi et al. (2017) - 共同购书网络揭示政治极化
 - +-- G. Xu et al. (2020) - 多层网络刻画创新生态系统

方法的认识论介绍

- **社会科学的核心解释模式：**
 - 事件/时间叙事：侧重具体事件、行动者动机、转折点和时序过程（如新闻报道，个体经历故事）。
 - 结构/机制叙事 (Zhao, 2020)：侧重解释现象背后稳定存在的模式、关系、规则或因因果机制（如阶级、社区、制度、社会网络）。SNA主要服务于后者。
- **SNA的本体论预设：关系主义 (Relationalism)**
 - 社会现实由行动者之间的关系构成，而非仅仅由孤立的个体及其属性构成。
 - 行动者的行为、态度、机会和结果在很大程度上受其所嵌入的关系网络结构的影响。
- **“结构化”思维：SNA的核心视角**
 - 强调社会现象（如权力分配、信息流动、社会支持、集体行动、市场形成）的根源在于行动者之间形成的连接模式（结构）。
 - 区分社会科学与理工科对SNA的不同侧重：
 - 社会科学关注结构如何促成社会经济现象
 - 理工科更关注网络自身的数学属性、算法效率和工程应用（如交通优化、推荐系统）。
- **连接微观与宏观：科尔曼之舟 (Coleman's Boat)**
 - 网络结构被视为关键的“中层”机制，能够解释宏观层面的模式（如社会规范、组织绩效）如何通过微观层面的互动（个体间的连接与影响）产生和维持。(Coleman, 1988; Hedström & Swedberg, 1998)
 - SNA提供了分析这种跨层次影响（Macro-to-Micro, Micro-to-Micro, Micro-to-Macro）的工具。

方法的具体原理

- **基本构成要素与术语：**
 - **实体：**节点 (Nodes / Vertices / Actors / Individuals / Members) - 网络中的基本单位（人、组织、国家、词语等）。

- **连接：** 边 (Edges / Ties / Links / Relations / Lines) - 节点间的关系（朋友、合作、交易、引用、共同出现等）。
- **网络类型属性：**
 - **方向性：** 有向 (Directed, e.g., 建议、借贷) vs. 无向 (Undirected, e.g., 朋友、共同参会)。
 - **权重性：** 加权 (Weighted, e.g., 关系强度、交易额、互动频率) vs. 无权/二元 (Unweighted/Binary, e.g., 是否认识)。
 - **节点类型：** 单模图 (Unimodal, 节点类型相同) vs. 二模图 (Bimodal/Bipartite, 包含两类节点及它们之间的连接, e.g., 作者-论文, 成员-事件)。
- **网络数据表示：**
 - 邻接矩阵 (Adjacency Matrix): $N \times N$ 矩阵, $A[i, j]$ 表示节点*i*到节点*j*的关系（或其权重）。适用于稠密网络和数学运算。
 - 边列表 (Edge List): 两列（或三列，含权重）列表，每行表示一条边。适用于稀疏网络和存储。
 - 关联矩阵 (Incidence Matrix): $N \times M$ 矩阵，用于表示节点与事件/群体的关联（常见于二模图）。
- **网络描述性分析 (Network Description)：呈现异质性**
 - **基础概念：**
 - **游走 (Walk):** 顶点和边可重复的顶点序列。
 - **路径 (Path):** 顶点和边均不重复的游走（最短路径）。
 - **距离 (Distance):** 两节点间最短路径的长度。
 - **连通性 (Connectivity):** 网络中节点间可达的程度（连通图, 强/弱连通分量）。
 - **网络密度 (Network Density):** 实际存在的边数占可能最大边数的比例，衡量网络的整体紧密程度。
 - **同质性 (Homophily):** “物以类聚”，具有相似属性的节点倾向于连接的现象。
 - **节点层面测量 (Node-level Measures):**
 - **中心性 (Centrality):**
 - 度中心性 (Degree Centrality): 连接的节点数 (入度/出度)。衡量节点的直接活跃度/受欢迎度。
 - 接近中心性 (Closeness Centrality): 到所有其他节点平均距离的倒数。衡量节点到达网络中其他节点的效率。

- 中介中心性 (Betweenness Centrality): 经过该节点的最短路径数量占有所有最短路径的比例。衡量节点的“桥梁”或控制信息流动的能力。
 - 特征向量中心性 (Eigenvector Centrality): 节点的中心性取决于其邻居的中心性。衡量节点在网络中的传递性影响力 (连接到重要节点更重要)。(Bonacich Power Centrality是其扩展)。
- **子群层面测量 (Subgroup-level Measures):**
- **凝聚子群 (Cohesive Subgroups):** 网络中内部连接紧密的节点集合。
 - **紧密团体 (Clique):** 子群内所有节点都相互连接 (完全子图)。要求非常严格。
 - **N-核 (N-core):** 移除所有度数小于N的节点后剩余的最大子图, 其中所有节点至少有N个内部连接。衡量网络核心区域的稳健性。
 - **连通分量 (Components):** 无向图中, 内部任意两点都可通过路径连接的最大子图。有向图中对应强/弱连通分量。识别网络的分割情况。
 - **社区发现 (Community Detection):** 识别网络中内部连接密集、外部连接稀疏的节点群组 (社区结构)。
 - **常用算法:**
 - 模块度优化 (Modularity Optimization): 如 Louvain 算法 (高效、常用), Fast Greedy。目标是最大化社区内部边比例与随机期望的差值。
 - 层次聚类 (Hierarchical Clustering): 基于相似性/距离逐步合并或分裂节点/社区。
 - 基于随机游走 (Random Walks): 如 Walktrap, InfoMap。利用随机游走在社区内停留时间长的特性。
 - 谱聚类 (Spectral Clustering): 基于网络拉普拉斯矩阵的特征向量。
- **结构洞与关系强度 (Structural Holes & Tie Strength):**
- **结构洞 (Structural Holes) (Burt, 1992):** 网络中两个 (或多组) 未直接连接的节点/群体之间的“空隙”。
 - **中介者 (Broker):** 占据结构洞位置、连接不同群体/信息的节点。
 - **约束 (Constraint):** Burt 提出的度量指标, 衡量一个节点的投入 (时间和精力) 在多大程度上集中于少数几个连接紧密的邻居。低约束意味着拥有更多结构洞。
 - **弱连接强度 (Strength of Weak Ties) (Granovetter, 1973):**
 - **桥 (Bridge):** 连接两个原本无连接的网络部分的边。

- **核心思想：** 将整个网络视为单一观测，假设网络的出现概率与网络中特定结构模式（如边、星形、三角形、同质性等）的加权和（由参数向量 θ 定义）成指数关系。
 - **概率公式：** $P(Y=y | \theta) = (1/\kappa(\theta)) * \exp(\sum \theta_k * g_k(y))$
 - Y : 观测到的网络邻接矩阵。
 - θ_k : 与第k个网络统计量 $g_k(y)$ 相关的模型参数。
 - $g_k(y)$: 第k个网络统计量（如边的数量、特定类型三元组的数量、基于属性的连接数等），反映了网络结构特征。
 - $\kappa(\theta)$: 归一化常数（所有可能网络的概率之和），计算通常困难。
 - **模型项 (Terms / Statistics):**
 - **结构项 (内生)：** `edges` (密度), `kstar(2/3)` (二/三星结构, 反映度数分布), `triangle` (传递性), `gwesp` (几何加权边共享伙伴, 更复杂的传递性), `mutual` (互惠性) 等。
 - **节点属性效应 (外生)：** `nodefactor('attr')` (节点属性主效应), `nodematch('attr')` (同质性), `nodecov('attr')` (节点协变量效应)。
 - **边属性效应 (外生)：** `edgecov(matrix)` (边协变量)。
 - **估计方法：** MCMC MLE (马尔可夫链蒙特卡洛最大似然估计) 或贝叶斯方法。
 - **优点：** 能够同时建模和检验复杂的内生结构依赖（如传递性、互惠性）和外生协变量的影响。
 - **局限：** 模型设定和收敛性可能存在挑战，通常用于横截面数据。
- **TERGM (Temporal Exponential Random Graph Models):**
- **定位：** ERGM 的动态扩展，用于分析网络面板数据（多个时间点的网络观测）。
 - **核心思想：** 当前时间点 t 的网络结构 Y_t ，不仅取决于 t 时刻的结构模式和属性，还可能依赖于过去的网络状态 Y_{t-1}, Y_{t-2}, \dots 。
 - **模型项扩展：** 引入跨时间的“记忆项”(Memory Terms) 或 动态依赖项。
 - **稳定性/惯性:** 衡量 $t-1$ 时刻存在的边在 t 时刻继续存在的倾向 (e.g., `memory`, `stability`).
 - **形成 (Formation):** 驱动新边形成的因素。
 - **溶解 (Dissolution):** 导致现有边消失的因素。
 - **滞后效应:** 过去的网络结构特征（如节点的度数、中心性）对当前关系形成/维持的影响。

- **估计方法:** 通常使用 STERGM (Separable Temporal ERGM) 框架, 将形成和溶解过程分开建模和估计。
- **SAOM (Stochastic Actor-Oriented Models):**
 - **定位:** 另一种主流的网络动态模型, 侧重于从行动者决策的角度解释网络演化。
 - **核心假设:** 网络变化是离散时间点上, 被选中的行动者基于其“目标函数” (Objective Function) 对其出边进行调整 (增加、删除或维持连接) 的结果。目标函数通常包含网络结构项 (如寻求传递闭包、互惠)、个体属性项 (如同质性偏好) 等。
 - **建模过程:** 模拟在微小时间步 (ministeps) 内, 行动者选择和关系改变的概率。
 - **估计方法:** Method of Moments (MoM), MCMC MLE, Bayesian methods (使用 RSiena 软件包)。
 - **与TERGM的比较:**
 - **理论视角:** SAOM 是行动者中心 (actor-centric), TERGM 是网络/关系中心 (network/tie-centric)。
 - **模型假设:** SAOM 假设行动者有明确的优化目标, TERGM 更侧重于描述结构依赖模式。
 - **应用选择:** 取决于研究问题和理论假设 (Block et al., 2019 认为应基于理论选择; Leifeld & Cranmer, 2019 认为两者经验上相似, 应比较预测性能)。
- **网络中的因果推断 (Causal Inference in Networks):**
 - **核心挑战:**
 - **干扰 (Interference):** 一个个体的处理状态可能影响另一个体的结果 (违反 SUTVA假设)。
 - **溢出效应 (Spillover Effects):** 处理效应可能扩散到控制组。
 - **内生性/混淆:** 如前所述, 选择效应 vs. 影响效应难以分离。
 - **随机试验 (Randomized Experiments / RCTs):**
 - **设计思路:** 在网络环境中进行随机化分配 (如随机选择种子节点、随机分配信息/干预)。
 - **目标:** 估计处理 (如信息、技术) 通过网络扩散的因果效应, 或网络位置本身的因果效应 (较难)。
 - **关键考量:** 随机化单位 (个体、群体、网络), 测量溢出效应, 理解扩散机制 (简单 vs. 复杂传染)。

- **理论基础：** 扩散模型 (Diffusion Models), 如 SIR 模型 (流行病学)、阈值模型 (Threshold Models - Granovetter, 1978; Watts, 2002)。

方法的常用工具

- **数据收集方法与途径：**

- **问卷调查 (Survey Methods):**

- **整体网络 (Whole Network / Sociocentric):** 对一个边界清晰的群体 (如班级、组织、社区) 内所有成员间的关系进行调查。
 - 花名册法 (Roster Method): 提供成员名单让被访者勾选关系。
- **个人中心网络 (Egocentric Network):** 调查个体 (ego) 及其直接联系人 (alters) 以及直接联系人之间的关系。
 - **提名生成法 (Name Generator):** 通过问题 (如“过去半年和谁讨论过重要事情?”) 让个体提名直接联系人。
 - **地位生成法 (Position Generator):** 询问个体是否认识处于特定社会地位/职业的人。
 - **资源生成法 (Resource Generator):** 询问个体能否通过其网络获取特定资源 (如信息、帮助)。
- **特殊策略:**
 - **位置式 (Positional Approach):** 关注占据特定正式位置的行动者及其关系。
 - **声誉式 (Reputational Approach):** 通过询问“谁最有影响力/最关键?”来识别核心行动者 (常用于边界模糊的网络, 可结合滚雪球抽样 Snowball Sampling)。

- **档案与观察数据 (Archival & Observational Data):**

- **事件追踪法 (Event-Based Approach):** 通过记录共同参与事件 (如会议、合作项目、抗议活动) 来构建网络。
- **资源流动法 (Resource Flows Approach):** 追踪资源 (信息、资金、物资) 在行动者间的流动记录 (如引用网络、贸易网络、邮件/通信记录)。
- **关系内容分析 (Relational Content Analysis):** 分析沟通内容 (邮件、社交媒体帖子) 来推断关系性质或主题。

- **数字痕迹数据 (Digital Trace Data):**

- 社交媒体互动 (点赞、评论、关注、转发)。
- 共同购买/浏览记录 (e.g., Amazon)。

- 通信记录（邮件、电话 - 需注意隐私和可得性）。
- 合作发表/共同专利申请记录。
- **分析软件与编程库：**
 - **图形用户界面 (GUI) 软件：**
 - **UCINET:** 功能全面，结合 NetDraw 进行可视化。
 - **Pajek:** 处理大规模网络能力强，算法丰富。
 - **Gephi:** 强大的交互式网络可视化和探索工具。
 - **编程语言库 (更灵活、可扩展、可复现)：**
 - **R 语言：**
 - `igraph` : 核心网络数据结构、分析和可视化包。
 - `statnet` 套件: 包含 `network` (基础数据结构), `sna` (描述性分析), `ergm` (ERGM模型), `tergm` (TERGM模型)。是网络统计建模的标准。
 - `RSiena` : 用于 SAOM 模型估计。
 - **Python 语言：**
 - `NetworkX` : 最常用的网络分析库，提供数据结构、算法和基本绘图。
 - `igraph` (Python接口): 功能与 R 版本类似。
 - `graph-tool` : 注重性能，基于 C++ 实现。
 - `Pyvis` : 用于交互式网络可视化。

论文复现 (python)

略。

Q3: 这个系列主要涉及的是 LLM 在社科中的使用吗?

虽说其中四大任务会穿插很多 LLM 使用的内容，但主要的落脚点还是在适应传统研究方法上。LLM 内容不会喧宾夺主。至于社会模拟的系统与框架，我只能尽力做一些类似系统综述 (systematic review) 的内容，放在模拟任务的部分，供读者参阅；当然同时也会与其他部分一样，有相关论文复现的代码。一旦涉及计科(Computer Science)，尤其是 CHI(ACM

Conference on Human Factors in Computing Systems) 与 CSCW(ACM Conference on Computer Supported Cooperative Work and Social Computing) 这些人机交互领域的会议，论文实在太多，技术路径无比繁杂，甚至在本体论与认识论角度都难以达成一致。让部分举全院之力的顶尖高校社科院系，其他高校的复杂科学相关院系当领头羊，静待往后的发展吧。

欢迎各位读者在评论区提问！ 共同交流共同进步！

第一部分——计算社 会科学研究方法基础

第一章——认识论基础：计算社会科学的研究思维范式

- └—— 认识论基础：计算社会科学的研究思维范式
 - └—— 问题思维：计算社会科学探究的源起与罗盘
 - └—— 社会科学问题的本体论与认识论基础
 - | └—— 问题的本体论地位
 - | └—— 认识论立场与问题观
 - | └—— 问题的“给定性”与“选择性”
 - └—— 研究问题的界定、分类学与评价准则
 - | └—— 科学研究问题的本质特征
 - | └—— 研究问题的基本类型学
 - | └—— 研究问题的认识论评价准则
 - └—— 理论与问题的内在纠缠：互构与驱动机制
 - | └—— 理论作为问题的“母体”和源泉
 - | └—— 问题作为理论发展的“引擎”和催化剂
 - | └—— 理论与问题的循环与迭代关系
 - └—— 计算范式对问题思维的认识论重塑
 - └—— 计算、理论、问题：一个动态的认识论三角
 - | └—— 计算作为理论检验、精炼与发展的平台
 - | └—— 计算作为理论生成与启发的工具
 - | └—— 理论指导计算方法的应用和结果解读
 - | └—— 研究问题的性质塑造计算策略的选择
 - └—— 计算社会科学中问题发现的认识论路径
 - | └—— 路径的介绍
 - | └—— 多路径融合的可能性与研究者自觉

本章将深入探讨计算社会科学（CSS）研究的认识论基石。认识论作为哲学核心分支，关乎知识的来源、本质、范围、确证标准及其可信限度 (Audi, 2015)。在社会科学领域，认识论的探讨尤为关键，因为它直接关联到我们如何理解社会实在、如何界定研究对象、如何选择研究方法以及如何评估知识主张的有效性 (Marsh & Stoker, 2010)。

计算社会科学的兴起，以其独特的数据来源、分析工具和建模能力，不仅带来了方法论上的革新，更在认识论层面提出了深刻的挑战与机遇 (Lazer et al., 2009; Cioffi-Revilla, 2010)。本部分，特别是第一节，旨在为读者奠定坚实的认识论基础，帮助其在面对复杂的社会现象和强大的计算工具时，能够进行批判性、反思性的思考。我们将遵循认识论→方法论→操作化的逻辑顺序，首先聚焦于计算社会科学研究的起点——研究思维范式，涵盖问题思维、数据思维与模型思维。

本节将专门深入剖析“问题思维”，阐明其作为科学探究源起与罗盘的核心作用，从哲学根源、界定标准、与理论的内在联系，到计算范式带来的重塑，系统梳理其认识论维度。

第一节——问题思维: 计算社会科学探究的源起与罗盘

科学研究始于问题 (Popper, 2002)。无论是自然科学还是社会科学, 探究的动力往往源自对未知的好奇、对现有解释的不满、或对特定现象的困惑。问题不仅是研究的起点, 更是指引研究方向、界定研究范围、确立研究目标的关键罗盘。缺乏清晰、有意义的问题意识, 研究活动便容易迷失方向, 沦为数据的堆砌或技术的炫耀 (Mills, 1959)。

在计算社会科学这一新兴交叉领域, 培养深刻、敏锐且符合学科规范的“问题思维”尤为重要。这不仅要求研究者掌握社会科学的理论传统与核心议题, 理解社会现象的复杂性与脉络性, 还需要洞悉计算工具的潜力与局限, 并能在二者之间建立有机的联系。

本节将从认识论的深度, 系统考察社会科学问题的本体论与认识论预设, 探讨问题的界定、分类与评价标准, 分析理论与问题之间复杂而动态的互构关系, 并着重阐述计算范式的引入如何深刻地重塑了我们对社会科学问题的认知、表述和探究方式, 最终勾勒出在计算社会科学中发现和形成有价值研究问题的多元认识论路径。

社会科学问题的本体论与认识论基础

社会科学研究问题的提出, 并非凭空而来, 其背后必然蕴含着研究者关于社会实在 (本体论) 以及如何获得关于社会实在的知识 (认识论) 的基本假定 (Guba & Lincoln, 1994; Blaikie, 2007)。这些深层的哲学预设, 深刻地影响着研究者“看到”什么样的问题、如何界定问题、以及认为哪些问题是“值得”研究的。

首先, **本体论 (Ontology)** 关乎“存在”的本质, 即社会世界的构成要素及其性质。不同的本体论立场对“社会问题”的来源和性质有着截然不同的理解。**实在论 (Realism)**, 特别是科学实在论或结构实在论, 倾向于认为社会世界存在着独立于我们意识之外的客观结构、机制和规律 (Bhaskar, 1979; Archer, 1995)。在此视角下, 社会问题往往被视为这些客观结构失衡、机制失效或规律作用下产生的不良后果。研究者的任务是去“发现”(discover) 这些潜在的、真实的结构与机制, 揭示问题的客观根源。例如, 社会不平等问题可能被视为源于某种客观存在的阶级结构或制度安排。问题的客观性是其研究价值的基础。

与此相对, **建构论 (Constructivism)** 或**社会建构论 (Social Constructivism)** 则强调社会实在的主观性和互动建构性 (Berger & Luckmann, 1966; Gergen, 1985)。它认为我们所理解的“社会现实”, 包括各种社会问题, 并非纯粹客观的存在, 而是在特定的历史、文化、社会互动

和话语实践中被共同“建构”(construct)出来的。在此视角下,关注点从“发现”问题转向了解“问题化”(problematization)的过程(Foucault, 1988)——即某个社会现象是如何被定义为“问题”、被赋予特定含义、并引发社会关注和干预的?问题的界定本身就反映了权力关系、价值观念和社会规范。例如,贫困问题不仅是客观的物质匮乏,更是社会如何定义、衡量和应对贫困的过程。问题的意义和重要性是相对的、情境化的。

介于两者之间或试图超越二元对立的立场,如**批判实在论 (Critical Realism)** (Bhaskar, 1979, 1989), 承认存在着独立于我们感知的深层社会结构和生成机制(本体论上的实在论),但同时强调我们对这些结构和机制的认识是理论负载的、易错的、并通过社会实践和话语间接获得的(认识论上的建构性或诠释性)。在此视角下,社会问题是深层结构和机制作用于经验层面的表现或后果。研究的目标是揭示这些不可直接观察的生成机制,并通过批判性反思推动社会结构的变革。它既承认问题的客观根源(源于潜在结构),也关注问题的社会呈现和认知建构。

其次,**认识论 (Epistemology)** 探讨知识的来源、性质、范围和确证方式。不同的认识论立场直接影响着研究者如何界定“有效”的知识主张,以及什么样的研究问题被认为是可以通过科学探究来回答的。**实证主义 (Positivism)** 及其现代变体**后实证主义 (Post-positivism)** (Comte, 1853; Popper, 1959; Phillips & Burbules, 2000), 强调知识应建立在可观察的经验证据之上,追求客观性、普遍性和可证伪性。它倾向于提出可以转化为清晰变量关系、能够进行量化测量和统计检验的问题,旨在发现社会现象的模式、规律和因果联系。知识的确证依赖于逻辑演绎和经验数据的系统验证(或证伪)。模糊的、价值负载的或无法操作化的问题在此范式下可能被视为“非科学”的。

解释主义 (Interpretivism) 或**诠释学 (Hermeneutics)** (Weber, 1949; Geertz, 1973; Taylor, 1985), 则认为社会科学的核心在于理解人类行动的主观意义、意图、信念和文化背景。社会现实是充满意义的世界,知识的获得依赖于研究者深入情境、“设身处地”地理解和阐释行动者的视角。因此,解释主义倾向于提出关于意义建构、文化象征、互动过程、社会规范解读等问题。知识的确证标准不是普适规律的发现,而是阐释的深度、融贯性(coherence)和说服力(persuasiveness)。强调对特定情境的“深描”(thick description)而非普遍性概括。

批判理论 (Critical Theory) (Horkheimer & Adorno, 1947; Habermas, 1984; Fay, 1987), 不仅关心“是什么”和“为什么”,更关心“应该怎样”。它将知识与权力、利益和解放联系起来,旨在揭示社会中隐藏的支配结构、意识形态和不平等,并促进社会的批判性反思和变革。批判理论倾向于提出关于权力运作、意识形态批判、社会压迫机制、解放路径等问题。知识的有效性不仅在于其经验符合度或解释力,更在于其批判性和解放潜力。价值判断在此范式中不仅是不可避免的,而且是研究的内在驱动力。

表 1：不同认识论立场对研究问题的侧重

认识论立场	核心主张	对研究问题的侧重	知识确证方式
实证主义/后实证主义	追求客观性、普遍性、可证伪性，知识基于经验观察与逻辑推理。	可操作化测量、变量关系、模式发现、因果解释、预测。问题需清晰、经验可检验。	经验验证/证伪、统计推断、逻辑一致性。
解释主义/诠释学	关注主观意义、理解行动者视角、文化脉络。社会现实是意义建构的。	意义阐释、文化理解、互动过程分析、情境化描述。问题围绕“理解”而非“解释/预测”。	阐释的深度、融贯性、主体间验证、内部一致性。
批判理论	知识与权力、解放相关，旨在揭示不平等、批判意识形态、促进变革。	权力分析、意识形态批判、结构性压迫机制、解放策略。问题具有明确的价值导向和实践意图。	批判性反思、解放潜力、历史语境分析、实践检验。

最后，问题的提出也涉及“**给定性**”与“**选择性**”的张力。一方面，研究问题可能看似是由学科内部的逻辑发展、理论空白或关键辩论“给定”的 (Lakatos, 1970)。另一方面，问题的选择也深受研究者所处的社会历史脉络、文化背景、资助机构的议程、学术界的规范以及研究者个人的兴趣、价值观和生命体验的影响 (Bourdieu, 1975; Harding, 1991)。例如，特定社会问题的凸显（如气候变化、数字鸿沟）会引导研究资源的投入和学者的关注。认识到问题选择背后的这种复杂互动，有助于研究者进行自我反思，审视自身研究问题的潜在偏见和预设。

作为基础地，深刻理解研究问题背后的本体论与认识论基础，是进行严谨社会科学研究，尤其是跨学科的计算社会科学研究的重要前提。任何研究问题都不是纯粹技术性的，都携带着关于世界本质和我们如何认识世界的深刻哲学烙印。在计算社会科学中，这一点尤为重要，因为强大的计算工具可能诱使我们忽视这些基础性问题，陷入技术决定论或无批判的实证主义倾向 (Boyd & Crawford, 2012)。

研究问题的界定、分类学与评价准则

在明确了研究问题深层的哲学意涵之后，我们需要进一步探讨如何在实践中界定、分类和评价一个具体的社会科学研究问题。这不仅关乎研究设计的清晰性，更关乎研究工作的价值和贡献。

首先，**界定科学研究问题**是将其与日常生活的困惑、政策制定的议题或工程技术的挑战区分开来的关键一步。虽然它们之间可能存在联系与转化，但科学研究问题的核心指向是对知识本身的贡献——增进我们对社会现象的理解、解释或预测能力 (Booth, Colomb, & Williams, 2008)。一个合格的科学研究问题通常具备以下特征：**它关乎某种普遍性的疑问，而不仅仅是个人或局部的疑虑；它能够（至少在原则上）通过系统的经验研究来探寻答案，而非仅仅依赖信仰、权威或纯粹思辨；它与现有的知识体系（理论、概念、先前研究）发生联系，旨在填补空白、解决矛盾或拓展认知；并且，它被表述得足够清晰、精确，能够引导后续的研究设计与操作** (Kerlinger & Lee, 2000)。例如，“如何解决失业问题？”更像一个政策议题，而“特定类型的劳动力市场政策对青年失业率的影响机制是什么？”则更接近一个可研究的科学问题。

为了更好地把握问题的性质和研究的目标，对研究问题进行**分类**是有益的。尽管存在多种分类方式，一个基础且常用的分类方式是基于研究的主要认知目标 (Kumar, 2018; Babbie, 2015)：

- **描述性问题 (Descriptive Problems)**：旨在回答“是什么？”这类问题，致力于系统地描绘一个社会现象的特征、形态、结构、分布、频率或发展趋势。例如，特定人群的社交媒体使用模式是怎样的？某个社会运动的参与者构成是怎样的？描述性研究是许多更深入研究的基础，它提供现象的基本图景。
- **解释性/因果性问题 (Explanatory/Causal Problems)**：旨在回答“为什么？”或“如何起作用？”这类问题，试图识别导致现象发生的原因、影响因素、作用机制或后果。例如，社会经济地位如何影响个体的政治参与？在线社交网络的结构特征如何影响信息传播的速度和广度？这是社会科学研究中最核心也最具挑战性的问题类型之一，因为它涉及到复杂的因果推断 (Morgan & Winship, 2014)。
- **预测性问题 (Predictive Problems)**：旨在回答“将会怎样？”这类问题，基于对现有模式和关系的理解，预测未来的状态、趋势或事件发生的可能性。例如，基于历史投票数据和民意调查，预测选举结果；基于用户行为数据，预测其未来的购买行为或流失风险。预测本身不一定等同于解释，高预测精度也可能来自对机制尚不完全理解的“黑箱”模型 (Shmueli, 2010)。
- **探索性问题 (Exploratory Problems)**：通常在研究者对某个现象所知甚少、缺乏成熟理论指导的情况下提出，旨在“摸着石头过河”，发现新的模式、关联、变量，形成初步的理解或假设，为后续更深入、更聚焦的研究（描述性、解释性）奠定基础。例如，在一个新兴的在线社区中，用户互动呈现出哪些主要模式？

- **比较性问题 (Comparative Problems):** 旨在通过比较不同群体、社会、文化、制度或时间点的异同，来揭示现象的普遍性与特殊性，或者探究差异产生的原因。例如，不同国家的数字不平等程度及其影响因素有何异同？
- **评估性问题 (Evaluative Problems):** 旨在评估某项政策、计划或干预的效果和价值，常与因果推断紧密相关。
- **方法论问题 (Methodological Problems):** 旨在评估或改进研究方法本身，虽服务于实质问题研究，但本身也可构成研究焦点。

表 2：研究问题的基本类型学

问题类型	核心疑问	主要认知目标	典型研究焦点
描述性 (Descriptive)	是什么？	刻画现象特征、结构、分布、趋势。	模式、构成、频率、发展阶段。
解释性/因果性 (Explanatory/Causal)	为什么？如何？	识别原因、机制、影响因素、后果。	变量关系、因果路径、作用过程。
预测性 (Predictive)	将会怎样？	预测未来状态、事件、趋势。	模型预测准确性、风险评估、趋势预测。
探索性 (Exploratory)	有哪些？	发现新模式、关联、变量，形成初步假设。	未知领域探索、初步概念化、假设生成。
比较性 (Comparative)	异同如何？	比较不同单元（群体/社会/时间）的差异及其原因。	普遍性与特殊性、跨情境差异、制度/文化影响。
评估性 (Evaluative)	有何价值？	评估某项政策、计划或干预的效果和价值。	效果、效应、差异、价值。
方法论 (Methodological)	如何研究？	评估或改进研究方法本身。	

同时并非所有提出的问题都具有同等的研究价值。评价一个研究问题是否“好”，需要一套**评价准则**。虽然不同学科和认识论范式可能有所侧重，但一些核心准则被广泛认可 (King, Keohane, & Verba, 1994; Creswell & Creswell, 2017):

- **重要性 (Significance/Importance):** 问题是否足够重要？这包含两个层面：

- **智识重要性 (Intellectual Significance)**, 即问题是否触及了学科的核心理论争论、挑战了既有认知、填补了重要的知识空白, 其解答能否对学科知识体系产生实质性贡献?
- **社会重要性 (Societal Significance)**, 即问题是否关涉重要的社会现象、公共议题或人类福祉, 其解答是否具有潜在的应用价值、政策启示或社会影响? 一个好的问题通常至少在其中一个层面具有显著的重要性。
- **原创性/新颖性 (Originality/Novelty)**: 问题是否提供了新的视角? 是否探索了未被充分研究的领域? 是否以创新的方式联系了已知的概念或现象? 是否采用了新的方法来审视旧问题? 研究旨在创造新知识, 避免对已知结论进行不必要的重复。原创性并非要求绝对“前无古人”, 也可以体现在对已有研究的深化、拓展或批判性整合上。
- **可研究性/可行性 (Researchability/Feasibility)**: 问题是否能够在现实条件下被研究? 这包括:
 - **概念清晰性**, 问题中的核心概念能否被清晰界定和操作化?
 - **经验可及性**, 是否存在或可能获得研究所需的数据或经验证据?
 - **方法可行性**, 是否存在合适的研究方法和技术来分析数据并回答问题?
 - **资源可行性**, 研究者是否拥有或能够获得完成研究所需的时间、资金、技能和伦理许可? 一个再重要、再原创的问题, 如果完全无法研究, 也难以构成一个有效的科研项目起点。
- **明确性/具体性 (Clarity/Specificity)**: 问题是否被清晰、准确地表述出来? 研究的范围、对象、核心变量或概念是否足够明确? 过于宽泛、模糊或抽象的问题难以引导具体的研究设计和操作。好的问题通常是聚焦的, 能够被分解为更具体、可操作的子问题。

这些评价准则之间可能存在张力。例如, 极具原创性和重要性的问题可能研究难度极大, 可行性较低; 而高度可行的问题可能缺乏足够的原创性或重要性。研究者需要在这些准则之间进行权衡, 结合自身的研究目标、能力和资源, 选择或塑造出兼具价值与可行性的研究问题。在计算社会科学领域, 评估“可研究性”时还需要特别考虑数据的可获得性、计算资源的需求以及相关算法或模型的适用性。

理论与问题的内在纠缠：互构与驱动机制

社会科学研究中, 理论与问题之间存在着深刻而复杂的内在联系, 远非简单的线性关系, 而是一种动态的、相互塑造的纠缠状态 (Merton, 1967; Swedberg, 2014)。理解这种互构关系, 对于把握问题的来源、深化问题的意义、以及推动理论发展都至关重要。

一方面，**理论是研究问题的“母体”和源泉 (Theory as the Matrix of Problems)**。理论，作为一套关于世界如何运作的系统化解释框架（包含概念、命题、假设和模型），为我们识别、界定和理解问题提供了基础。具体而言，理论可以通过多种方式催生研究问题：

- **揭示理论的解释边界 (Identifying Theoretical Boundaries)**：当现有理论无法解释某些新出现的或反常的经验现象 (anomalies) 时，这些“理论失效”之处就构成了重要的研究问题。这些问题旨在挑战、修正或补充现有理论，是推动理论进步的关键动力 (Kuhn, 1962)。例如，经典理性选择理论无法解释的利他行为或集体行动参与，就催生了对社会规范、身份认同、网络效应等新理论视角的研究需求。
- **解决理论的内在张力 (Resolving Internal Theoretical Tensions)**：理论体系内部可能存在逻辑上的不一致、概念模糊或不同假设之间的冲突。澄清这些内部张力、寻求更融贯的理论表述，本身就可以构成重要的研究问题。例如，社会学中关于结构与能动性 (structure vs. agency) 关系的持续辩论，就不断激发着试图整合或超越这一二元对立的新理论探索和相关经验研究。
- **检验理论的衍生预测 (Testing Theoretical Predictions)**：理论通常会产出一系列关于经验世界的可检验的预测或假设。将这些预测转化为具体的研究问题，并通过经验数据进行验证或证伪，是理论发展的重要环节 (Popper, 1959)。例如，社会资本理论预测更高的网络中心性可能带来更多的资源获取，这就引出了“个体在社交网络中的中心性与其职业成就之间是否存在正相关关系？”这样的研究问题。
- **拓展理论的应用范围 (Extending Theoretical Scope)**：将一个在特定领域被验证有效的理论框架，尝试应用于新的社会情境、人群或现象，探讨其适用性和边界条件，也是产生研究问题的常见途径。例如，将源于西方背景的现代化理论应用于非西方社会的研究，考察其解释力及需要进行的修正。
- **深化理论的核心概念 (Deepening Core Theoretical Concepts)**：对理论中的核心概念进行更深入的挖掘、辨析、操作化和测量，本身就可以形成研究问题。例如，对“社会资本”、“文化”、“权力”等复杂概念进行不同维度、不同测量方式的研究。

另一方面，**问题也是理论发展的“引擎”和催化剂 (Problems as the Engine of Theoretical Development)**。社会科学理论并非封闭的逻辑体系，其活力在于与经验世界的持续对话，而这种对话往往由具体的研究问题所驱动：

- **新现象呼唤新理论 (New Phenomena Demanding New Theories)**：社会现实的不断变迁会涌现出许多现有理论难以涵盖或解释的新现象。对这些新现象的深入探究，往往能够激发新的概念化努力和理论框架的构建。例如，互联网和社交媒体的普及，催生了关于网络社会、虚拟社区、数字劳动、算法规制等一系列新的研究问题和相应的理论思考 (Castells, 2000; Van Dijk, 2012)。

- **问题驱动理论整合 (Problem-Driven Theoretical Integration)**: 为了解决某个复杂的、多层面的社会问题, 研究者可能需要整合来自不同理论流派的洞见, 从而促进理论的交叉、融合与创新。例如, 理解健康不平等问题, 可能需要整合社会分层理论、社会网络理论、文化社会学、行为经济学等多方面的视角。
- **经验发现修正理论 (Empirical Findings Refining Theory)**: 旨在回答特定问题的经验研究, 其结果可能支持、否定或要求修正现有理论的某些假设或命题。这种基于经验证据的反馈是理论实现自我完善和进步的重要机制。
- **聚焦“中层理论” (Focusing on Middle-Range Theories)**: 许多富有成效的研究问题并非直接源自宏大理论 (grand theories), 而是与特定经验领域或现象相关的“中层理论” (Merton, 1967) 发生联系。这些中层理论旨在解释有限范围内的社会现象, 更容易转化为可操作的研究问题, 其研究结果也更容易反馈并充实理论体系。例如, 关于犯罪率的“破窗理论”、关于组织创新的理论等。

此外, 理论并非总是在问题提出之前就已完整存在。在研究过程中, **理论与问题之间常常呈现出一种循环与迭代 (Circularity and Iteration) 的关系**。初步的问题意识可能引导研究者去寻找相关的理论资源, 而理论的学习又会反过来帮助研究者澄清、聚焦或重塑最初的问题。在研究执行过程中, 数据的分析结果可能与预期不符, 迫使研究者重新审视理论假设或调整研究问题。这种在理论思考、问题界定和经验探索之间的持续往复, 是社会科学研究, 尤其是探索性研究的常态 (Alvesson & Sandberg, 2011)。理论不是僵化的教条, 问题也不是一成不变的起点, 二者在研究实践中相互激发、共同演进。

深刻的“问题思维”必然要求研究者具备扎实的理论素养。只有熟悉相关的理论图景、掌握核心的概念工具、了解主要的理论争论, 研究者才能提出具有深度和意义的研究问题, 才能将自己的研究定位于更广阔的知识脉络之中, 也才能最终为理论的发展做出贡献。忽视理论根基的问题意识, 容易导致研究的碎片化、表面化和重复性。

计算范式对问题思维的认识论重塑

计算社会科学的兴起, 不仅仅是引入了一套新的研究工具和数据来源, 更在深层次上重塑了社会科学研究的认识论景观, 特别是对于我们如何构思、表述和探究研究问题产生了根本性的影响 (Lazer et al., 2009; Conte et al., 2012; Salganik, 2018)。这种重塑体现在多个维度, 带来了新的可能性, 也伴随着新的挑战。

无可置疑地, **计算强化了问题的形式化潜能 (Enhanced Potential for Formalization)**。传统社会科学理论, 特别是宏大理论或解释性理论, 往往包含丰富但有时也模糊的概念和复杂的因果叙事。计算方法, 无论是基于数学模型的分析、计算机模拟, 还是机器学习算法,

都要求对研究对象进行精确、无歧义的定义和表述。将社会科学概念（如信任、影响力、社会规范、文化距离）转化为可计算的变量、数据结构（如网络、序列、向量空间）或模型参数（如状态、规则、转移概率），这个过程本身就迫使研究者进行更严格、更清晰的概念化工作 (Nowak & Vallacher, 1998; Cioffi-Revilla, 2017)。

这种形式化的压力，一方面可能过滤掉一些难以精确化的重要但模糊的社会维度，但另一方面，它也使得问题的表述更加严谨，逻辑关系更加清晰，从而增强了问题的可检验性和研究的可重复性。例如，关于社会影响的问题，可以被形式化为网络节点状态传播的动力学模型问题。形式化不仅是一种技术操作，更是一种认识论上的选择，它塑造了我们认为哪些问题是“可处理”的。

其次，**计算极大地拓展了可观察性的边界 (Expanding the Boundaries of Observability)**。

传统社会科学研究依赖的调查、访谈、实验或档案数据，在规模、粒度、时间跨度和覆盖范围上往往受到限制。数字技术的发展，产生了海量的、被动收集的、细粒度的关于人类行为和互动的“数字足迹”(digital traces)，如社交媒体记录、网络浏览历史、移动定位数据、在线交易信息等 (Lazer et al., 2009)。这些新型数据使得研究者能够观察到前所未有的社会现象：大规模人群的实时互动、个体层面细微行为的长期追踪、复杂网络结构的动态演化、跨越地理边界的信息流动等。

这种观察能力的革命性提升，直接催生了全新的研究问题领域，例如：在线社会运动的动员机制与线下有何不同？个体情绪如何在大型社交网络中传播？算法推荐系统如何塑造用户的认知与行为？城市内部的社会隔离模式如何在细粒度时空尺度上展现？可以说，计算范式通过改变“可见性”，重新定义了社会科学可以探索的问题空间。

第三，**计算赋能了对社会复杂性的直接探究 (Enabling Direct Inquiry into Social Complexity)**。

社会系统本质上是复杂的自适应系统 (complex adaptive systems)，充满了非线性互动、反馈循环、层级结构、涌现现象和路径依赖。传统的研究方法（如基于线性模型的统计分析）在处理这种高度复杂性时常常力不从心，往往需要做出强烈的简化假设。

计算工具，特别是**基于主体的建模 (Agent-Based Modeling, ABM)** 和**复杂网络分析 (Complex Network Analysis)**，为直接模拟和分析这种复杂性提供了强大的武器 (Gilbert & Troitzsch, 2005; Newman, 2010)。

ABM 允许研究者设定微观个体（主体/代理人）的行为规则和互动模式，然后通过计算机模拟观察宏观层面的系统行为如何“涌现”出来。网络分析则提供了刻画和理解大规模社会结构、互动模式及其动力学后果的数学和计算框架。这些工具使得研究者能够提出并尝试回答关于系统整体行为、临界转变 (tipping points)、结构韧性、干预措施的非预期后果等复杂性问题，这些问题在以往往往被视为难以处理或只能进行定性描述。


第四，**计算促进了生成性理解与反事实思考 (Facilitating Generative Understanding and Counterfactual Thinking)**。传统社会科学研究往往侧重于分析已有的数据，以解释“发生了什么”以及“为什么发生”。计算模型，特别是生成性模型（如ABM），开辟了一种新的认识路径——“通过构建来理解”(understanding by building)。研究者如果能够构建一个计算模型，使其能够生成（或“生长”出）与真实世界观察到的宏观模式（如财富分布、观点极化、城市形态）相类似的现象，那么他们就可能对产生这些现象的底层微观机制获得了更深的理解。

这种生成性的方法不仅服务于解释，还极大地便利了**反事实思考 (counterfactual thinking)**。研究者可以在模型中系统地改变某些参数、规则或初始条件（模拟政策干预、环境变化或历史偶然事件），观察其对系统演化结果的影响。这使得提出和探索“如果……（没有发生），会怎样？”(what if...?) 这类反事实问题成为可能，这对于理解因果机制和评估干预效果具有重要意义 (Pearl, 2009)。

此外，**计算本身也成为了新的问题来源 (Computation Itself Becoming a Source of New Problems)**。随着算法和数字平台日益深度地嵌入社会生活的方方面面，它们本身的行为、偏见及其社会后果，也成为了社会科学研究的重要议题。例如：搜索引擎或社交媒体推荐算法是否存在偏见，加剧了信息茧房或社会歧视 (Noble, 2018; O'Neil, 2016)? 自动化决策系统（如招聘、信贷审批）的公平性如何衡量和保障？大规模数据收集和分析引发的隐私伦理问题如何应对？这些由计算技术自身引发的社会问题，构成了计算社会科学一个独特且日益重要的研究领域，需要社会科学家、计算机科学家、伦理学家和法学家的共同关注。计算范式带来的这些可能性也伴随着认识论上的风险。过度依赖数据驱动可能导致理论的空洞化；形式化的追求可能牺牲对复杂社会情境的深度理解；模型构建中的简化假设可能被忽视；算法的不透明性可能阻碍对其社会影响的真正理解。因此，拥抱计算范式带来的机遇，同时对其认识论预设和潜在局限保持批判性反思，是发展健康、负责任的计算社会科学的关键。

计算、理论、问题：一个动态的认识论三角

在计算社会科学研究实践中，计算、理论与问题并非孤立存在，而是构成了一个相互依存、动态互构的认识论三角。理解这三者之间的复杂互动关系，对于避免研究中的陷阱、提升研究的深度和价值至关重要。它们之间的关系并非简单的线性链条，而是更接近于一个持续对话、相互塑造的网络。



计算为理论的检验、精炼与发展提供了前所未有的平台 (Computation as a Platform for Theory Testing, Refinement, and Development)。一方面，大规模数据的可得性与强大的计算分析能力，使得研究者能够以前所未有的规模和精度来**检验 (test)** 源自理论的预测和假设。例如，可以通过分析数百万用户的社交媒体数据来检验关于信息扩散或社会影响的理论模型 (Aral & Walker, 2012)。这种大规模经验检验有助于增强理论的经验基础或识别其局限性。另一方面，计算模型，特别是模拟模型（如 ABM），可以作为理论的“虚拟实验室” (virtual laboratory)。研究者可以将理论的核心假设和机制编码为模型规则，然后通过运行模拟来探索这些微观机制在逻辑上会产生什么样的宏观后果 (Gilbert & Conte, 1995)。这有助于**检验理论的内在一致性 (internal consistency)**，**探索理论的边界条件 (boundary conditions)**（即理论在什么条件下成立），甚至发现理论的**未预期后果 (unintended consequences)**。例如，Axelrod (1984) 通过简单的计算模型模拟，揭示了即使在自私个体组成的群体中，合作规范也可能通过重复互动和“针锋相对”策略得以涌现和维持，极大地推动了合作理论的发展。

其次，**计算也日益成为理论生成与启发的有力工具 (Computation as a Tool for Theory Generation and Inspiration)**。传统上，理论的产生更多依赖于思想家的洞察、定性观察或对已有理论的逻辑推演。计算范式为此增添了新的路径。**数据驱动的模式发现 (data-driven pattern discovery)**，即通过机器学习、数据挖掘等技术从大规模数据中识别出先前未知的、有趣的或反常的模式、关联或结构，可以成为提出新理论假设的起点 (Hastie, Tibshirani, & Friedman, 2009)。虽然这些模式本身不等于理论，但它们可以激发研究者去思考“为什么会出现这种模式？”，从而引导新的理论探索（需要警惕虚假关联的风险）。此外，**生成性计算模型 (generative computational models)** 本身也可以被视为一种形式化的、动态的理论表达。构建一个能够重现目标社会现象的计算模型的过程，本身就是一种理论构建活动，它要求研究者明确阐述机制、互动规则和关键参数。模型的行为和结果，可能揭示出超越初始理论设想的新洞见。

理论对于指导计算方法的应用和结果解读至关重要 (Theory Guiding Computational Application and Interpretation)。缺乏理论指导的计算分析，容易陷入“数据主义”(dataism)

或“方法论拜物教”(methodological fetishism)的误区，即仅仅因为数据可用或技术新颖就进行分析，而忽视了研究的实质性意义 (Varian, 2014)。社会科学理论为计算研究提供了：1) **研究问题的来源和意义框架**：理论帮助我们判断哪些计算发现是重要的、值得进一步探究的；2) **变量选择和模型构建的依据**：理论指导我们应该关注哪些变量、它们之间可能存在何种关系、模型的关键假设应该是什么；3) **结果解释的透镜**：理论提供了将计算结果（如统计显著性、预测准确率、模拟模式）翻译回有意义的社会科学语言、并将其与现有知识体系联系起来的概念框架。没有理论的导航，计算分析可能只是一堆缺乏解释力的数字或模式。例如，在社交网络分析中，不同的社会理论（如社会资本理论、结构洞理论、社会影响理论）会引导研究者关注不同的网络指标，并对相同的网络结构赋予不同的社会意义。

研究问题的性质深刻地塑造着计算策略的选择 (Problem Definition Shaping Computational Strategy)。如前所述，研究问题具有不同的认知目标（描述、解释、预测、模拟等）。问题的性质直接决定了研究所需的数据类型、合适的计算方法以及评估结果的标准。例如，如果问题是**预测性**的（如预测用户流失），那么机器学习模型（如逻辑回归、随机森林、神经网络）可能更受青睐，评估标准侧重于预测准确率，对模型的可解释性要求可能相对较低 (Breiman, 2001)。如果问题是**解释性/因果性**的（如评估某项政策干预的效果），那么研究者可能需要运用因果推断的统计模型（如回归分析、倾向得分匹配、双重差分法）或结构化的因果模型，并需要仔细考虑混淆变量、选择偏差等问题，对模型参数的因果解释力要求很高 (Pearl, 2009; Angrist & Pischke, 2008)。如果问题是**探索复杂系统动态**的（如理解社会规范的涌现），那么基于主体的建模或网络动力学模型可能是更合适的工具，评估标准可能侧重于模型能否重现关键的宏观模式或动态特征。问题的类型决定了我们应该向计算工具“索取”什么。

这个认识论三角可能存在的**潜在失衡与风险**。一个常见的风险是“**路灯效应**”(streetlight effect)，即研究者倾向于研究那些更容易用现有计算工具和数据处理的问题，而不是那些理论上或社会意义上更重要但计算上更困难的问题 (Kaplan, 1998)。计算方法的可行性反过来不成比例地影响了研究问题的选择，导致研究议程的偏斜。另一个风险是**理论与计算的脱节**，即计算分析完全由数据驱动，缺乏理论根基，导致结果难以解释或融入现有知识体系；或者，理论模型过于抽象，难以与经验数据和计算分析有效对接。

理想的计算社会科学研究，需要在计算能力、理论深度和问题意识这三者之间寻求一种动态的、建设性的平衡。研究者应具备在三者之间灵活穿梭、相互参照的能力，既能运用计算工具解决有意义的理论问题，也能从计算实践中获得理论启发，并始终保持对问题本身的批判性审视。

计算社会科学中问题发现的认识论路径

在计算社会科学这一充满活力的交叉领域，发现和形成有价值的研究问题可以遵循多种不同的认识论路径。这些路径并非相互排斥，在实际研究中常常交织融合，但区分它们有助于我们理解不同研究取向的逻辑起点和侧重点。

- **理论驱动路径 (Theory-Driven Pathway)**: 这是社会科学研究的经典路径，其逻辑起点是现有的社会科学理论。研究者基于对某一理论（或多个竞争理论）的深入理解，识别出其中的逻辑缺口、经验争议、未解之谜或需要进一步检验的预测，然后思考如何利用计算方法或数据来解决这些理论问题。例如，检验经典社会流动理论在数字时代是否依然适用；利用大规模网络数据验证或修正社会影响理论；通过计算模型模拟来探索特定博弈论模型的均衡解在复杂社会互动中的稳定性。这条路径的认识论基础主要是**演绎逻辑**（从一般理论推导出具体可检验的假设）和**理论证伪/确证**的传统 (Popper, 1959; Lakatos, 1965)。它的优势在于能够确保研究与学科核心知识体系的紧密联系，直接贡献于理论积累。挑战在于需要深厚的理论功底，并且可能受限于现有理论的想象力。
- **经验/数据驱动路径 (Empirical/Data-Driven Pathway)**: 这条路径的起点是数据，特别是新的、大规模的、或特殊类型的数据集（如数字痕迹、信令数据、大规模文本语料库）。研究者通过对数据进行探索性分析 (Exploratory Data Analysis, EDA) (Tukey, 1977)，利用可视化、聚类、关联规则挖掘、异常检测等计算技术，识别出数据中显著的、有趣的、反常的或未预期的模式、趋势或结构。然后，围绕这些经验发现来构建研究问题，试图对其进行解释：“为什么我们会观察到这种模式？”例如，在社交媒体数据中发现某种特定信息呈现出异常的传播模式，进而提出关于其背后机制的研究问题；发现某种在线行为与线下社会经济指标之间存在强相关性，进而探究其原因。这条路径的认识论基础主要是**归纳逻辑**（从具体观察中总结出一般模式或提出假设）。它的优势在于能够发现传统方法难以察觉的新现象和关联，具有较强的探索性。挑战在于容易产生虚假关联，且发现的模式可能缺乏理论意义或难以解释，需要后续与理论进行审慎对话，避免陷入“无理论的经验主义”。
- **方法驱动路径 (Method-Driven Pathway)**: 这条路径的起点是一种新的计算方法、算法或分析技术。研究者掌握或开发了一种新的方法后，思考“这种方法能够用来解决社会科学中的哪些问题？”或者“将这种方法应用于社会数据，能够带来哪些新的洞见？”例如，将自然语言处理中的深度学习模型（如 BERT, GPT）应用于分析大规模文本数据，以研究文化变迁、公众意见动态或社会心态；将计算机视觉技术应用于分析卫星图像或街景图片，以研究城市空间、社会不平等等问题。这条路径的认识论基础可以看作是一种**工具理性**或**方法论创新驱动**。它的优势在于能够推动研究范式的革新，开拓新的研究可能性。挑战在于可能导致“锤子找钉子”的倾向，即为了使用新方法而选择问题，而不是根据问题的重要性选择方法，容易脱离实质性的理论关怀，甚至产生“方法崇拜”。需要警惕将方法本身作为研究目的，而非服务于理解社会现象的工具。

- **现象驱动路径 (Phenomenon-Driven Pathway)**: 这条路径的起点是社会现实中涌现出的新的、重要的、或令人困惑的社会现象，特别是那些与数字技术密切相关的现象。研究者被现象本身所吸引，旨在理解其特征、成因、演变过程或社会影响。例如，对“共享经济”模式的兴起及其对劳动关系的影响进行研究；对特定网络谣言的传播轨迹和公众反应进行分析；研究“取消文化”(cancel culture) 在社交媒体上的表现及其机制。这条路径的认识论基础是**问题导向和对现实的回应**。它的优势在于能够确保研究的现实相关性和社会意义。挑战在于新兴现象往往缺乏成熟的理论框架和数据支持，研究难度较大，需要较强的探索性和理论构建能力。
- **价值/规范驱动路径 (Value/Normative-Driven Pathway)**: 这条路径的起点是对某些社会价值（如公平、正义、民主、福祉、隐私、可持续性）的关切。研究者旨在通过经验研究来揭示与这些价值相关的社会问题、评估相关政策或干预措施的效果、或者为实现这些价值提供知识支持。例如，研究算法决策中存在的偏见及其对社会公平的影响；评估数字技术对民主参与的促进或阻碍作用；分析不同信息架构对用户福祉的影响。这条路径的认识论基础涉及**实践理性和社会责任感**。虽然社会科学研究通常强调价值中立（至少在分析阶段），但问题的选择本身常常蕴含价值判断。批判理论更是将价值关切置于核心。计算社会科学由于其研究对象（如算法、平台）和研究能力（如大规模干预、预测）的特性，使其与价值和规范问题更加密不可分。挑战在于需要在坚持经验研究严谨性的同时，清晰地处理价值立场，区分经验分析与规范判断。
- **跨学科概念迁移路径 (Interdisciplinary Concept Transfer Pathway)**: 这条路径的起点是借鉴其他学科（如物理学、生物学、生态学、计算机科学、复杂性科学）的概念、模型或理论框架，将其创造性地应用于理解社会现象。例如，将流行病学中的 SIR 模型应用于研究信息或行为的社会传染 (social contagion)；将生态学中的概念（如生态位、种间竞争）应用于研究组织或市场的动态；将物理学中的相变理论应用于理解集体行为的突变。这条路径的认识论基础是**类比推理和知识整合**。它的优势在于能够提供全新的视角和分析工具，促进学科交叉和理论创新。挑战在于需要准确理解源学科的概念，并审慎评估其对社会领域的适用性与局限性，避免不恰当的或表面化的类比。

表 3：计算社会科学问题发现的认识论路径


路径名称	逻辑起点	核心驱动力	认识论基础	主要优势	主要风险/挑战
理论驱动 (Theory)	现有社会科学理论	理论空白/争议/预测	演绎/理论证伪/确证	理论贡献明确，学科关联性强	可能受限于理论视野，需要理论功底
经验/数据驱动 (Data)	数据集（尤其是新的）	数据中的模式/异常/关联	归纳/模式识别	发现新现象/关联，探索性强	可能产生虚假关联，易

方法驱动 (Method)	新的计算方法/技术	方法的应用潜力	工具理性/方法论创新	开拓新研究范式，推动方法创新	脱离理论解释“锤子找钉子”，可能脱离实质问题/理论
现象驱动 (Phenomenon)	新兴/重要社会现象	理解现实/回应需求	问题导向/现实回应	现实相关性强，社会意义直接	可能缺乏理论/数据支持，研究难度大
价值/规范驱动 (Value)	社会价值/伦理关切	促进价值实现/评估影响	实践理性/社会责任	关切重要社会议题，具实践意义	需清晰处理价值立场，区分经验与规范
跨学科迁移 (Transfer)	其他学科概念/模型	类比/知识整合	类比推理/知识整合	提供新视角/工具，促进学科交叉	可能存在不当类比，需谨慎评估适用性

在实际研究中，一个好的研究项目往往是多种路径融合的结果。例如，一个由现象驱动的研究问题，可能需要借鉴跨学科的概念，利用数据驱动的方法发现模式，并最终与现有理论进行对话。关键在于研究者能够自觉地意识到自己问题意识的来源，批判性地评估不同路径的优劣，并在研究过程中保持开放性和灵活性。

在计算社会科学中，“问题思维”绝非仅仅是确定一个研究主题那么简单，它是一个贯穿研究全程的、需要持续反思和打磨的核心环节。它要求研究者不仅要掌握社会科学的理论遗产和现实关怀，熟悉计算工具的能力边界，更要具备深刻的认识论自觉——理解知识如何产生、证据如何解读、理论如何构建、价值如何安放。一个在认识论上成熟的问题意识，是引领计算社会科学研究穿越数据迷雾、避免技术陷阱、最终抵达有意义的知识彼岸的不可或缺罗盘。接下来的章节将继续探讨构成计算社会科学研究思维范式的另外两个重要支柱：数据思维和模型思维。

参考文献



Alvesson M, Sandberg J, 2011. Generating research questions through problematization[J]. *The Academy of Management Review*, 36(2): 247-271.

Angrist J D, Pischke J S, 2009. *Mostly Harmless Econometrics: An Empiricist's Companion*[M]. 1st edition. Princeton, New Jersey Oxford: Princeton University Press.

Archer M S, 1995. *Realist Social Theory: The Morphogenetic Approach*[M]. Cambridge: Cambridge University Press.

Audi R, 2015. *The Cambridge Dictionary of Philosophy*[M]. 3rd edition. New York City: Cambridge University Press.

Axelrod R, 1984. *The Evolution of Cooperation*[J].

Babbie E, 2015. *The Practice of Social Research - Standalone Book*[M]. 14th edition. Boston, MA: Cengage Learning.

Berger P L, Luckmann T, 1967. *The Social Construction of Reality: A Treatise in the Sociology of Knowledge*[M]. New York: Anchor.

Bhaskar R, 1989. *Reclaiming Reality: A Critical Introduction to Contemporary Philosophy*[M]. New York: Verso.

Bhaskar R, 1998. *The Possibility of Naturalism: A Philosophical Critique of the Contemporary Human Sciences*[M]. New York: Routledge.

Blaikie D N, 2007. *Approaches to Social Enquiry: Advancing Knowledge*[M]. 2nd edition. Cambridge: Polity.

Booth W C, Colomb G G, Williams J M, 2008. *The Craft of Research, Third Edition*[M]. Third edition. Chicago: University of Chicago Press.

Bourdieu P, 1975. The specificity of the scientific field and the social conditions of the progress of reason[J]. *Social Science Information*, 14(6): 19-47.

Boyd D, Crawford K, 2012. Critical questions for big data: Provocations for a cultural, technological, and scholarly phenomenon[J]. *Information, Communication & Society*, 15(5): 662-679.

Cioffi-Revilla C, 2010. Computational social science[J]. *WIREs Computational Statistics*, 2(3): 259-271.

Cioffi-Revilla C, 2017. *Computation and Social Science*[M]//Cioffi-Revilla C. *Introduction to Computational Social Science: Principles and Applications*. Cham: Springer International Publishing: 35-102.

Comte A, 2009. *The Positive Philosophy of Auguste Comte: 2 ed*[M]. Martineau H, trans. Cambridge: Cambridge University Press.

Conte R, Gilbert N, Bonelli G, et al., 2012. Manifesto of computational social science[J]. *The European Physical Journal Special Topics*, 214(1): 325-346.

Creswell J W, Creswell J D, 2014. *Research Design: Qualitative, Quantitative, and Mixed Methods Approaches*[M]. 4th edition. Los Angeles, Calif.: SAGE Publications, Inc.

Editors Marsh D and G S, 2010. *Theory and Methods in Political Science: Third Edition*[M]. 3rd edition. Basingstoke, Hampshire: Palgrave Macmillan.

Fay B, 1987. *Critical Social Science: Liberation and its Limits*[M]. Ithaca, N.Y.: Cornell University Press.

Foucault M, 1988. *Technologies of the Self: A Seminar with Michel Foucault*[M]. First Edition. Amherst: University of Massachusetts Press.

Geertz C, 1973. Interpretation of Cultures[M]. Fifth Pr. edition. New York, NY: Basic Books, Inc.

Gergen K J, 1985. The social constructionist movement in modern psychology[J]. American Psychologist, 40(3): 266-275.

Gilbert N, Klaus T, 2005. Simulation for the Social Scientist[M]. 2 ed.

Guba E G, Lincoln Y S, 1994. Competing paradigms in qualitative research[M]//Handbook of qualitative research. Thousand Oaks, CA, US: Sage Publications, Inc: 105-117.

Habermas J, 1985. The Theory of Communicative Action, Volume 1: Reason and the Rationalization of Society[M]. McCarthy T, 译. Reprint edition. Boston: Beacon Press.

Harding S, 1991. Whose Science? Whose Knowledge? Thinking From Women's Lives[M]. Cornell University.

Hastie T, Tibshirani R, Friedman J, 2009. Introduction[M]//Hastie T, Tibshirani R, Friedman J. The Elements of Statistical Learning: Data Mining, Inference, and Prediction. New York, NY: Springer: 1-8.

Horkheimer M, Adorno T W, 2007. Dialectic of Enlightenment[M]. Jephcott E, trans 1st edition. Stanford, Calif: Stanford University Press.

I. Lakatos, 1970. Criticism and the Growth of Knowledge: Falsification and the Methodology of Scientific Research Programmes[M]//Criticism and the Growth of Knowledge. Cambridge University Press: 91-196.

Italy N G U of S R C N R C of, 1995. Artificial Societies: The Computer Simulation Of Social Life[M]. 1st edition. Milton: Routledge.

Kaplan A, 1998. The Conduct of Inquiry: Methodology for Behavioural Science[M]. London: Routledge.

Kerlinger F N, Lee H B, 1999. Foundations of Behavioral Research[M]. 4th edition. Singapore: Wadsworth Publishing.

King G, Keohane R O, Verba S, 1994. Designing Social Inquiry: Scientific Inference in Qualitative Research[M]. Princeton, N.J: Princeton University Press.

Kuhn T S, 1962. The structure of scientific revolutions[M]. University of Chicago Press: Chicago.

Kumar R, 2014. Research Methodology: A Step-by-Step Guide for Beginners[M]. 4th edition. Los Angeles London New Delhi Singapore Washington DC: SAGE Publications Ltd.

Lazer D, Pentland A, Adamic L, et al., 2009. Computational Social Science[J]. Science, 323(5915): 721-723.

Merton R K, 1967. On Theoretical Sociology: Five Essays, Old and New[M]. 624th ed. edition. New York, NY: Free Press.

Morgan S L, Winship C, 2007. Counterfactuals and Causal Inference: Methods and Principles for Social Research[M]. 1st edition. Cambridge: Cambridge University Press.

Newman M E J, 2010. Social networks: A discussion of social networks and the empirical techniques used to probe their structure[M]//Newman M. Networks: An Introduction. Oxford University Press: 0.

Noble S U, 2018. Algorithms of Oppression: How Search Engines Reinforce Racism[M]. Illustrated edition. New York: NYU Press.

Nowak A, Vallacher R R, 1998. Dynamical social psychology[M]. New York,

NY, US: Guilford Press: xvi, 318.

O'Neil C, 2016. Weapons of Math Destruction: How Big Data Increases Inequality and Threatens Democracy[M]. 1st edition. New York: Crown.

Pearl J, 2009. Causality: Models, Reasoning and Inference[M]. 2nd edition. Cambridge, U.K. ; New York: Cambridge University Press.

Phillips D C, Burbules N C, 2000. Postpositivism and educational research[M]. Lanham, MD, US: Rowman & Littlefield: ix, 101.

Popper K, 2002. Conjectures and Refutations: The Growth of Scientific Knowledge[M]. 2nd edition. London: Routledge.

数据的认识论属性：作为现实表征的本质与起源

Salganik M J, 2018. Bit by bit: Social research in the digital age[M]. Princeton, NJ, US: Princeton University Press: xix, 423.

Shmueli G, 2010. To Explain or to Predict?[J]. Statistical Science, 25(3): 289-310.

Swedberg R, 2014. Theorizing in Social Science: The Context of Discovery[M]. Stanford, California: Stanford University Press.

Taylor C, 1985. Human Agency and Language[M]. New York: Cambridge University Press.

Tukey J, 1977. Exploratory Data Analysis[M]. 1st edition. Reading, Mass.: Pearson.

van Dijk H, van Engen M L, van Knippenberg D, 2012. Defying conventional wisdom: A meta-analytical examination of the differences between demographic and job-related diversity relationships with performance[J]. Organizational Behavior and Human Decision Processes, 119(1): 38-53.

Varian H R, 2014. Big Data: New Tricks for Econometrics[J]. Journal of Economic Perspectives, 28(2): 3-28.

Weber M, 1949. The Methodology Of The Social Sciences[M]. Shils E A, Finch H A, trans. Free Press.

进一步地，数据的产生还体现了显著的**选择性 (Selectivity)**。面对无限复杂的社会现实，任何数据收集行为本质上都是一种有目的的简化和抽象 (Kitchin, 2014a)。研究者或数据生产者总是在特定理论框架、研究问题或实践需求的引导下，选择性地关注现实的某些方面，而忽略其他方面。数字时代广泛存在的“**数据化**”(Datafication) 趋势——即将社会生活的各个方面（如情绪、关系、位置、偏好）转化为可量化、可存储、可分析的数据的过程 (Mayer-Schönberger & Cukier, 2013; Couldry & Mejias, 2019)——本身就是一种深刻的认识论实践。它不仅改变了我们认识世界的方式，也可能改变世界本身（后文将详述）。这种转化过程并非中立，它往往遵循特定逻辑（如商业逻辑、治理逻辑），使得某些现象更容易被“数据化”，而另一些则被边缘化或扭曲。

因此，理解数据的**生成语境 (Context of Generation)** 和**意向性 (Intentionality)** 成为批判性数据思维的关键一环。我们需要追问：这份数据最初是为了什么目的被收集和创建的？是用于商业运营优化、用户监控、行政管理、科学研究，还是其他？其“**原生目的**”(Primary

Purpose) 往往决定了数据的内在结构、覆盖范围、时间频率、变量定义以及潜在的偏向 (Groves, 2011; Kitchin, 2014)。例如, 为广告投放而收集的用户行为数据, 可能在反映用户真实兴趣或社会互动方面存在系统性偏差。此外, 数据的产生往往涉及**多重主体意图**的交织, 包括数据产生者 (用户)、数据收集者 (平台/机构)、数据处理者和数据使用者 (研究者)。各方可能拥有不同甚至冲突的目标和利益, 这使得数据的意义解释更加复杂, 需要研究者具备高度的语境敏感性。

数据的**本体论状态 (Data Ontology)** 也直接影响其**认知潜能 (Epistemic Potential)**。不同类型的数据——如图数据库 (graph data) 强调关系, 地理空间数据 (geospatial data) 强调位置, 文本数据 (text data) 蕴含意义, 时间序列数据 (time-series data) 捕捉动态——为我们认识社会现象提供了不同的维度和切入点 (Cioffi-Revilla, 2014; Borgman, 2015)。理解特定数据类型的本体论预设 (例如, 网络数据通常预设了离散节点和边的存在) 及其表征能力的边界至关重要。与此同时, **元数据 (Metadata)**——即关于数据的数据, 描述了数据的来源、定义、格式、质量、收集方法、时间范围等信息——对于评估数据的认识论价值起着决定性作用 (Gitelman, 2013; Borgman, 2015)。缺乏充分元数据的数据往往如同失去了“身份”和“履历”, 其可信度和可用性大打折扣。数据的格式和结构也赋予其不同的“**可操作性**” (Affordances) (Gibson, 1979; Kitchin, 2014), 即数据“允许”或“邀请”我们对其进行何种类型的计算分析。这种可操作性反过来又可能塑造我们的研究问题和分析路径, 形成一种技术与认知的互动循环。

最后, 在认识论层面厘清**观察 (Observation)**、**测量 (Measurement)** 与**数据 (Data)** 之间的概念链条极为重要。观察是对现象的初步感知, 可能带有主观性和非系统性。测量则是依据特定规则, 将观察到的现象属性赋予符号 (通常是量化的数值) 的过程 (Stevens, 1946; Michell, 1999)。测量蕴含着一系列理论和操作化假设, 例如, 是否可以将被测量的属性视为连续的、可加的, 以及所使用的测量工具是否有效、可靠。数据则是测量结果经过系统性记录、组织和存储的产物 (Suppes & Zanotti, 1981)。计算社会科学研究所依赖的“数据”, 实际上是这个从观察到测量的链条末端的输出。因此, 对其认识论地位的批判性评估, 必须回溯性地审视整个链条中可能引入的假设、偏差和失真 (Blalock, 1982)。例如, 在线社交网络中的“连接”数据, 是基于平台对“好友关系”或“关注关系”的操作化定义 (测量规则) 而产生的记录 (数据), 它与个体实际的社会支持网络 (观察到的现象或潜在构念) 之间可能存在显著差异。忽视这一链条, 直接将数据等同于现实, 是认识论上的重大谬误。

数据作为社会过程的知识来源：推断的桥梁与挑战

数据之所以在计算社会科学中扮演核心角色，是因为它被视为理解和解释社会过程——如人类行为模式、社会结构演化、文化意义传播、集体动态涌现——的**经验证据 (Empirical Evidence)** (Popper, 1959; Hempel, 1965)。然而，数据本身并不能自动生成知识。从数据记录到关于社会过程的知识主张，必须跨越一个**推断的桥梁 (Inferential Bridge)**。这个推断过程本质上是基于归纳、演绎或溯因逻辑，并且高度依赖于研究者所持有的理论假设、背景知识、分析框架以及所采用的计算方法 (Pearl, 2009; Salganik, 2018)。数据只是推断链条中的一环，其作为证据的强度 (informativeness and relevance) 取决于它与所要探究的社会现象的关联程度、数据本身的质量，以及研究者在多大程度上能够排除其他可能的解释或混淆因素 (Campbell & Stanley, 1963)。

社会数据能够为我们提供关于社会过程不同层面的洞见。例如，用户的点击流、购买记录、地理移动轨迹等可以被视为**行为痕迹 (Behavioral Traces)**，揭示个体和群体的日常实践、决策模式与互动节奏 (Lazer et al., 2009)。社交网络图、组织成员名单、合著网络等数据则像是**结构快照 (Structural Snapshots)**，表征了特定时间点上的社会关系、权力分布或合作模式 (Wasserman & Faust, 1994; Borgatti et al., 2013)。大量的文本、图像、视频等多模态数据则成为**意义载体 (Carriers of Meaning)**，承载着个体的观点、情感、文化符号、社会规范和意识形态 (Jurafsky & Martin, 2023)。而带有时间戳的事件数据、面板数据 (longitudinal data) 或连续生成的流数据 (streaming data) 则记录了**动态流变 (Dynamic Flows)**，使研究者得以追踪社会现象的演变轨迹、扩散过程和因果时序 (Coleman, 1981; Cioffi-Revilla, 2014)。然而，对于每一种数据表征，研究者都需要审慎思考其局限性。行为痕迹可能无法反映行为背后的动机和意图；结构快照可能是静态的，忽略了关系的动态变化；意义的解读高度依赖于阐释框架和文化语境；动态记录往往是离散的，可能无法捕捉到关键的转折点或连续过程的细微变化。

这种对数据意义解读的**语境依赖性 (Context Dependency)** 是认识论上的一个核心挑战。数据的含义并非内在于符号本身，而是在其产生的具体社会、文化、历史背景以及研究者所采用的理论视角下被赋予和建构的 (Geertz, 1973; Gitelman, 2013)。例如，社交媒体上的一个“点赞”行为，在不同平台、不同文化、不同用户关系、不同内容语境下，可能代表着赞同、已阅、社交礼仪、甚至讽刺等截然不同的含义。脱离语境的数据聚合和量化分析，很可能导致对社会现象的肤浅理解甚至严重误读。因此，计算社会科学研究不仅需要强大的计算能力，同样需要深厚的领域知识 (domain knowledge) 和对社会文化语境的敏感性 (Schrodt, 2014)。

更进一步，我们需要认识到数据与现实之间可能存在的**互动关系 (Interaction between Data and Reality)**，这超越了数据仅仅作为现实被动“记录”的传统观念。一方面，数据化过程本身就可能**构成 (Constitute)** 或**塑造 (Shape)** 它所意图测量的社会现实。正如伊恩·哈金 (Ian Hacking) 所提出的“循环效应” (looping effect) 概念，对人类行为的分类和测量会反

过来影响人们的自我认知和行为方式 (Hacking, 1995)。在数字时代, 这种效应尤为显著。例如, 在线声誉系统、信用评分、健康追踪应用等, 不仅仅是记录用户的状态, 它们通过设定标准、提供反馈、影响机会, 直接干预和塑造着用户的行为与身份认同 (Zuboff, 2019)。这种数据的“**展演性**”(Performativity) ——即数据不仅描述世界, 也参与构建世界——使得认识论上的因果推断和客观性声称变得异常复杂 (MacKenzie, 2006)。研究者必须警惕, 他们分析的数据可能并非“自然”状态下的社会现象, 而是已经被数据化过程本身所“污染”或“改造”的结果。这种数据与现实之间的反馈循环, 对计算社会科学研究的设计、解释和伦理提出了深刻的挑战。

社会数据的系统性认知局限：知识扭曲的来源分类

尽管数据为计算社会科学提供了前所未有的经验基础, 但我们必须清醒地认识到, 所有数据, 尤其是大规模、被动收集的数字痕迹数据, 都内嵌着各种系统性的局限, 这些局限可能扭曲我们对社会现实的认知, 损害知识主张的有效性和可靠性。批判性的数据思维要求我们能够系统性地识别、评估这些局限的来源及其潜在的认识论后果。我们可以将这些局限大致归纳为以下几个相互关联的类别:

表 1: 社会数据的系统性认知局限来源分类及其认识论后果

局限类别	主要表现	核心认识论问题	潜在后果
来源与覆盖局限	人口/群体代表性偏差 内容/行为覆盖偏差 时间/空间覆盖偏差	我们看到了谁/什么?	抽样偏差 结论的外部效度受损 对特定群体或现象的系统性忽视
测量与表征局限	构念-测量差距 测量误差 (随机/系统) 代理变量问题 观察者效应/反应性	我们看到的是否准确?	测量偏差 构念效度低下 关系估计失真 行为非自然
系统与中介局限	算法混淆/中介 系统动态性/非平稳性 反馈循环/内生性	我们看到的受到何种干扰?	因果推断困难 结果不可复现/不稳定 模型预测失效
数据内在质量局限	数据缺失 (模式) 数据噪音	数据本身可靠吗?	信息损失 分析结果偏差/方差增大

下面我们对每一类局限进行更详细的阐述：

- **来源与覆盖局限 (Limitations from Source and Coverage)**：这类局限源于数据并非对目标研究总体（无论是人群、行为、内容、时间还是空间）的全面、无偏反映。**人口/群体代表性偏差**是数字数据面临的普遍问题 (Schober et al., 2016; Hargittai, 2020)。例如，特定社交媒体平台的用户在年龄、性别、教育程度、地理分布、政治倾向等方面可能与总体人口或其他平台用户存在显著差异（所谓的“平台偏差” Platform Bias）。更深层次的**数字鸿沟 (Digital Divide)** 意味着那些缺乏数字接入或数字技能的群体在数据世界中被系统性地“消声” (van Dijk, 2020)。**内容/行为覆盖偏差**则指数据可能只捕捉了现象的某些特定方面。例如，在线购物数据反映了消费行为，但可能无法揭示人们的线下社交互动；政治讨论论坛的数据反映了言论，但可能忽略了非言语的政治参与。**时间/空间覆盖偏差**也很常见，例如，某些历史时期的数据可能难以获取，或者数据只覆盖了特定城市而无法代表更广泛区域。这些覆盖性的局限直接威胁到研究结论的**外部效度 (External Validity)**，即研究结果能否推广到数据来源之外的人群、情境或时间段 (Shadish, Cook, & Campbell, 2002)。忽视这些偏差可能导致研究者基于有偏样本得出关于普遍规律的错误结论。
- **测量与表征局限 (Limitations from Measurement and Representation)**：即使数据来源覆盖了目标群体或现象，其测量和表征方式也可能存在问题。核心挑战在于**构念-测量差距**，即研究中实际测量或操作化的变量（如“点赞数”、“好友数”、“在线时长”）与研究真正关心的抽象理论构念（如“社会影响力”、“社会资本”、“幸福感”）之间往往存在距离 (Cronbach & Meehl, 1955; Goertz, 2006)。这种差距导致了**构念效度 (Construct Validity)** 问题——我们测量的是我们声称要测量的东西吗？许多数字痕迹数据本质上是研究者无法直接控制其测量过程的“现成数据”(found data)，这使得构念效度评估尤为困难 (Howison, Wiggins, & Crowston, 2011)。**测量误差**是所有经验研究都面临的问题，包括随机误差（噪音）和系统误差（偏差）。在数字环境中，平台界面变化、用户误操作、数据记录系统的 bug 等都可能引入测量误差。**代理变量问题**也很突出，研究者常常不得不使用容易获取但并非最优的代理指标来测量难以直接观察的构念，这可能引入额外的偏差和噪音 (Bound, Brown, & Mathiowetz, 2001)。此外，如前所述，**观察者效应或反应性**在数字环境中可能以新的形式出现，例如用户意识到自己的行为被追踪或评估时，可能会改变其行为模式（例如，为了迎合算法推荐而调整浏览习惯），使得观测到的数据并非其“自然”状态下的表现 (Acquisti, Taylor, & Wagman, 2016)。
- **系统与中介局限 (Limitations from System and Mediation)**：现代数字数据通常产生于复杂的社会技术系统之中，这些系统本身及其运行逻辑会深刻影响我们能观测到的数据，带来独特的认识论挑战。**算法混淆或中介**是计算社会科学面临的核心难题之一 (Salganik, 2018; Anderson et al., 2020)。搜索引擎的排序算法、社交媒体的信息流推荐算法、内容审核机制等，都在无形中塑造着用户接触到的信息、互动模式和行为选择。

这使得研究者很难区分观测到的模式是源于用户内生的偏好或行为，还是算法干预的结果。例如，社交网络中的“同质性”(homophily, 相似的人倾向于连接)可能被推荐算法放大，使得从观测数据中估计真实的同质性水平变得困难。**系统动态性与非平稳性**也带来挑战。社会系统本身在不断演变，同时，数据产生的平台、用户群体、使用行为、乃至平台自身的算法和功能也在随时间变化(Ribes & Jackson, 2013)。这使得跨时间的数据比较和建立稳定预测模型变得困难，因为过去的模式可能不再适用于未来(即“模型漂移” model drift)。**反馈循环与内生性问题**也更为突出，例如，基于历史犯罪数据部署警力的预测性警务系统，可能导致在特定区域投入更多警力，进而发现更多犯罪，产生的数据又进一步强化了最初的偏见，形成恶性循环(Ensign et al., 2018)。这种内生性使得从观测数据中识别真实的因果关系异常困难。

- **数据内在质量局限 (Limitations from Intrinsic Data Quality)**: 最后，数据本身可能存在各种质量问题，直接影响分析结果的可靠性。**数据缺失**是常见问题，关键在于缺失的机制：是完全随机缺失(MCAR)、随机缺失(MAR)还是非随机缺失(MNAR)? 不同的缺失机制对分析结果的偏差影响不同，需要采用恰当的方法处理(Little & Rubin, 2002)。大规模数据中往往也伴随着相当程度的**数据噪音**，即无关或错误的记录。**数据真实性与伪造**问题在数字时代变得更加突出，例如社交媒体上的虚假账户(bots)、刷单行为、网络水军等产生的“脏数据”可能严重污染分析结果(Ferrara et al., 2016)。对于依赖用户生成内容的平台尤其如此。**数据一致性与整合问题**则出现在需要合并来自不同来源、不同时间点或不同格式的数据时，可能存在定义不一致、格式不兼容、实体识别困难等问题(Doan, Halevy, & Ives, 2012)。

这些系统性局限相互交织，共同构成了计算社会科学研究在认识论上面临的严峻挑战。其最终的**认知后果**是导致基于数据的知识主张充满了**不确定性(Uncertainty)**。批判性的数据思维并不意味着因噎废食、放弃使用数据，而是要求研究者在整个研究过程中，始终对这些潜在的局限性保持警惕，主动地去识别、评估它们对研究结论可能产生的影响，并通过研究设计(如多源数据印证)、分析方法(如敏感性分析、偏差校正模型)和结果解释(如明确承认局限、界定结论适用范围)来尽可能地缓解或说明这些问题。这要求研究者不仅具备技术能力，更要具备深刻的认识论自觉和方法论审慎。

数据规模的认识论意涵：新视野、旧陷阱与批判性反思

计算社会科学常常与“大数据”(Big Data)联系在一起，后者通常被认为具有“3V”(体量大、速度快、多样性)特征(Laney, 2001; Kitchin, 2014)。数据规模的急剧扩张无疑为社会科学研究打开了新的认识论视野(**New Epistemic Horizons**)。首先，大规模数据使得研究者能够**探测到传统小样本研究难以发现的微弱信号、罕见事件或细微差异**(Fan, Han, & Liu, 2014)。其

次，数据的多样性和高维度允许我们**分析更为复杂的社会互动模式和网络结构**，捕捉到个体行为与宏观现象之间的多层次联系 (Contractor et al., 2006)。再次，数据的实时性或高频性使得**近乎实时地追踪社会动态过程**（如舆情演变、疾病传播、金融市场波动）成为可能 (Sakaki, Okazaki, & Matsuo, 2010)。最后，数据在时间和空间上的延展性使得研究**更大时空尺度的社会变迁和模式**成为可能 (Aiden & Michel, 2013)。这些无疑极大地拓展了社会科学的研究议程和解释能力。

然而，数据规模的扩张并非全然是认识论上的福音，它也可能放大已有的**旧陷阱 (Old Traps, Amplified)**，并带来新的认识论风险。一个突出的风险是**对虚假关联的易感性显著增加** (Calude & Longo, 2017; Harford, 2014)。当变量数量巨大、数据点极多时，仅仅因为偶然性就发现统计上显著（例如 p 值很小）但实际上毫无意义或误导性的相关关系的可能性大大增加。这要求研究者在解释相关性时更加审慎，并更加注重因果推断的严格性。另一个陷阱是所谓的“**N=All 的幻觉**” (boyd & Crawford, 2012)。即使数据规模巨大，它通常也并非真正意义上的“全数据”(total population data)，而只是“可用数据”(available data)。如前所述，这些数据往往带有系统性的覆盖偏差。规模的庞大性可能掩盖甚至加剧这些偏差的影响，使得研究者误以为自己的发现具有普遍性，而实际上可能只适用于产生数据的特定（且可能有偏的）人群或情境。此外，大规模、高维度数据也增加了**模型过度拟合 (Overfitting)** 的风险，即模型过于完美地拟合了训练数据中的噪音和特异性，导致其在新的、未见过的数据上表现很差，丧失了**泛化能力 (Generalizability)** (Hastie, Tibshirani, & Friedman, 2009)。最后，过度强调数据的规模和计算能力，可能带来**理论空洞化的风险** (Risk of A-theoretical Empiricism)。一些人甚至宣称大数据时代“理论的终结”(Anderson, 2008)，认为数据自身就能“说话”，无需理论指导。这是一种危险的认识论短视 (Pietsch, 2016; Kitchin, 2014)。缺乏理论指导的数据分析容易陷入盲目的“数据挖掘”或仅仅发现肤浅的相关性，而无法提供深刻的解释机制和对社会过程的真正理解。理论在提出有意义的研究问题、构建合理的模型、解释分析结果以及评估发现的重要性方面，仍然发挥着不可替代的作用 (Hedström & Ylikoski, 2010; Watts, 2014)。

数据规模的扩张及其带来的计算方法（如机器学习）的广泛应用，也对一些**传统的认识论假设提出了挑战 (Challenges to Traditional Epistemological Assumptions)**。例如，当数据规模接近甚至号称覆盖总体时，传统基于小样本抽样的**统计推断逻辑**（如置信区间、假设检验）的解释和适用性引发了讨论 (Lin, Lucas Jr, & Shmueli, 2013; Meng, 2018)。同时，尽管数据量巨大，但从观测性大数据中进行可靠的**因果推断**仍然面临巨大的方法论和认识论障碍（如混淆变量控制、内生性问题） (Pearl & Mackenzie, 2018; Athey, 2017)。此外，机器学习算法在预测方面的成功，特别是那些“黑箱”模型，引发了关于**知识的可解释性 (Interpretability)** 与**预测准确性 (Predictive Accuracy)** 之间关系的讨论：一个我们不完全理解其内部机制但预测准确的模型，能在多大程度上构成“科学知识”？ (Rudin, 2019; Lipton,

2018)。知识发现过程的**自动化**也引发了关于“发现”主体性（是人类研究者还是算法？）以及知识**正当性 (Justification)** 来源的新问题。

面对这些机遇、陷阱和挑战，计算社会科学研究者需要发展并践行一套**批判性的数据认知实践 (Critical Data Epistemic Practices)**。这包括：


- **数据谱系追溯 (Data Provenance Tracking)**：系统性地记录、审视和报告数据的来源、生成过程、处理历史及其潜在影响 (Borgman, 2015; Chapman et al., 2020)。
- **情境化理解 (Contextual Understanding)**：将数据分析嵌入其产生的具体社会、技术和组织背景中，结合定性知识和领域专长进行解读 (boyd & Crawford, 2012)。
- **方法论透明性 (Methodological Transparency)**：清晰、完整地报告数据处理步骤、分析方法、模型假设和参数选择，确保研究过程的可检验性和可复现性 (Peng, 2011)。
- **知识主张的审慎性 (Prudence in Knowledge Claims)**：坦诚地承认研究的不确定性和局限性，避免对结果进行过度泛化或过度自信的因果声称 (Lazer et al., 2014)。
- **多源数据/方法三角互证 (Triangulation)**：尽可能结合使用不同来源、不同类型的数据（如数字痕迹、调查数据、实验数据、定性访谈）和不同的分析方法，对研究发现进行交叉验证，以增强结论的稳健性 (Jick, 1979; Webb et al., 1966; Edelman, Wolff, & Bail, 2020)。
- **理论敏感性 (Theoretical Sensitivity)**：始终保持数据分析与社会科学理论的对话，用理论指导数据探索的方向和结果的解释，同时用数据分析中的发现来检验、修正或启发理论创新 (Timmermans & Tavory, 2012; Watts, 2014)。

批判性的数据思维还需要包含**认识论反身性 (Epistemological Reflexivity)** (Bourdieu & Wacquant, 1992; Alvesson & Skoldberg, 2009)。研究者需要意识到，数据并非仅仅是被动观测的对象，数据、算法以及基于它们产生的知识本身具有**能动性 (Agency)**，它们可以反过来干预、塑造甚至“制造”社会现实，这就是数据的“**展演性**”(performativity) 在认识论上的深刻意涵 (MacKenzie, 2006)。例如，预测犯罪的模型可能改变警务实践，影响犯罪率的记录方式；推荐算法不仅反映用户偏好，也可能塑造用户的偏好。研究者自身作为数据分析和知识生产者，也嵌入在这个过程中，其自身的立场、价值观、研究选择都可能影响研究结果及其社会后果。因此，反思研究者自身在知识生产过程中的角色、权力关系以及研究工作可能带来的潜在社会影响，是负责任的计算社会科学实践不可或缺的一部分 (D'Ignazio & Klein, 2020)。

“数据思维”远不止于掌握数据处理和分析的技术技能。它是一种根本性的认识论实践，要求研究者对数据的本质持有批判性理解，深刻认识到数据作为社会现实表征的复杂性、中介性和局限性。从数据的起源、生成语境，到其作为证据的推断桥梁，再到系统性的认知

局限（覆盖、测量、系统、质量），以及数据规模带来的双重影响，每一个环节都需要审慎的考量。计算社会科学研究者必须培养一种能力，既能充分利用数据带来的前所未有的洞察力，又能时刻警惕数据中潜藏的陷阱和偏见，并在整个研究过程中保持方法论的透明性、理论的敏感性和认识论的反身性。只有这样，我们才能在数字化的浪潮中，更加审慎、可靠且富有洞察力地推进对社会世界的理解。这种批判性的数据思维，将为我们在后续章节中探讨具体的方法论原则和操作技术奠定坚实的认识论基础，并最终导向更有意义、更有价值的计算社会科学研究。下一节将基于问题思维、数据思维，进一步地讨论模型思维。

参考文献



Acquisti, Alessandro, Curtis Taylor, and Liad Wagman. 2016. "The Economics of Privacy." *Journal of Economic Literature* 54(2): 442–92. doi:10.1257/jel.54.2.442

Aiden, Erez, and Jean-Baptiste Michel. 2013. *Uncharted: Big Data as a Lens on Human Culture*. First Edition. New York: Riverhead Books.

Alvesson, Mats, and Kaj Skoldberg. 2009. *Reflexive Methodology: New Vistas For Qualitative Research*. Second edition. Los Angeles ; London: Sage Publications Ltd.

Anderson, David, Dennis Sweeney, Thomas Williams, Jeffrey Camm, and James Cochran. 2019. *Statistics for Business & Economics*. 14th edition. Boston, MA: Cengage Learning.

Anderson, Terry, ed. 2008. *The Theory and Practice of Online Learning*, Second Edition. 2nd edition. Edmonton: Athabasca University Press.

Athey, Susan, and Guido W. Imbens. 2017. "The State of Applied Econometrics: Causality and Policy Evaluation." *Journal of Economic Perspectives* 31(2): 3–32. doi:10.1257/jep.31.2.3

Blalock, Jane W. 1982. "Persistent Auditory Language Deficits in Adults with Learning Disabilities." *Journal of Learning Disabilities* 15(10): 604–9. doi:10.1177/002221948201501010

Borgatti, Stephen P., Martin G. Everett, and Jeffrey C. Johnson. 2018. *Analyzing Social Networks*. 2nd edition. Los Angeles: SAGE.

Borgman, Christine L. 2015. *Big Data, Little Data, No Data: Scholarship in the Networked World*. The MIT Press. doi:10.7551/mitpress/9963.001.0001

Bourdieu, Pierre, and Loïc J. D. Wacquant. 1992. *An Invitation to Reflexive Sociology*. First Edition. Chicago: University of Chicago Press.

Boyd, Danah, and Kate Crawford. 2012. "Critical Questions for Big Data: Provocations for a Cultural, Technological, and Scholarly Phenomenon." *Information, Communication & Society* 15(5): 662–79. doi:10.1080/1369118X.2012.678878

Calude, Cristian S., and Giuseppe Longo. 2016. "The Deluge of Spurious Correlations in Big Data." *Foundations of Science* 22(3): 595–612. doi:10.1007/s10699-016-9489-4

Campbell, Donald T., and Julian Stanley. 1963. *Experimental and Quasi-Experimental Designs for Research*. 1st edition. Belmont, CA: Cengage Learning.

Chapman, Evelina, Michelle M. Haby, Tereza Setsuko Toma, Maritsa Carla de Bortoli, Eduardo Illanes, Maria Jose Oliveros, and Jorge O. Maia Barreto. 2020. "Knowledge Translation Strategies for Dissemination with a Focus on Healthcare Recipients: An Overview of Systematic Reviews." *Implementation Science* 15(1): 14. doi:10.1186/s13012-020-0974-3

Cioffi-Revilla, Claudio. 2010. "Computational Social Science." *WIREs Computational Statistics* 2(3): 259–71. doi:10.1002/wics.95

Cioffi-Revilla, Claudio. 2017. "Social Networks." In *Introduction to Computational Social Science: Principles and Applications*, ed. Claudio Cioffi-Revilla. Cham: Springer International Publishing, 141–92.

Kevin R. Brine, Mary Poovey, Matthew Stanley, et al. 2013. "Data Bite Man: The Work of Sustaining a Long-Term Study." In "Raw Data" Is an Oxymoron, MIT Press, 147-66.
<https://ieeexplore.ieee.org/document/6462156> (May 9, 2025).

Goertz, Gary. 2006. *Social Science Concepts: A User's Guide*. Princeton University Press. doi:10.2307/j.ctvc4mgm.

Groves, Robert M. 2011. "Three Eras of Survey Research." *Public Opinion Quarterly* 75(5): 861-71. doi:10.1093/poq/nfr057.

Hacking, Ian. 1995. *Rewriting the Soul: Multiple Personality and the Sciences of Memory*. Princeton, NJ, US: Princeton University Press.

Harford, Tim. 2014. "Big Data: A Big Mistake?" *Significance* 11(5): 14-19. doi:10.1111/j.1740-9713.2014.00778.x.

Hargittai, Eszter. 2020. "Potential Biases in Big Data: Omitted Voices on Social Media." *Social Science Computer Review* 38(1): 10-24. doi:10.1177/0894439318788322.

Hastie, Trevor, Robert Tibshirani, and Jerome Friedman. 2009a. "Basis Expansions and Regularization." In *The Elements of Statistical Learning: Data Mining, Inference, and Prediction*, eds. Trevor Hastie, Robert Tibshirani, and Jerome Friedman. New York, NY: Springer, 139-89. doi:10.1007/978-0-387-84858-7_5.

Hastie, Trevor, Robert Tibshirani, and Jerome Friedman. 2009b. "Model Inference and Averaging." In *The Elements of Statistical Learning: Data Mining, Inference, and Prediction*, eds. Trevor Hastie, Robert Tibshirani, and Jerome Friedman. New York, NY: Springer, 261-94. doi:10.1007/978-0-387-84858-7_8.

Hedström, Peter, and Petri Ylikoski. 2010. "Causal Mechanisms in the Social Sciences." *Annual Review of Sociology* 36(Volume 36, 2010): 49-67. doi:10.1146/annurev.soc.012809.102632.

Hempel, Carl Gustav. 1965. *Aspects of Scientific Explanation and Other Essays in the Philosophy of Science*. New York: The Free Press.

Howison, James, Andrea Wiggins, and Kevin Crowston. 2011. "Validity Issues in the Use of Social Network Analysis with Digital Trace Data." *Journal of the Association for Information Systems* 12(12). doi:10.17705/1jais.00282.

Ihde, Don. 1990. *Technology and the Lifeworld: From Garden to Earth*. Bloomington: Indiana University Press.

Jick, Todd D. 1979. "Mixing Qualitative and Quantitative Methods: Triangulation in Action." *Administrative Science Quarterly* 24(4): 602-11. doi:10.2307/2392366.

Jurafsky, Daniel, and James Martin. 2008. *Speech and Language Processing, 2nd Edition*. 2nd edition. Upper Saddle River, NJ: Prentice Hall.

Kitchin, Rob. 2014. "Big Data, New Epistemologies and Paradigm Shifts." *Big Data & Society* 1(1): 2053951714528481. doi:10.1177/2053951714528481.

Latour, Bruno. 1988. *Science in Action: How to Follow Scientists and Engineers Through Society*. Revised ed. edition. Cambridge (Mass.):

Harvard University Press.

Lazer, David, Ryan Kennedy, Gary King, and Alessandro Vespignani. 2014. "Big Data. The Parable of Google Flu: Traps in Big Data Analysis." *Science* (New York, N.Y.) 343(6176): 1203–5. doi:10.1126/science.1248506



Lazer, David, Alex Pentland, Lada Adamic, Sinan Aral, Albert-László Barabási, Devon Brewer, Nicholas Christakis, et al. 2009.

"Computational Social Science." *Science* 323(5915): 721–23.

doi:10.1126/science.1167742

Lin, Mingfeng, Henry C. Lucas Jr., and Galit Shmueli. 2013. "Too Big to Fail: Large Samples and the p-Value Problem." *Information Systems Research* 24(4): 906–17. doi:10.1287/isre.2013.0480

doi:10.1287/isre.2013.0480

Lipton, Zachary C. 2018. "The Mythos of Model Interpretability: In Machine Learning, the Concept of Interpretability Is Both Important and Slippery." *Queue* 16(3): 31–57. doi:10.1145/3236386.3241340

Little, Roderick J. A., and Donald B. Rubin. 2002a. "Large-Sample Inference Based on Maximum Likelihood Estimates." In *Statistical Analysis with Missing Data*, John Wiley & Sons, Ltd, 190–99.

doi:10.1002/9781119013563.ch9

Little, Roderick J. A., and Donald B. Rubin. 2002b. "Maximum Likelihood for General Patterns of Missing Data: Introduction and Theory with Ignorable Nonresponse." In *Statistical Analysis with Missing Data*, John Wiley & Sons, Ltd, 164–89. doi:10.1002/9781119013563.ch8

doi:10.1002/9781119013563.ch8

Little, Roderick J. A., and Donald B. Rubin. 2002c. "Missing Data in Experiments." In *Statistical Analysis with Missing Data*, John Wiley & Sons, Ltd, 24–40. doi:10.1002/9781119013563.ch2

MacKenzie, Doris Layton. 2006. *What Works in Corrections: Reducing the Criminal Activities of Offenders and Delinquents*. New York, NY, US: Cambridge University Press. doi:10.1017/CB09780511499470

doi:10.1017/CB09780511499470

Mayer-Schönberger, Viktor, and Kenneth Cukier. 2013. *Big Data: A Revolution That Will Transform How We Live, Work, and Think*. Boston, MA: Houghton Mifflin Harcourt.

"Measurement Error in Survey Data." 2001. In *Handbook of Econometrics*, Elsevier, 3705–3843. doi:10.1016/S1573-4412(01)05012-7

Meng, Xiao-Li. 2018. "Statistical Paradises and Paradoxes in Big Data (I): Law of Large Populations, Big Data Paradox, and the 2016 US Presidential Election." *The Annals of Applied Statistics* 12(2): 685–726. doi:10.1214/18-AOAS1161SF

doi:10.1214/18-AOAS1161SF

Mf, Schober, Pasek J, Guggenheim L, Lampe C, and Conrad Fg. 2016.

"Social Media Analyses for Social Measurement." *Public opinion quarterly* 80(1): 180–211. doi:10.1093/poq/nfv048

doi:10.1093/poq/nfv048

Michell, Joel. 1999. *Measurement in Psychology: A Critical History of a Methodological Concept*. New York, NY, US: Cambridge University Press.

doi:10.1017/CB09780511490040

Pearl, Judea. 2009. *Causality: Models, Reasoning and Inference*. 2nd edition. Cambridge, U.K. ; New York: Cambridge University Press.

- Pearl, Judea, and Dana Mackenzie. 2018. *The Book of Why: The New Science of Cause and Effect*. 1st edition. New York: Basic Books.
- Peng, Roger D. 2011. "Reproducible Research in Computational Science." *Science* (New York, N.Y.) 334(6060): 1226-27. doi:10.1126/science.1213847.
- Popper, Karl R. 1959. *The Logic of Scientific Discovery*. Oxford, England: Basic Books.
- Rudin, Cynthia. 2019. "Stop Explaining Black Box Machine Learning Models for High Stakes Decisions and Use Interpretable Models Instead." *Nature Machine Intelligence* 1(5): 206-15. doi:10.1038/s42256-019-0048-x.
- Sakaki, Takeshi, Makoto Okazaki, and Yutaka Matsuo. 2010. "Earthquake Shakes Twitter Users: Real-Time Event Detection by Social Sensors."
- Salganik, Matthew J. 2018. *Bit by Bit: Social Research in the Digital Age*. Princeton, NJ, US: Princeton University Press.
- Shadish, William R., Thomas D. Cook, and Donald T. Campbell. 2002. *Experimental and Quasi-Experimental Designs for Generalized Causal Inference*. Boston, MA, US: Houghton, Mifflin and Company.
- Stevens, S. S. 1946. "On the Theory of Scales of Measurement." *Science* 103: 677-80. doi:10.1126/science.103.2684.677.
- Suppes, Patrick, and Mario Zanotti. 1981. "When Are Probabilistic Explanations Possible?" *Synthese* 48(2): 191-99. doi:10.1007/BF01063886
- 模型的认识论本质：作为认知中介的抽象建构**
- Timmermans, Stefan, and Iddo Tavory. 2012. "Theory Construction in Qualitative Research: From Grounded Theory to Abductive Analysis." *Sociological Theory* 30(3): 167-86. doi:10.1177/0735275112457914.
- Wasserman, Stanley, and Katherine Faust. 1994. *Social Network Analysis: Methods and Applications*. New York, NY, US: Cambridge University Press. doi:10.1017/CB09780511815478.
- Watts, Simon. 2014. "User Skills for Qualitative Analysis: Perspective, Interpretation and the Delivery of Impact." *Qualitative Research in Psychology* 11(1): 1-14. doi:10.1080/14780887.2013.776156.
- Webb, Eugene J., Donald T. Campbell, Richard D. Schwartz, and Lee Sechrest. 1966. *Unobtrusive Measures: Nonreactive Research in the Social Sciences*. Oxford, England: Rand McNally.
- Zuboff, Shoshana. 2019. "Surveillance Capitalism and the Challenge of Collective Action." *New Labor Forum* 28(1): 10-29. doi:10.1177/1095796018819461.

经济模型可能在预测市场趋势方面与真实市场相似，尽管它忽略了许多个体行为细节。另一种更强调结构对应的观点是**同构/同态论 (Isomorphism/Homomorphism Accounts)**，尤其在形式科学和结构主义传统中影响深远 (Suppes, 1960; van Fraassen, 1980)。这种观点认为，模型（通常是数学或逻辑结构）与其目标系统在结构上存在一一对应（同构）或多对一对应（同态）的关系。模型的认识价值在于其能够精确地映射目标系统的结构性特征和关系。

与表征主义相对或互补的是**工具主义 (Instrumentalist Views)**。持此观点的学者认为，模型的主要价值不在于其是否“真实地”反映了世界，而在于其作为工具的有效性 (effectiveness) 和有用性 (usefulness)。模型是服务于特定科学目的（如预测、计算、干预、启发）的工具或仪器 (Cartwright, 1983)。评价一个模型的标准是它能否很好地完成这些任务，而不是它是否“像”现实。工具主义提醒我们，模型构建往往受到实用目标的驱动，其形式和内容可能更多地由其预期功能而非对现实的忠实模仿所决定。

进一步，**虚构主义 (Fictional Views)** 将模型视为一种概念上的虚构创造物 (fictions) (Godfrey-Smith, 2006; Frigg, 2010)。模型描述的往往是现实世界中并不存在的、经过高度简化或理想化的“模型世界”。例如，物理学中的无摩擦平面、经济学中的完全理性人。这些模型并非直接描述现实，而是通过与现实进行类比、隐喻或思想实验，间接地帮助我们理解现实世界的某些方面。虚构主义强调了模型构建中的创造性和非描述性特征。

近年来，一种整合性的**推论性观点 (Inferential Views)** 受到越来越多的关注 (Suárez, 2004; Weisberg, 2013)。这种观点认为，模型的核心功能是充当推理的中介 (mediator)。研究者并非直接从理论推导到数据，或从数据归纳到理论，而是通过构建和分析模型来进行推论。模型使得我们能够运用特定的推理工具（如数学演绎、计算机模拟）来探索理论的含义、预测数据的模式或解释观测到的现象。模型的表征能力（如果有的话）和其作为工具的有效性，最终都服务于其作为可靠推理引擎的功能。

下表总结了这四种主要的哲学视角：

哲学视角 (Philosophical View)	核心观点 (Core Idea)	强调重点 (Emphasis)
表征主义 (Representationalism)	模型旨在代表或描绘目标系统的某些方面。	模型的相似性或结构对应 (Similarity/Structure)
工具主义 (Instrumentalism)	模型是用于特定科学目的（预测、计算等）的有效工具。	模型的有效性与有用性 (Effectiveness/Usefulness)
虚构主义 (Fictionalism)	模型是概念上的虚构创造物，通过类比等方式促进理解。	模型的非描述性与创造性 (Non-description/Creativity)
推论性观点 (Inferentialism)	模型是使研究者能够对目标系统进行推论的中介结构。	模型作为推理引擎 (Model as Inference Engine)

无论持有何种哲学立场，科学模型的核心构建过程都离不开两个关键的认知操作：**抽象化 (Abstraction)** 和 **理想化 (Idealization)**。这两者密切相关，但概念上可以区分，并且对于理解模型的认识论功能至关重要。**抽象化**是指在构建模型时，识别并抽取出目标系统的关键

或相关要素、属性或关系，同时忽略 (omit) 那些被认为是不相关、干扰性或过于复杂的细节 (Weisberg, 2013)。抽象化的目标是抓住问题的本质，简化复杂性，使其易于处理和理解。例如，在研究社会网络对信息传播的影响时，模型可能会抽象出网络的拓扑结构（节点和连接），而忽略个体的具体身份、动机或互动内容等细节。抽象化追求的是一种**普遍性 (generality)**，试图剥离特殊性，揭示更广泛适用的模式或原理。

理想化则更进一步，它不仅是忽略，而且是对模型中的元素或条件进行有意的、通常是与现实不符的简化、变形或极端化处理 (McMullin, 1985; Cartwright, 1989; Weisberg, 2007)。理想化可以表现为多种形式：假设不存在摩擦力或空气阻力的物理模型；假设信息完全对称、交易成本为零的经济模型；假设人口无限大或混合均匀的传染病模型；或者，在计算模型中，设定简化的行为规则或同质化的代理人主体。理想化的目的通常是为了使模型在数学上或计算上易于处理 (tractable)，或者为了凸显某个特定机制的“纯粹”效果，排除其他干扰因素的影响——这被称为**伽利略式理想化 (Galilean Idealization)**。与抽象化主要关注“遗漏”不同，理想化涉及了某种程度的“扭曲”或“失真”。

抽象化和理想化共同构成了模型构建的基础。它们是科学理解得以可能的必要手段，因为现实世界过于复杂，无法被完整无缺地复制到模型中。通过有选择地忽略和简化，模型才能够有效地降低认知负荷，突出核心机制，实现知识的迁移和应用 (Wimsatt, 2007)。然而，这也正是模型的局限性所在。抽象化可能遗漏了对现象有重要影响的因素，而理想化则可能导致模型与现实的系统性偏离。因此，对模型进行评估时，理解其所做的抽象和理想化假设，并判断这些假设在特定研究目的下的合理性与后果，是模型思维不可或缺的一环。研究者需要意识到，模型提供的知识总是“有条件的”，其有效性依赖于其抽象和理想化在多大程度上捕捉了目标问题的关键特征，而没有过度扭曲现实。

模型的认识论本质也体现在其多样的本体论形态上，这些形态往往与其服务的主要认知功能相关。虽然模型的分类方式多种多样，但从认知功能的角度区分，有助于我们理解不同模型贡献知识的方式。例如，**现象学模型 (Phenomenological Models)** 主要目标是准确地描述或预测可观测的现象模式（经验规律），它们关注输入和输出之间的关系，但不一定深入探究产生这种关系的内部机制 (Frigg & Hartmann, 2020)。相比之下，**机制性模型 (Mechanistic Models)** 则致力于揭示产生现象的底层因果过程、组件及其相互作用 (Craver & Darden, 2013; Hedström & Ylikoski, 2010)。这类模型追求的是解释的深度和对“为什么”的回答。此外，还有结构简单、高度理想化的**探索性/玩具模型 (Exploratory/Toy Models)**，它们的主要价值不在于精确拟合数据，而在于探索基本原理、展示概念可能性、激发理论洞见或作为更复杂模型的起点 (Grüne-Yanoff, 2009)。理解不同类型模型的本体论地位和认知目标，有助于研究者更恰当地选择、使用和评估模型。

模型在知识生产循环中的作用：连接理论、数据与认知

模型并非孤立存在，它们深深嵌入在科学知识生产的动态循环之中，扮演着连接理论、数据与研究者认知的关键角色。理解模型在这一循环中的多重作用，是掌握模型思维精髓的重要一步。模型既非纯粹的理论演绎，也非简单的经验归纳，而是处在理论思考与经验观察之间，进行着复杂的双向互动与中介。

模型是理论的载体与探针 (Models as Vessels and Probes for Theory)。理论通常以抽象的、往往是定性的语言表述。模型，特别是数学和计算模型，提供了一种精确、无歧义的语言，可以将理论的核心假设、概念关系和机制进行**形式化 (formalization)** (Lehtinen, 2018)。这一过程本身就具有重要的认识论价值：它可以暴露理论中隐藏的含糊性、不一致性或未明确的假设；它使得理论的逻辑后果可以通过严格的推导（数学分析）或模拟（计算实验）被探索出来。通过系统地改变模型的参数或结构，研究者可以进行**理论探索 (theory exploration)**，考察理论在不同条件下的含义、预测其动态行为、识别其解释力的边界条件，甚至发现理论中未曾预料到的潜在后果。模型还可以作为**比较和整合不同理论 (theory comparison and integration)** 的平台。研究者可以构建代表不同理论观点的模型，比较它们在解释同一现象时的优劣，或者尝试将来自不同理论的机制整合到一个统一的模型框架中 (Nowak & Vallacher, 1998)。更进一步，模型运行的结果，尤其是那些反直觉或与现有预期不符的结果，常常能够**生成新的理论假设 (generating theoretical hypotheses)**，这些假设随后可以被引导进行新的经验检验，从而推动理论的修正与发展 (Axelrod, 1997)。在这个意义上，模型是理论发展和精炼过程中不可或缺的“实验室”。

模型是数据的组织者与解释者 (Models as Organizers and Interpreters of Data)。面对庞杂的经验数据，无论是来自传统调查还是大规模数字痕迹，模型提供了一种结构化的方式来**模式化数据 (data patterning)**。它们帮助研究者识别、描述和总结数据中隐藏的结构、趋势、聚类或异常点，将看似混乱的观测组织成有意义的模式 (Hastie, Tibshirani, & Friedman, 2009)。模型通过其参数或结构，以一种简洁的形式捕捉数据中的关键信息，实现了**数据压缩 (data compression)** (MacKay, 2003)。例如，一个简单的线性回归模型用两个参数（截距和斜率）就可能概括了两个变量之间数千个数据点的关系。模型还能基于已有的数据和模型结构，对缺失的数据进行**插补 (imputation)** 或对未来的数据进行**外推 (extrapolation)**，尽管这需要谨慎对待其假设和不确定性。更重要的是，模型为**赋予数据意义 (attributing meaning to data)** 提供了框架。单纯的数据模式本身并不能自动提供解释。模型，特别是那些蕴含了理论机制的模型，能够将观测到的数据模式与潜在的社会过程、行为动机或因果关系联系起来，从而使得数据不仅仅是数字，而是关于社会现实某种叙述的证据

(Morgan, 1998)。正如著名统计学家 George Box 所言：“所有模型都是错误的，但有些是有用的 (All models are wrong, but some are useful)” (Box, 1976)，其“有用性”很大程度上就体现在它们帮助我们理解和解释数据的能力上。

模型扮演着**理论与数据之间的中介 (Models as Mediators Between Theory and Data)** 的关键角色。科学知识的进步往往涉及在抽象的理论构念与具体的经验测量之间建立联系。模型正是实现这一连接的**操作化桥梁 (operational bridge)**。理论构念（如社会资本、政治极化）通过模型被转化为可测量的变量或可计算的指标，而经验数据则通过模型被用来检验理论的预测或估计理论参数 (Blalock, 1968)。在这个过程中，理论与数据形成了某种**双向约束 (mutual constraint)**。一方面，相关的社会科学理论为模型的构建提供了指导，约束了模型的结构形式、变量选择和机制设定的合理性。缺乏理论根基的模型可能只是数据的过度拟合，缺乏解释力或泛化能力。另一方面，经验数据则对模型的有效性提出了检验，约束了模型参数的取值范围，并可能通过与模型预测的偏差来挑战或修正理论 (Mayo, 1996)。这种理论、模型与数据之间的互动关系有时被形容为一个复杂的“三体问题” (Bail, 2014)，研究者需要在理论的普适性与简洁性、模型的易处理性与精确性、以及数据的特殊性与噪音之间寻求一种动态的平衡。成功的模型往往是在这三者之间达到了某种富有成效的契合。

模型不仅仅是理论和数据的“仆人”，它们也可以作为**独立的认知工具 (Models as Independent Cognitive Tools)** 发挥作用。模型构建的过程本身，即思考如何将一个复杂的社会问题抽象化、形式化的过程，往往就能**启发新的视角 (heuristic devices)**，加深研究者对问题本身的理解，即使模型最终未能完美运行或拟合数据 (Wimsatt, 2007)。模型，特别是计算模型，提供了一个进行**思想实验 (thought experiments)** 的强大平台 (Reiss, 2011)。研究者可以在模型世界中探索那些在现实世界中因伦理、成本或技术限制而无法进行的干预（例如，改变社会网络的结构、调整政策参数），或者考察反事实情景（例如，“如果没有这项技术，社会会如何发展？”），从而获得对因果关系和系统动态的洞察。此外，一个经过充分发展和验证的模型，本身就是一种**知识的具体化 (embodiment of knowledge)**。它以一种紧凑、可操作、可传播的形式，封装了研究者（或科学共同体）关于某个目标系统如何运作的理解，成为后续研究或实践应用的基础 (Morgan & Knuuttila, 2012)。

模型的目的论：核心认知任务与知识类型

模型思维的一个核心要求是清晰地认识到：我们为什么需要模型？我们希望通过模型获得什么样的知识？不同的研究目标或认知任务，往往需要不同类型的模型，并且对应着不同的评价标准。混淆模型的目标是导致研究设计混乱和结果误读的常见原因。借鉴科学哲学和统计学中的讨论 (Shmueli, 2010; Grüne-Yanoff & Weirich, 2010; Craver, 2006; Hempel,

1965), 我们可以将模型服务的主要认知任务大致归纳为四类: 描述、预测、解释和生成/可能性探索。这四类任务并非总是截然分开, 有时一个模型可能服务于多个目的, 但明确主要目标对于指导模型选择、构建和评估至关重要。

描述性知识

描述是科学研究的基础任务之一。服务于描述目的的模型, 旨在捕捉、刻画、分类和总结目标现象的静态特征或动态模式。这类模型的目标是提供一个关于“世界是怎样”的准确、简洁、有组织的画面。它们可能用于识别数据中的群体 (如聚类分析)、概括大量文本的主题 (如主题模型)、展示社会网络的结构特征 (如网络可视化与统计指标)、或者描绘变量的分布和相关性。描述性模型产生的知识形态主要是**模式陈述 (pattern statements)**、**类型学 (typologies)**、**分布特征总结 (distributional summaries)** 或**结构图谱 (structural maps)**。在认识论上, 评估描述性模型的关键在于其**经验充分性 (empirical adequacy)**, 即模型在多大程度上能够忠实地、准确地反映观测到的数据模式。其重点在于**表征的保真度 (fidelity of representation)**。一个好的描述性模型应该能够有效地压缩信息, 同时保留数据中的关键结构和变异。

预测性知识

预测是许多科学领域的重要目标, 尤其在需要进行决策或干预的场景下。服务于预测目的的模型, 旨在基于已有的信息 (历史数据、当前状态) 来推断未来的状态、未观测到的情况或干预的潜在结果。例如, 预测选举结果、金融市场波动、疾病传播趋势、用户行为 (如购买、流失) 等。预测性模型产生的知识形态主要是**预测陈述 (predictive statements)**、**概率估计 (probability estimates)** 或**趋势预测 (trend forecasts)**。在认识论上, 评估预测性模型的核心标准是其**预测准确性 (predictive accuracy)**, 通常通过在未用于模型训练的新数据 (测试集或未来数据) 上的表现来衡量。其重点在于模型的**泛化能力 (generalizability)**。值得注意的是, 一个预测能力很强的模型, 其内部机制不一定需要完全符合我们对现实的理论理解, 甚至可能是难以理解的“黑箱”, 只要它能持续做出准确预测即可被认为是成功的 (在预测任务上) (Breiman, 2001)。这与解释性目标形成了鲜明对比。

解释性知识

解释是科学理解的核心追求。服务于解释目的的模型, 旨在超越现象的表面描述和结果预测, 去理解现象发生的原因、机制或依赖关系。它们试图回答“为什么”的问题。例如, 解

释社会不平等是如何产生和维持的、某项政策为什么会（或不会）产生预期效果、或者个体为何会做出某种特定的社会行为。解释性模型往往致力于揭示变量之间的**因果关系 (causal relationships)** 或阐明导致宏观现象的**微观机制 (micro-level mechanisms)**。其产生的知识形态是**因果机制陈述 (causal mechanism statements)**、**反事实依赖关系说明 (counterfactual dependencies)** 或**过程追踪叙述 (process-tracing narratives)**。在认识论上，评估解释性模型的标准比描述和预测模型更为复杂和苛刻。除了需要具备一定的经验充分性外，关键在于其**因果有效性 (causal validity)**（即模型所断言的因果关系是否真实存在）、**机制合理性 (mechanistic plausibility)**（即模型所假设的机制是否符合我们对社会行为和互动的理解）、以及与相关领域知识和理论**的一致性 (theoretical coherence)** (Pearl, 2009)。解释性模型通常要求其内部结构和参数具有可解释性 (interpretability)。

生成性/可能性知识

有时，研究的目标并非解释某个具体发生的事件，而是探索产生某种类型现象的**可能机制 (possible mechanisms)** 或条件。服务于此目的模型，尤其是计算模拟模型，旨在展示一个特定的微观过程**如何可能 (how-possibly)** 导致某种宏观模式的涌现 (emergence)。这类模型的目标是探索系统的潜在行为空间，理解现象生成的充分条件 (sufficient conditions)。例如，Schelling (1971) 的模型展示了即使个体只有轻微的“邻近同质性”偏好，也可能导致宏观层面的严重种族隔离。这个模型并非旨在精确预测某个城市的隔离程度，而是揭示了一种产生隔离现象的可能机制。

生成性/可能性模型产生的知识形态是“**如何可能**”的**解释 (how-possibly explanations)** (Grüne-Yanoff, 2009)、**涌现机制说明 (emergent mechanisms)** 或**反事实路径探索 (counterfactual)**。在认识论上，评估这类模型的标准主要在于其**生成充分性 (generative sufficiency)**（即模型所设定的机制确实能够产生目标现象）、**过程合理性 (process plausibility)**（即模型中的行为规则和互动方式是否具有一定的现实依据或理论基础）以及其**启发性价值 (heuristic value)**（即模型是否能带来新的洞见或激发新的研究方向）。

下表总结了这四种核心认知任务：

认知任务	核心问题	知识类型	主要认识论侧重
描述 (Description)	"是什么样的?" (What is it like?)	模式陈述, 类型学, 分布特征, 结构图谱	经验充分性, 表征保真度 (Empirical Adequacy, Fidelity)

预测 (Prediction)	"将会发生什么？" (What will happen?)	预测陈述, 概率估计, 趋势预测	预测准确性, 泛化能力 (Predictive Accuracy, Generalizability)
解释 (Explanation)	"为什么会这样？" (Why is it so?)	因果机制陈述, 反事实 依赖, 过程追踪	因果有效性, 机制合理 性, 理论一致性 (Causal Validity, Plausibility, Coherence)
生成/可能性 (Generation/Possibilit v)	"如何可能发生？" (How could it happen?)	"如何可能"解释, 涌现 机制说明, 反事实路径 探索	生成充分性, 过程合理 性, 启发性价值 (Generative Sufficiency,

理解这些认知任务之间的区别与联系至关重要。例如，一个好的解释性模型通常也应该具备一定的描述和预测能力，但反之则不然：一个预测准确的模型可能完全缺乏解释力（所谓的“预测性陷阱”）。同样，一个揭示了“如何可能”机制的模型，并不一定能准确预测具体事件的发生。研究中常常存在**任务间的认识论张力**：追求高预测准确性的复杂模型可能牺牲**可理解性 (intelligibility)**；追求**简洁性 (simplicity)**的模型可能无法捕捉现实的全部复杂性，影响其**真实性 (realism)**；侧重输入-输出关系的描述/预测模型与侧重内部过程的解释/生成模型在构建和评估的逻辑上存在显著差异。因此，模型思维要求研究者在项目开始阶段就明确其主要认知目标，并围绕这个目标来选择模型类型、确定评估标准、并最终解释模型结果的意义和局限性。只有目标清晰，模型才能真正成为推动知识进步的有效工具。

模型的内在属性与认识论评估标准

在明确了模型的认识论本质、其在知识循环中的作用以及服务于不同认知目标之后，模型思维的下一个关键环节是如何对模型本身进行深入的审视和批判性的评估。这涉及到两个层面：一是理解模型的**内在结构属性 (intrinsic structural properties)**，即模型“是什么”；二是掌握评估模型认知价值的**认识论标准 (epistemological criteria)**，即判断模型“好不好”的依据。对这两个层面的清晰认知，是负责任地构建、使用和解读模型的基础。

首先，我们需要剖析模型的**内在结构属性**。任何模型，无论简单或复杂，都由一系列基本构成要素和特征组成。识别这些要素是理解模型行为和局限的前提。

- **假设集 (Set of Assumptions)**：这是模型构建的基石。所有模型都建立在一系列明确或隐含的假设之上，这些假设可能涉及本体论（例如，世界是由哪些基本实体构成

的?)、理论 (例如, 个体行为遵循何种原理?)、简化 (例如, 忽略哪些因素?)、或关于数据生成过程的假定。对这些假设进行清晰的陈述、辨识其性质 (哪些是核心假设, 哪些是辅助性或技术性假设?)、评估其合理性及其对模型结果可能产生的影响, 是评估模型有效性的第一步 (Levins, 1966; Mäki, 2009)。

- **抽象层次与粒度 (Level of Abstraction and Granularity)**: 模型是在哪个层次上描述目标系统的? 是宏观层面 (如国家间的关系)、中观层面 (如组织或社区) 还是微观层面 (如个体行为)? 模型捕捉的细节程度如何? 选择合适的抽象层次和粒度取决于研究问题和理论视角, 不同的选择会带来不同的洞察和局限。
- **范围与边界 (Scope and Boundaries)**: 模型声称能够解释或预测的现象范围是什么? 它适用于哪些特定的时间、空间、社会或文化背景? 明确模型的适用边界 (scope conditions) 对于避免过度泛化和误用至关重要 (Walker & Cohen, 1985)。
- **组件与关系 (Components and Relations)**: 模型包含哪些基本元素 (如变量、主体、节点)? 这些元素之间通过何种关系 (如数学方程、逻辑规则、网络连接) 相互作用? 这些关系的性质是确定性的还是随机性的? 是线性的还是非线性的? 这些结构性选择直接决定了模型的动态行为和潜在能力。
- **参数空间 (Parameter Space)**: 模型中包含哪些可以调整的参数? 这些参数的含义是什么? 它们是如何被估计或设定的 (基于数据拟合? 理论设定? 敏感性分析?)? 参数的取值范围和敏感性分析是理解模型行为和不确定性的关键。

理解了模型的内在属性之后, 我们才能进而讨论如何评估其**认识论价值 (epistemological value)**, 即模型在多大程度上能够增进我们的知识或理解。科学哲学和方法论文献中已经发展出一系列用于评估模型的**认知美德 (cognitive virtues)** 或标准 (Kuhn, 1981; Lacey, 1999; Douglas, 2013)。这些标准并非像数学定理那样具有绝对的客观性, 其应用和权重往往取决于研究的具体目标和语境, 但它们为我们提供了进行批判性评估的框架。以下是一些核心的认识论评估标准:

- **经验充分性/拟合优度 (Empirical Adequacy / Goodness-of-Fit)**: 这是最基本的要求之一, 即模型与其试图解释或预测的经验数据 (观测结果) 的一致程度。评估方式包括统计拟合指标、残差分析、模式匹配等。但需要警惕过度拟合 (overfitting) 的风险, 即模型过于紧密地拟合了样本数据中的噪音, 而失去了对总体规律的把握。
- **预测力/泛化能力 (Predictive Power / Generalizability)**: 模型不仅要能解释已知数据, 更重要的是能够准确预测未知或未来的数据。这体现了模型的泛化能力, 是衡量模型外部有效性的重要指标。通常通过交叉验证、样本外测试等方法来评估。
- **解释力 (Explanatory Power)**: 模型是否能够提供深刻的、令人信服的、通常是因果性的理解? 它能否揭示现象背后的机制? 能否统一看似无关的现象? 解释力强的模型不仅“知其然”, 更能“知其所以然”。评估解释力往往需要结合理论判断和对机制细节的考察。

- **简洁性/简约性 (Simplicity / Parsimony)**: 在其他条件（如解释力、预测力）相近的情况下，我们倾向于选择更简单的模型（奥卡姆剃刀原则, Occam's Razor）。简洁性体现在假设更少、结构更简单、参数更少等方面。简洁的模型通常更易于理解、分析和推广 (Forster & Sober, 1994)。但这并不意味着最简单的模型总是最好的，有时需要一定的复杂性才能捕捉现实的关键特征。
- **一致性 (Consistency)**: 包括内部一致性（模型自身逻辑无矛盾）和外部一致性（模型与同一领域内广泛接受的其他理论、知识或背景信念不冲突）。一个与现有知识体系严重冲突的模型，需要提供非常强的证据才能被接受 (Thagard, 1978)。
- **稳健性/稳定性 (Robustness / Stability)**: 一个好的模型，其核心结论不应过于依赖于某些特定的、可能不确定的假设、参数选择或数据输入的微小变动。稳健性分析（如改变假设、扰动参数、使用不同数据集）是检验模型结论可靠性的重要手段 (Wimsatt, 2012; Levins, 1966)。
- **可理解性/可解释性 (Intelligibility / Interpretability)**: 模型的内部工作机制和产生结果的过程，能够在多大程度上被人类研究者所理解？对于旨在提供解释的模型，或者需要在高风险领域（如医疗、司法）应用的预测模型，可解释性是一个重要的要求 (Lipton, 2018; Rudin, 2019)。复杂的“黑箱”模型在这方面面临挑战。
- **精确性 (Precision)**: 模型做出的预测或解释的明确程度如何？是定性的方向判断，还是定量的精确数值？更高的精确性通常意味着更强的可证伪性 (falsifiability) (Popper, 1959)，但也可能更容易被证伪。
- **启发性 (Heuristic Power / Fruitfulness)**: 模型是否能够激发新的研究问题、引导新的实验设计、提出新的概念框架或应用于新的领域？一个富有启发性的模型能够推动整个研究议程的发展，其价值可能超越其最初的拟合或预测能力 (Lakatos, 1970; Kuhn, 1981)。
- **有效性 (Validity)**: 这是一个 overarching 的概念，指模型在整体上是否达到了其声称的目标，是否真正测量或代表了它意图研究的构念或过程。有效性可以细分为多种类型，如**构念效度 (construct validity)**（模型操作化是否准确反映了理论构念？）、**内部效度 (internal validity)**（模型推断的因果关系在研究设定内是否成立？）、**外部效度 (external validity)**（模型结果能否推广到其他人群、情境或时间？）和**生态效度 (ecological validity)**（模型设定是否贴近真实的社会环境？）。对有效性的评估需要综合运用多种证据和判断。

下表总结了这些核心的认识论评估标准：

评估标准	核心问题
经验充分性 (Empirical Adequacy)	模型与数据的符合程度如何？
预测力/泛化能力 (Predictive Power)	模型对新数据的预测有多准确？

解释力 (Explanatory Power)	模型提供了多大程度的因果理解或机制洞察？
简洁性/简约性 (Simplicity/Parsimony)	模型是否足够简单（在假设、结构、参数方面）？
一致性 (Consistency)	模型内部逻辑是否自洽？是否与背景知识兼容？
稳健性/稳定性 (Robustness/Stability)	模型结论对假设或输入的微小变化是否不敏感？
可理解性/可解释性 (Intelligibility)	模型的运作和结果是否易于人类理解？
精确性 (Precision)	模型的预测或解释有多明确？
启发性 (Heuristic Power)	模型能否激发新的研究或应用？
有效性 (Validity)	模型是否真正测量/代表了其目标构念/过程？ (综合多种效度)

需要强调的是，这些评估标准之间可能存在冲突或需要权衡。例如，增加模型的复杂性可能提高拟合优度，但会降低简洁性和可解释性，甚至可能损害泛化能力。追求高度精确的预测可能需要使用难以解释的复杂算法。因此，**评估的语境依赖性 (context-dependency of evaluation)** 至关重要。对不同标准的侧重取决于模型的认知目标、研究领域的规范、数据的可用性以及研究的最终用途。不存在一个适用于所有情况的“完美模型”或单一的评估指标。模型思维要求研究者基于对这些标准的深刻理解，结合具体的研究情境，进行审慎的、多维度的、透明的评估与论证。

计算模型作为独特的认识论引擎

虽然模型思维的基本原理适用于所有类型的科学模型，但计算模型 (computational models)，特别是那些在计算社会科学中广泛应用的模拟模型 (如Agent-Based Modeling, ABM) 和复杂的机器学习模型，因其独特的性质，为传统的模型认识论带来了新的维度和挑战。理解计算模型的独特性，是充分发挥其潜力并规避其风险的关键。

首先，计算模型强调了一种**过程导向的认识论 (process-oriented epistemology)**。传统的社会科学模型 (如许多统计模型) 往往侧重于变量之间的相关关系或净效应，有时难以深入揭示导致这些关系的动态过程。计算模型，尤其是模拟模型，通过明确设定主体 (代理人) 的行为规则以及它们之间的互动方式，使得研究者能够观察和分析从微观互动到宏观模式

的**逐步演化过程 (step-by-step evolution)**。这种对过程的关注，补充了传统基于均衡或静态分析的视角，为理解社会现象的动态性、时间依赖性和路径依赖性提供了强大的工具 (Cederman, 2005; Sawyer, 2005)。

其次，计算模型，特别是生成性模型，突出了一种**生成性作为理解方式 (generativity as a mode of understanding)** 的认识论途径。正如 Epstein (1999) 的著名论断：“如果你不能让它生长出来，你就不能理解它 (If you didn't grow it, you didn't explain it)”。这种观点认为，对一个社会现象的深刻理解，不仅仅在于能够描述或预测它，更在于能够构建一个包含核心机制的模型，并让这个模型能够“自下而上”地**生成 (generate)** 出与目标现象相似的宏观模式。这种生成性的成功，被视为对所假设机制的一种强有力支持，尤其对于理解那些难以通过直接观察或还原分析来把握的**涌现现象 (emergent phenomena)** (如市场崩溃、社会规范形成、集体行为爆发) 至关重要 (Gilbert & Troitzsch, 2005)。

再次，计算模型的**可执行性 (executability)** 使其成为进行“**数字实验 (digital experimentation)**”的独特平台。与只能进行一次性推导的数学模型或难以精确控制的物理实验不同，计算模型可以被反复运行。研究者可以系统地探索广阔的**参数空间 (parameter space)**，进行**敏感性分析 (sensitivity analysis)**，考察不同初始条件或随机因素对结果的影响。更重要的是，可以在模型世界中进行受控的**干预实验 (intervention experiments)** 和**反事实分析 (counterfactual analysis)**，即探索“如果.....会怎样？”的问题 (Pearl, 2009)。例如，模拟不同政策干预对社会不平等的影响，或者比较不同网络结构对信息传播效率的作用。这种通过模拟进行的实验，极大地拓展了我们探索因果关系和系统行为的能力，超越了传统思想实验的局限性 (Humphreys, 2004; Winsberg, 2009)。

此外，计算模型的广泛应用也推动了**算法思维 (algorithmic thinking)** 在社会科学中的渗透。这种思维方式强调将社会过程理解为一系列可被形式化描述的**规则 (rules)**、**步骤 (steps)** 和**信息处理过程 (information processing)**。它关注过程的逻辑、效率和可计算性。将社会现象“算法化”本身就是一种特定的认识论视角，它可能揭示传统理论框架未能注意到的结构和动态，但也可能因过度简化或技术决定论而带来风险 (Elish, 2016; Kitchin, 2017)。


同时，计算模型，特别是那些能够整合大量异质性个体、复杂互动网络和非线性反馈回路的模型，为**处理复杂性 (addressing complexity)** 提供了前所未有的途径 (Miller & Page, 2007)。传统分析方法往往难以处理这类系统性特征。计算模型通过模拟，使得研究者能够直接观察和分析复杂系统中的涌现行为、临界点、自组织现象等，挑战了传统社会科学中基于线性思维和平均主义假设的研究范式 (Urry, 2005)。

然而，计算模型的强大能力也伴随着独特的认识论挑战。

- **“黑箱”问题 (The "Black Box" Problem)**: 许多先进的计算模型，特别是深度学习等机器学习模型，虽然可能具有很高的预测精度，但其内部运作机制极其复杂，难以被人类研究者直观理解和解释。这给需要透明度和问责制的解释性任务或高风险决策带来了严峻挑战。追求模型的可解释性 (Explainable AI, XAI) 已成为一个重要的研究方向 (Adadi & Berrada, 2018)。
- **模拟与现实的鸿沟 (The Gap Between Simulation and Reality)**: 对于复杂的模拟模型，如何验证其结果的有效性是一个难题。模型可能在内部逻辑上是自洽的，甚至能生成看似合理的模式，但这并不保证它真实地反映了现实世界的运作方式。模型的**验证 (validation)** (模型是否准确代表了目标系统?) 和**确认 (verification)** (模型代码是否正确实现了设计意图?) 是计算建模中持续存在的挑战 (Kleindorfer & Ganeshan, 1993; Sargent, 2013)。需要结合经验数据校准、模式匹配、专家判断等多种方法进行严格的评估。
- **过度拟合与虚假发现的风险 (Risks of Overfitting and Spurious Discovery)**: 计算模型 (尤其是数据驱动的机器学习模型) 与大规模数据的结合，增加了发现虚假关联或模式的风险。模型可能过度拟合样本数据的噪音，或者在海量探索中偶然发现统计上显著但无实际意义的模式。这要求研究者在使用复杂模型和大数据时，采取更加严格的统计推断标准、模型验证程序和理论审视 (Calude & Longo, 2017)。

模型思维是贯穿计算社会科学研究始终的核心认知能力。它要求研究者深刻理解模型的本质是作为认知中介的抽象建构，认识到模型在连接理论与数据、驱动知识生产中的多重角色，能够根据不同的认知目标 (描述、预测、解释、生成) 选择和评估模型，并掌握一套包含经验充分性、解释力、简洁性、稳健性等多维度在内的认识论评估标准。特别地，在计算社会科学时代，模型思维还需要融入对计算模型独特优势 (如过程导向、生成性、可执行性) 和挑战 (如黑箱问题、验证困境) 的理解。唯有具备深厚且具批判性的模型思维，研究者才能有效地运用模型这一强大工具，在复杂的社会世界中探索真知，并为应对现实挑战贡献有价值的洞见。下一部分将进入方法论介绍，该部分将尽可能全面地介绍传统社会科学 with 计算社会科学所涉及的核心概念、方法体系与应用。

参考文献



Adadi, Amina, and Mohammed Berrada. 2018. "Peeking Inside the Black-Box: A Survey on Explainable Artificial Intelligence (XAI)." *IEEE Access* 6: 52138–60. doi:10.1109/ACCESS.2018.2870052.

Axelrod, Robert. 1997. "The Dissemination of Culture: A Model with Local Convergence and Global Polarization." *The Journal of Conflict Resolution* 41(2): 203–26. doi:10.1177/0022002797041002001.

Bail, Christopher A. 2014. "The Cultural Environment: Measuring Culture with Big Data." *Theory and Society* 43(3): 465–82. doi:10.1007/s11186-014-9216-5.

Bas, C. Van Fraassen. 1980. *The Scientific Image*. New York: Oxford University Press.

Blalock, Hubert M. & Ann B. 1968. *Methodology in Social Research*. Later printing edition. New York: London: McGraw-Hill.

Box, George E. P. 1976. "Science and Statistics." *Journal of the American Statistical Association* 71(356): 791–99. doi:10.1080/01621459.1976.10480949.

Breiman, Leo. 2001. "Random Forests." *Machine Learning* 45(1): 5–32. doi:10.1023/A:1010933404324.

Calude, Cristian S., and Giuseppe Longo. 2016. "The Deluge of Spurious Correlations in Big Data." *Foundations of Science* 22(3): 595–612. doi:10.1007/s10699-016-9489-4.

Cartwright, Nancy. 1983. *How the Laws of Physics Lie*. New York: Oxford University Press.

Cartwright, Nancy. 1989. *Nature's Capacities and Their Measurement*. New York: Oxford University Press.

Craver, Carl F. 2006. "When Mechanistic Models Explain." *Synthese* 153(3): 355–76. doi:10.1007/s11229-006-9097-x.

Craver, Carl F. 2013. *In Search of Mechanisms: Discoveries Across the Life Sciences*. ed. Lindley Darden. London: University of Chicago Press.

Forster, Malcolm, and Elliott Sober. 1994. "How to Tell When Simpler, More Unified, or Less Ad Hoc Theories Will Provide More Accurate Predictions." *The British Journal for the Philosophy of Science* 45(1): 1–35.

Frigg, Roman. 2007. "Models and Fiction." *Synthese* 172(2): 251–68. doi:10.1007/s11229-009-9505-0.

Frigg, Roman, and Stephan Hartmann. 2006. "Models in Science." <https://plato.sydney.edu.au/entries/models-science/> (May 12, 2025).

Giere, Ronald N. 1990. *Explaining Science*. University of Chicago Press.

Giere, Ronald N. 1999. *Science without Laws*. 1st edition. Chicago: University of Chicago Press.

Godfrey-Smith, Peter. 2006. "The Strategy of Model-Based Science." *Biology and Philosophy* 21(5): 725–40. doi:10.1007/s10539-006-9054-6.

Harris, William A. 1997. "On 'Scope Conditions' in Sociological Theories." *Social and Economic Studies* 46(4): 123–27.

Hastie, Trevor, Robert Tibshirani, and Jerome Friedman. 2009. "Overview of Supervised Learning." In *The Elements of Statistical Learning: Data Mining, Inference, and Prediction*. New York: Springer.

mining, Inference, and Prediction, eds. Trevor Hastie, Robert Tibshirani, and Jerome Friedman. New York, NY: Springer, 9–41. doi:10.1007/978-0-387-84858-7_2.

Hedström, Peter, and Petri Ylikoski. 2010. "Causal Mechanisms in the Social Sciences." *Annual Review of Sociology* 36(Volume 36, 2010): 49–67. doi:10.1146/annurev.soc.012809.102632.

Hempel, Carl Gustav. 1965. *Aspects of Scientific Explanation and Other Essays in the Philosophy of Science*. New York: The Free Press.

Herfeld, Catherine. 2018. "Explaining Patterns, Not Details: Reevaluating Rational Choice Models in Light of Their Explananda." *Journal of Economic Methodology* 25(2): 179–209. doi:10.1080/1350178X.2018.1427882.

Hesse, Mary B. 1966. *Models and Analogies in Science*. University of Notre Dame Press.

Humphreys, Paul. 2004. *Extending Ourselves: Computational Science, Empiricism, and Scientific Method*. New York, US: Oxford University Press.

Kitchin, Rob. 2017. "Thinking Critically about and Researching Algorithms." *Information, Communication & Society* 20(1): 14–29. doi:10.1080/1369118X.2016.1154087.

Kuhn, Thomas S. 1981. "Objectivity, Value Judgment, and Theory Choice." In *Review of Thomas S. Kuhn The Essential Tension: Selected Studies in Scientific Tradition and Change*, ed. David Zaret. Duke University Press, 320–39.

Lakatos, I. 1970. "Falsification and the Methodology of Scientific Research Programmes." In *Criticism and the Growth of Knowledge: Proceedings of the International Colloquium in the Philosophy of Science, London, 1965*, eds. Alan Musgrave and Imre Lakatos. Cambridge: Cambridge University Press, 91–196. doi:10.1017/CB09781139171434.009.

Levins, Richard. 1966. "The Strategy of Model Building in Population Biology." *American Scientist* 54(4): 421–31.

Lipton, Zachary C. 2018. "The Mythos of Model Interpretability: In Machine Learning, the Concept of Interpretability Is Both Important and Slippery." *Queue* 16(3): 31–57. doi:10.1145/3236386.3241340.

MacKay, David J. C. 2003. *Information Theory, Inference and Learning Algorithms*. Illustrated edition. Cambridge: Cambridge University Press.

Mäki, Uskali. 2009. "Economics Imperialism: Concept and Constraints." *Philosophy of the Social Sciences* 39(3): 351–80. doi:10.1177/0048393108319023.

Mayo, Deborah G. 1996. *Error and the Growth of Experimental Knowledge*. 1st edition. Chicago: University of Chicago Press.

McMullin, Ernan. 1985. "Galilean Idealization." *Studies in History and Philosophy of Science Part A* 16(3): 247. doi:10.1016/0039-3681(85)90003-2.

Miller, John H., and Scott E. Page. 2007. *Complex Adaptive Systems: An Introduction to Computational Models of Social Life*. Princeton, NJ, US: Princeton University Press.

Morgan, D. L. 1998. "Practical Strategies for Combining Qualitative and Quantitative Methods: Applications to Health Research." *Qualitative Health Research* 8(3): 362–76. doi:10.1177/104973239800800307.

Morgan, Mary S., and Tarja Knuuttila. 2012. "Models and Modelling in Economics." In ed. Uskali Mäki. Elsevier (Firm), 49–87. http://www.elsevier.com/wps/find/homepage.cws_home (May 12, 2025).

Nowak, Andrzej, and Robin R. Vallacher. 1998. *Dynamical Social Psychology*. New York, NY, US: Guilford Press.

Pearl, Judea. 2009. *Causality: Models, Reasoning and Inference*. 2nd edition. Cambridge, U.K. ; New York: Cambridge University Press.

Popper, Karl R. 1959. *The Logic of Scientific Discovery*. Oxford, England: Basic Books.

Reiss, Peter C. 2011. "Structural Workshop Paper—Descriptive, Structural, and Experimental Empirical Methods in Marketing Research." *Marketing Science* 30(6): 950–64. doi:10.1287/mksc.1110.0681.

Rudin, Cynthia. 2019. "Stop Explaining Black Box Machine Learning Models for High Stakes Decisions and Use Interpretable Models Instead." *Nature Machine Intelligence* 1(5): 206–15. doi:10.1038/s42256-019-0048-x.

Sargent, Robert G. 2007. "Verification and Validation of Simulation Models." In *Proceedings of the 39th Conference on Winter Simulation: 40 Years! The Best Is yet to Come, WSC '07*, Washington D.C.: IEEE Press, 124–37.

Sargent, Thomas J. 2013. *Rational Expectations and Inflation* (Third Edition). Princeton University Press. <https://www.jstor.org/stable/j.ctt2jc97n> (May 12, 2025).

Sawyer, R. Keith. 2005. *Social Emergence: Societies As Complex Systems*. Cambridge: Cambridge University Press.

Schelling, Thomas C. 1971. "Dynamic Models of Segregation†." *Journal of Mathematical Sociology* 1(2): 143–86. doi:10.1080/0022250X.1971.9989794.

Shmueli, Galit. 2010. "To Explain or to Predict?" *Statistical Science* 25(3): 289–310. doi:10.1214/10-STS330.

Suárez, Mauricio. 2004. "An Inferential Conception of Scientific Representation." *Philosophy of Science* 71(5): 767–79. doi:10.1086/421415.

Suppes, Patrick. 1960. "A Comparison of the Meaning and Uses of Models in Mathematics and the Empirical Sciences." *Synthese* 12(2): 287–301. doi:10.1007/BF00485107.

Sutton, Robbie, and Karen Douglas. 2013. *Social Psychology*. New York, NY: Palgrave Macmillan/Springer Nature. doi:10.1007/978-1-137-29968-0.

Thagard, Paul R. 1978. "The Best Explanation: Criteria for Theory Choice." *Journal of Philosophy* 75(2): 76–92. doi:10.2307/2025686.

Weisberg, Michael. 2007. "Three Kinds of Idealization." *Journal of Philosophy* 104(12): 639–59. doi:10.5840/jphil20071041240.

Weisberg, Michael. 2015. *Simulation and Similarity: Using Models to*

Understand the World. Reprint edition. Oxford: Oxford University Press.
Wimsatt, William C. 2007. Re-Engineering Philosophy for Limited Beings: Piecewise Approximations to Reality. Cambridge: Harvard University Press.

Wimsatt, William C. 2012. "Robustness, Reliability, and Overdetermination." In Characterizing the Robustness of Science: After the Practice Turn in Philosophy of Science, ed. Lena Soler. Springer Verlag, 61-78.

Winsberg, Eric. 2009. "Computer Simulation and the Philosophy of Science." Philosophy Compass 4(5): 835-45. doi:10.1111/j.1747-

目录

- └── 方法论基础：通用的研究流程与核心概念
 - └── 计算社会科学研究迭代生命周期的核心阶段与循环反馈
 - └── 阶段一：研究启动与规划
 - | └── 问题定义与精炼
 - | └── 可行性评估与研究设计初步
 - └── 阶段二：数据获取与系统准备
 - | └── 数据收集与获取
 - | └── 数据检视与评估
 - | └── 数据预处理与转换
 - └── 阶段三：探索性分析与模型构建
 - | └── 探索性数据分析
 - | └── 模型/方法选择与设计
 - | └── 模型实现与参数校准
 - └── 阶段四：评估、解释与迭代优化
 - | └── 模型评估与验证
 - | └── 结果解释与理论关联
 - | └── 迭代与优化
 - └── 阶段五：沟通、影响与知识贡献
 - | └── 知识封装与成果沟通
 - | └── 可重复性、可复制性与开放科学
 - | └── 伦理反思与社会影响评估
 - | └── 知识存档与未来研究展望
 - └── 结语：研究的迭代循环与研究者的成长

计算社会科学作为一门融合了社会科学理论洞察与计算机科学方法创新的交叉学科，其研究过程既遵循科学探究的一般逻辑，也展现出由数据密集型和计算驱动型特征所带来的独特性。理解并遵循一个结构化的研究生命周期，对于确保研究的系统性、严谨性和可重复性至关重要 (King, Keohane, & Verba, 1994)。然而，与传统观念中严格线性的研究流程不同，计算社会科学的研究实践更像是一个动态的、高度迭代的循环过程 (Lazer et al., 2009; Salganik, 2018)。

传统的知识发现流程模型，如数据挖掘领域的知识发现数据库 (Knowledge Discovery in Databases, KDD) 过程 (Fayyad, Piatetsky-Shapiro, & Smyth, 1996) 和跨行业数据挖掘标准流程 (Cross-Industry Standard Process for Data Mining, CRISP-DM) (Chapman et al., 2000)，都

强调了从数据理解到模型部署的多个阶段，并内含了反馈循环。这些模型为我们理解数据驱动的研究提供了有益的框架。

例如，CRISP-DM 模型将数据挖掘项目划分为商业理解、数据理解、数据准备、建模、评估和部署六个阶段，并允许在各阶段之间灵活跳转。KDD 过程则概括为数据选择、预处理、转换、数据挖掘和解释/评估等步骤。

借鉴这些成熟的研究生命周期模型，并结合社会科学研究特有的理论驱动、问题导向以及对因果解释和社会意义的追求 (Babbie, 2020)，我们可以勾勒出一个适用于计算社会科学的、包含核心组件的理想化迭代研究生命周期。这个生命周期并非一个僵硬的模板，而是一个指导性的框架，强调在各个阶段研究者都需要保持灵活性、适应性和持续的批判性反思 (Alvesson & Sandberg, 2011)。后续的发现、遇到的挑战或新的洞见，都可能促使研究者重访并修正早期阶段的决策，形成一个螺旋式上升的认知与实践过程。本节将这一生命周期划分为五个核心阶段：研究启动与规划、数据获取与系统准备、探索性分析与模型构建、评估解释与迭代优化，以及沟通影响与知识贡献。每个阶段内部又包含若干关键子步骤，它们共同构成了计算社会科学探究的完整图景。

下表简要对比了 KDD、CRISP-DM 与《无算之策》总结的 CSS 研究生命周期在核心阶段上的对应关系，以期展现其共性与 CSS 的特性：

表：不同研究生命周期模型的阶段对比

KDD Process (Fayyad et al., 1996)	CRISP-DM (Chapman et al., 2000)	CSS 研究生命周期 (《无算之策》)	核心侧重
(隐含于问题定义)	商业理解 (Business Understanding)	研究启动与规划 (问题定义、可行性评估、初步设计)	理论驱动的问题形成，社会科学意义，伦理考量，多维度可行性分析
数据选择 (Selection)	数据理解 (Data Understanding)	数据获取与系统准备 (数据收集、检视、评估)	多源异构数据获取策略，数据质量深度评估，元数据管理，伦理合规执行
预处理 (Preprocessing)	数据准备 (Data Preparation)	数据获取与系统准备 (数据预处理与转换)	针对社会数据的复杂清洗、转换、特征工程，确保分析就绪性
		数据获取与系统准备 (数据预处理与转换) /	

转换 (Transformation)	数据准备 (Data Preparation)	探索性分析与模型构建 (特征工程)	同上，并强调服务于模型构建的特征创造
数据挖掘 (Data Mining)	建模 (Modeling)	探索性分析与模型构建 (EDA、模型选择与设计、模型实现与校准)	结合理论的 EDA，多元模型选择（统计、ML、模拟），模型假设与社会过程的关联，参数校准的理论意义
解释/评估 (Interpretation/Evaluation)	评估 (Evaluation)	评估、解释与迭代优化 (模型评估与验证、结果解释与理论关联、迭代优化)	多维度评估（性能、稳健性、可解释性），社会科学意义阐释，理论对话，持续的迭代改进
(隐含于知识应用)	部署 (Deployment)	沟通、影响与知识贡献 (知识封装、可重复性、伦理反思、知识存档)	学术与社会沟通，强调可重复性与开放科学，研究的社会责任与长远影响，知识的积累与传承

接下来，我们将详细阐述计算社会科学研究生命周期的各个阶段及其核心任务。

本小节参考文献：

Alvesson, Mats, and Jörgen Sandberg. 2011. "Generating Research Questions through Problematization." *The Academy of Management Review* 36(2): 247-71. doi:10.5465/AMR.2011.59330882

Babbie, Earl. 2021. *The Practice of Social Research*. Boston, MA: Cengage Learning.

Chapman, P. 2000. "CRISP-DM 1.0: Step-by-Step Data Mining Guide." <https://www.semanticscholar.org/paper/CRISP-DM-1.0%3A-Step-by-step-data-mining-guide-Chapman/54bad20bbc7938991bf34f86dde0babfbd2d5a72> (March 14, 2025).

Fayyad, Usama, Gregory Piatetsky-Shapiro, and Padhraic Smyth. 1996. "From Data Mining to Knowledge Discovery in Databases." *AI Magazine* 17(3): 37-37. doi:10.1609/aimag.v17i3.1230

King, Gary, Robert O. Keohane, and Sidney Verba. 1994. *Designing Social Inquiry: Scientific Inference in Qualitative Research*. Princeton, N.J: Princeton University Press.

Lazer, David, Alex Pentland, Lada Adamic, Sinan Aral, Albert-László Barabási, Devon Brewer, Nicholas Christakis, et al. 2009.

"Computational Social Science." *Science* 323(5915): 721-23. doi:10.1126/science.1167742

阶段一：研究启动与规划

研究的启动与规划是整个计算社会科学探究过程的基石，其质量直接决定了后续工作的方向、效率和最终价值。这一阶段的核心任务在于清晰地定义研究问题，系统地评估其可行性，并勾勒出初步的研究设计蓝图。它要求研究者不仅具备敏锐的问题意识和扎实的理论素养，还需要对计算方法、数据资源和伦理规范有初步的把握。

问题定义与精炼

科学研究始于有意义的问题 (Popper, 2002)。在计算社会科学领域，一个好的研究问题往往源于对现实社会现象的深刻观察、对现有社会科学理论的批判性思考，或是对计算方法应用于社会研究所能带来新洞见的敏锐预判 (Lazer et al., 2009)。**从广泛议题到可研究问题的转化**是此阶段的首要任务。研究者可能从一个宽泛的兴趣领域（如社交媒体上的信息传播、城市中的社会不平等、在线社群的集体行为）出发，通过不断聚焦和具体化，将其提炼为一个或一组清晰、明确、可探究的研究问题 (Booth, Colomb, & Williams, 2008)。这一过程并非一蹴而就，往往需要在理论学习、文献回顾和初步观察之间反复迭代。

文献回顾与理论对话在此过程中扮演着至关重要的角色。系统的文献回顾不仅仅是对前人研究成果的简单罗列，更是一次深度融入学术共同体对话的智力旅程。研究者需要系统梳理相关社会科学理论（如社会网络理论、集体行动理论、组织社会学、传播学理论等），理解这些理论对所关注现象的核心解释、关键概念和主要争议。同时，也需要关注计算社会科学领域内已有的相关研究，了解哪些计算方法（如网络分析、自然语言处理、机器学习、主体建模）已被用于研究类似问题，取得了哪些进展，又面临哪些局限 (Salganik, 2018; Cioffi-Revilla, 2014)。通过深入的文献回顾，研究者能够更准确地**识别现有知识的空白 (knowledge gaps)、理论的未解之谜或内在张力 (theoretical puzzles or tensions)**，以及**已有研究在方法论上的不足 (methodological limitations)**。这将有助于将自己的研究问题清晰地**定位于现有知识体系之中**，并明确其潜在的**理论贡献、经验贡献或方法论贡献** (Bryman, 2016)。一个与现有理论和文献完全脱节的研究问题，即使技术上可行，也可能因缺乏学术对话的根基而难以产生深远影响。

在文献回顾和理论对话的基础上，研究问题需要进一步**具体化 (specification)**，并初步思考其**操作化 (operationalization)** 的可能性。这意味着要将问题中的核心抽象概念（如“影响力”、“社会资本”、“极化”、“福祉”）思考如何转化为可观察、可测量、可计算的指标或变量 (Goertz, 2006)。例如，如果研究“社交媒体对政治极化的影响”，就需要思考“政治极化”

可以如何通过用户的关注网络、发帖内容的情感倾向或观点分布等数字痕迹来测量。这种初步的操作化思考，有助于判断研究问题在经验层面上的可处理性。最终，研究者应力求形成**清晰、简洁、具有焦点 (focused) 的研究问题陈述**。好的研究问题通常是能够引导后续研究设计，并且其答案能够对知识体系有所增益的 (King, Keohane, & Verba, 1994)。

同时，需要明确**研究的主要目标 (research objectives)** 是什么，以及期望通过研究获得什么样的**预期成果 (expected outcomes)**。研究目标可能包括：**描述 (description)** 一个现象的特征、分布或模式（例如，描绘特定人群在线信息获取行为的图谱）；**解释 (explanation)** 现象发生的原因、机制或后果（例如，探究算法推荐对用户观点多样性的因果影响）；**预测 (prediction)** 未来的趋势或事件发生的可能性（例如，预测哪些在线社群更容易出现极端言论）；或是**探索可能性/生成 (exploration/generation)**，即通过模拟等方式理解某种宏观模式是如何从微观互动中涌现的（例如，模拟不同社会互动规则下合作规范的形成）。明确认知目标有助于后续选择合适的研究方法和评估标准 (Shmueli, 2010)。

当研究旨在检验特定理论或已有经验发现时，研究者会在问题定义的基础上进一步构建**具体的、可检验的假设 (testable hypotheses)**。假设是对研究问题答案的初步预期陈述，通常表述为变量之间的预期关系 (Babbie, 2020)。例如，“在控制其他因素的情况下，社交媒体使用频率越高，个体感知到的社会支持越多”。假设的构建需要有坚实的理论基础或充分的先验证据支持。然而，并非所有计算社会科学研究都始于明确的假设，特别是那些探索性较强、旨在从数据中发现模式或生成新理论的研究 (Glaser & Strauss, 1967)。在这种情况下，清晰的研究问题比具体的假设更为重要。问题定义与精炼是一个高度智力密集型的过程，它要求研究者在社会科学理论的深度、计算思维的广度与经验现实的复杂性之间进行创造性的联结。一个经过深思熟虑、界定清晰的研究问题，是成功研究的起点和罗盘。

可行性评估与研究设计初步

在清晰定义了研究问题和目标之后，接下来的关键步骤是对研究的整体可行性进行系统评估，并在此基础上勾勒出初步的研究设计框架。这一步骤旨在确保研究计划在现实条件下是可执行的，并且能够在预期的资源约束内达成研究目标。可行性评估需要从数据、方法、伦理、资源等多个维度进行综合考量。

首先，**数据可获得性与适用性评估 (Data Availability and Suitability Assessment)** 是计算社会科学研究可行性评估的核心。研究者需要初步探查可能用于回答研究问题的数据来源。这些数据可能包括**现有的公开数据集**（如政府开放数据、国际组织数据库、学术数据档案库，后文会详细介绍）、**通过 API 获取的平台数据**（如社交媒体数据、搜索引擎数据）、**需要通过网络爬虫自行采集的网页数据**，或者是**通过数字实验、在线调查等方式主动收集的**

一手数据 (Salganik, 2018)。针对每一种潜在数据源，需要评估其与研究问题的**相关性 (relevance)**——数据是否包含了研究所需的核心变量或信息？其次是数据的**潜在覆盖范围与代表性 (coverage and representativeness)**——数据能够代表哪些人群、时间段或社会情境？是否存在已知的系统性偏差（如数字鸿沟导致的样本偏差、平台用户特征偏差）？此外，还需要初步评估数据的**质量 (quality)**（如准确性、完整性、一致性）、**获取难度与成本 (accessibility and cost)**，以及获取和使用数据所涉及的法律与伦理限制 (**legal and ethical constraints**) (boyd & Crawford, 2012)。如果现有数据不足或不适用，研究者需要规划切实可行的数据收集策略，并评估其所需的时间和资源。

其次，**方法论路径初步选择 (Initial Methodological Path Selection)** 也至关重要。基于研究问题的性质（描述、解释、预测、生成）、数据的类型与特征（结构化/非结构化、大规模/小样本、截面/时序/面板），以及研究者的技能储备，需要初步考虑采用哪些计算分析方法。可能的选项非常广泛，包括传统的统计建模 (Gelman & Hill, 2006)、机器学习算法 (Hastie, Tibshirani, & Friedman, 2009)、自然语言处理技术 (Jurafsky & Martin, 2023)、社会网络分析方法 (Wasserman & Faust, 1994)、主体建模与仿真，或是这些方法的组合。在初步选择方法时，不仅要考虑其技术先进性，更要评估其是否与研究的理论框架和认知目标相契合，以及其结果是否具有可解释性。同时，需要初步评估所选方法对**计算资源的需求**，包括硬件、软件以及具备相关技能的人力。

第三，**伦理考量与合规性规划 (Ethical Considerations and Compliance Planning)** 必须贯穿研究设计的始终，并在规划阶段就得到充分重视。计算社会科学研究，特别是涉及大规模人类行为数据（尤其是数字痕迹数据）的研究，面临着诸多复杂的伦理挑战 (Floridi et al., 2018; Vitak, Shilton, & Ashktorab, 2016)。研究者需要主动识别研究计划中潜在的伦理风险，例如：**隐私侵犯**（如何保护个体身份不被泄露？）、**数据偏见导致的算法歧视**（模型是否会不成比例地损害特定群体的利益？）、**知情同意的获取**（在使用公开数据或平台数据时，何为恰当的知情同意标准？）、**研究结果的潜在误用**等。在初步规划阶段，就需要了解并遵守相关的**法律法规**以及所在机构的**伦理审查委员会 (Institutional Review Board, IRB 或 Research Ethics Committee, REC)** 的要求。规划初步的**数据安全保障措施**（如数据加密、访问控制）和**数据匿名化/去标识化策略**也应提上日程。确保研究从一开始就符合伦理规范，不仅是研究者的责任，也是保障研究可持续性和社会信任的基础。

第四，实际的**时间、资源与团队规划 (Time, Resource, and Team Planning)** 也不可或缺。基于对数据获取、方法实施、伦理审查等环节的初步评估，研究者需要制定一个现实的**研究时间表 (timeline)**，明确各个阶段的主要任务和预期完成时间。同时，需要估算研究所需的**预算**，包括数据购买、软件许可、计算资源使用、人员薪酬、会议差旅等费用。如果研究需要团队协作，还需要明确**团队成员的角色与分工 (team roles and responsibilities)**，确保成员技能互补，沟通顺畅。

最后，进行**风险评估与应对策略**的思考。预估在研究过程中可能遇到的主要挑战和障碍，例如数据获取失败、关键技术难题、伦理审查受阻、核心成员变动、研究结果不符合预期等。针对这些潜在风险，应初步思考相应的应对预案，以增强研究计划的韧性。

可行性评估与初步研究设计是一个动态的、需要权衡的过程。有时，评估结果可能会显示最初设想的研究问题或方法路径并不可行，这时就需要返回到问题定义阶段进行调整，甚至重新构思。只有当研究问题被认为具有重要的学术或社会价值，并且在数据、方法、伦理和资源方面都具备基本可行性时，才能稳妥地进入下一阶段。这个阶段的产出通常是一个相对完整的**研究计划书 (research proposal)**，它将指导后续所有研究活动的开展。

本小节参考文献:

- Babbie, Earl. 2021. *The Practice of Social Research*. Boston, MA: Cengage Learning.
- Booth, Wayne C., Gregory G. Colomb, and Joseph M. Williams. 2008. *The Craft of Research*, Third Edition. Third edition. Chicago: University of Chicago Press.
- Boyd, Danah, and Kate Crawford. 2012. "Critical Questions for Big Data: Provocations for a Cultural, Technological, and Scholarly Phenomenon." *Information, Communication & Society* 15(5): 662-79. doi:10.1080/1369118X.2012.678878
- Bryman, Alan. 2015. *Social Research Methods*. 5th edition. Oxford: OUP Oxford.
- Cioffi-Revilla, Claudio. 2017. *Introduction to Computational Social Science: Principles and Applications*. 2nd ed. 2017 edition. New York, NY: Springer.
- Gelman, Andrew, and Jennifer Hill. 2021. *Data Analysis Using Regression and Multilevel/Hierarchical Models*. Cambridge: Cambridge University Press.
- Glaser, Barney G., and Anselm L. Strauss. 1980. *The Discovery of Grounded Theory: Strategies for Qualitative Research*. New York: Aldine Pub. Co.
- Goertz, Gary. 2006. *Social Science Concepts: A User's Guide*. Princeton University Press. doi:10.2307/j.ctvc4gmg
- Hastie, Trevor, Robert Tibshirani, and Jerome Friedman. 2017. *The Elements of Statistical Learning: Data Mining, Inference, and Prediction*, Second Edition. New York, NY: Springer.
- Jurafsky, Daniel, and James Martin. 2008. *Speech and Language Processing*, 2nd Edition. 2nd edition. Upper Saddle River, NJ: Prentice Hall.
- King, Gary, Robert O. Keohane, and Sidney Verba. 1994. *Designing Social Inquiry: Scientific Inference in Qualitative Research*. Princeton, N.J: Princeton University Press.
- Lazer, David, Alex Pentland, Lada Adamic, Sinan Aral, Albert-László Barabási, Devon Brewer, Nicholas Christakis, et al. 2009. "Computational Social Science." *Science* 323(5915): 721-23. doi:10.1126/science.1167742
- Popper, Karl. 2002. *The Logic of Scientific Discovery*. 2nd edition. London: Routledge.
- Salganik, Matthew J. 2018. *Bit by Bit: Social Research in the Digital Age*. Princeton, NJ, US: Princeton University Press.
- Shmueli, Galit. 2010. "To Explain or to Predict?" *Statistical Science* 25(3): 289-310. doi:10.1214/10-STS330

阶段二：数据获取与系统准备

在完成了研究问题的清晰界定和可行性评估之后，计算社会科学研究便进入了实质性的数据获取与系统准备阶段。这一阶段的核心任务是依据研究设计，系统性地收集或获取所需数据，并对这些数据进行初步的检视、评估和基础性的预处理，为后续的深入分析奠定坚实的数据基础。同时，也需要搭建和配置必要的计算环境和工具。

数据收集与获取

数据收集与获取是计算社会科学研究的生命线，数据的质量和适切性直接关系到研究结论的有效性和可靠性。**执行在规划阶段制定的数据收集计划**是本环节的首要任务。具体的数据获取方式多种多样，取决于研究问题、数据来源的性质以及研究者的技术能力和资源。

对于利用**现有数据资源**的研究，可能涉及从**开放数据平台**下载数据集，或者通过学术合作、数据使用协议等方式获取特定的**私有数据集或商业数据**。研究者需要仔细阅读并遵守数据提供方设定的使用条款和许可协议。

当研究需要**通过数字平台获取数据**时，利用**应用程序编程接口 (Application Programming Interfaces, APIs)** 是一种常见且规范的方式。许多大型社交媒体平台（如 X/Twitter、Reddit 等）、内容分享网站和数字服务提供商都提供 API，允许研究者以结构化的方式查询和下载特定类型的数据 (Bruns & Stieglitz, 2013)。使用 API 通常需要注册开发者账户、获取访问凭证，并遵守平台设定的调用频率限制和数据使用政策。研究者需要编写脚本（通常使用 Python、R 等语言）来与 API 交互，自动化数据拉取过程。

在某些情况下，如果目标数据无法通过 API 获取，或者 API 提供的粒度和范围不能满足研究需求，研究者可能会考虑使用**网络爬虫 (Web Scraping)** 技术。网络爬虫是自动从网页上抓取信息的程序。虽然网络爬虫提供了获取大量公开网络数据的灵活性，但其使用必须极为审慎。研究者需要严格遵守网站的 `robots.txt` 文件（该文件声明了网站所有者允许或禁止爬虫访问的路径）和服务条款。不规范的爬取行为可能对目标网站服务器造成过大负担，甚至引发法律纠纷或伦理争议。因此，设计爬虫时应考虑设置合理的抓取频率、模拟人类浏览行为，并尽可能减少对服务器的影响。

对于需要探究因果关系或特定干预效果的研究，设计并实施**数字实验 (Digital Experiments)** 或**在线 A/B 测试**可能更为合适。研究者可以在真实的数字环境（如社交媒体平台、在线劳动力市场、电商网站）中，通过随机分配不同的处理条件（如信息呈现方式、界面设计、算法推荐策略）给用户，来观察和测量其行为或态度的差异 (Kohavi, Tang, & Xu, 2020)。数字实验的实施需要与平台方合作或利用允许进行此类实验的特定工具。

传统的社会科学数据收集方法，如**在线调查 (Online Surveys)**，在计算社会科学中依然有其用武之地。利用 Qualtrics, SurveyMonkey, Amazon Mechanical Turk 等工具，研究者可以设计和分发问卷，收集关于个体态度、信念、行为自述等信息，这些信息往往难以从数字痕迹中直接获得 (Couper, 2000)。在线调查可以与数字痕迹数据相结合，提供更全面的视角。

无论采用何种数据收集方式，都必须确保整个过程的**规范性 (rigor) 与记录完整性 (thorough documentation)**。这包括详细记录数据来源、收集时间、所用工具或脚本的版本、API 端点和参数、爬虫的种子 URL 和抓取逻辑、实验的设计方案和实施细节、调查问卷的版本和抽样框等。这些元信息对于后续的数据校验、分析复现和问题追溯至关重要。

在数据收集过程中，还需要进行初步的**数据获取质量控制 (quality control during acquisition)**。例如，监控 API 调用的成功率和返回数据的完整性，检查爬虫是否按预期抓取了所有目标字段，确保实验处理的正确施加，或追踪在线调查的回复率和完成情况。及时发现并处理数据收集阶段出现的问题，可以避免在后期分析中遇到更大的麻烦。

最后，收集到的原始数据需要进行**初步的存储与管理 (initial data storage and management)**。选择合适的存储格式（如 CSV, JSON, Parquet, HDF5）和存储平台（本地硬盘、服务器、云存储），并建立初步的**数据版本控制或追踪机制**，例如通过命名约定、目录结构或专门的版本控制工具来管理不同批次或版本的数据。这有助于确保原始数据的完整性和可追溯性，为后续的数据处理和分析打下坚实基础。

数据检视与评估

在成功收集或获取到原始数据之后，并不能立即投入分析。一个至关重要的中间步骤是对数据进行系统性的检视与深度评估。这一环节的目标是全面了解数据的内在特征、质量状况、潜在局限以及其与研究问题的真正契合度。忽视这一步骤，直接使用未经验证的数据进行分析，极易导致错误的结论和资源的浪费。数据检视与评估是一个细致的“侦探”过程，需要研究者运用统计方法、可视化工具以及批判性思维。

数据质量深度评估 (In-depth Data Quality Assessment) 是核心任务。数据质量是一个多维度概念，通常包括以下几个关键方面 (Wang & Strong, 1996; Pipino, Lee, & Wang, 2002; Kitchin, 2014):

1. **准确性 (Accuracy)**: 数据记录的值与其所代表的真实世界实体或事件的符合程度。例如，用户的年龄信息是否准确？地理位置坐标是否精确？评估准确性可能需要与外部可信数据源进行比对，或进行人工抽样核查。

2. **完整性 (Completeness)**: 数据记录中是否存在缺失值? 所有预期的变量是否都已收集到? 对于时间序列数据, 是否存在时间断点? 对于网络数据, 节点或边的信息是否完整? 需要识别缺失的模式 (例如, 完全随机缺失、随机缺失、非随机缺失), 因为这会影响后续处理策略和分析结果的偏差 (Little & Rubin, 2002)。
3. **一致性 (Consistency / Coherence)**: 数据在不同部分之间、不同数据源之间或在同一数据项的不同时间点之间是否存在逻辑矛盾或冲突。例如, 一个用户的注册日期是否晚于其首次发帖日期? 两个声称测量同一构念的变量是否呈现出预期的相关性?
4. **时效性 (Timeliness / Currency)**: 数据是否足够新, 能够反映当前或研究目标时期的状况? 对于需要追踪动态变化的研究, 数据的“新鲜度”尤为重要。过时的数据可能无法支持有效的推断。
5. **相关性 (Relevance / Appropriateness)**: 数据是否直接或间接地与研究问题相关? 它是否包含了能够操作化核心构念的信息? 即使数据质量很高, 如果与研究问题不相关, 其价值也有限。
6. **可信度/来源清晰度 (Believability / Provenance)**: 数据的来源是否可靠? 收集过程是否透明、有据可查? 元数据是否充分? 对于二手数据或融合数据, 理解其“血统”和加工历史对于评估其可信性至关重要。
7. **粒度 (Granularity)**: 数据的详细程度是否适合研究问题? 例如, 是个体层面数据还是聚合层面数据? 是每日数据还是每月数据? 粒度过粗可能无法捕捉细微变化, 粒度过细则可能带来不必要的复杂性和噪音。
8. **唯一性 (Uniqueness)**: 数据集中是否存在重复记录? 重复记录可能导致统计偏差。

研究者可以运用描述性统计 (如计算各变量的均值、中位数、标准差、缺失值比例、唯一值数量)、数据可视化 (如绘制直方图、箱线图、散点图来观察分布和异常值) 以及更专门的数据剖析 (data profiling) 工具来系统地评估这些质量维度。识别并记录数据中存在的**系统性偏差 (systematic biases)** 也在此阶段进行, 例如覆盖偏差、选择偏差或测量偏差。

元数据理解与管理 (Metadata Understanding and Management) 对于数据评估同样关键。元数据, 即“关于数据的数据”, 描述了数据的背景、定义、结构、来源、收集方法、处理历史、质量指标等信息 (Gitelman, 2013)。研究者需要仔细研读已有的元数据 (如数据字典、代码手册、API 文档), 如果元数据不完整, 则需要主动收集或创建元数据。理解数据生成的具体社会、技术和组织情境对于正确解读数据至关重要。例如, 理解社交媒体平台的用户协议、内容审核政策或算法推荐机制, 有助于判断其数据可能存在的潜在偏见和局限。

在完成深入的数据检视和质量评估后, 需要进行**数据适用性再评估 (Re-assessment of Data Suitability)**。根据检视结果, 研究者需要重新判断当前获得的数据是否真正足以回答最初

设定的研究问题。数据中可能存在预料之外的严重质量问题，或者其覆盖范围和内容与预期有较大差距。在这种情况下，可能需要调整研究问题，或者考虑补充新的数据源、采用不同的数据收集策略，甚至在极端情况下，如果发现数据完全不适用且无法补救，可能需要中止当前研究路径。这个再评估过程体现了研究的迭代性——数据获取和评估的结果会反馈到研究设计的初始阶段。

数据预处理与转换

数据预处理与转换是计算社会科学研究流程中承上启下的关键环节，它发生在数据检视评估之后、探索性数据分析与模型构建之前。这一阶段的目标是将原始的、可能“脏乱差”的数据转化为干净、规整、适合特定分析方法或模型输入的“分析就绪”数据集 (Han, Pei, & Kamber, 2023)。数据预处理的质量直接影响后续分析的准确性和可靠性，甚至有研究指出，在实际的数据科学项目中，数据准备工作可能占据整个项目时间的 60%-80% (Dasu & Johnson, 2003)。计算社会科学研究所用的数据，尤其是大规模数字痕迹数据，往往具有异构性、非结构化、高噪音、多缺失等特征，使得数据预处理尤为复杂和重要。

数据预处理与转换包含一系列相互关联的任务，主要可以归纳为数据清洗、数据转换、数据集集成与融合、数据规整与结构化，以及数据子集划分。

1. 数据清洗 (Data Cleaning): 数据清洗旨在识别并处理数据中的错误、不一致和缺失，以提高数据质量。数据清洗主要包括以下几种做法：

- **处理缺失值 (Handling Missing Values):** 社会科学数据中普遍存在缺失值。首先需要识别缺失的模式 (完全随机缺失 MCAR、随机缺失 MAR、非随机缺失 MNAR) (Little & Rubin, 2002)。处理方法包括：**删除** (删除含有缺失值的记录或变量，但可能损失信息或引入偏差)、**均值/中位数/众数填充** (简单易行，但可能扭曲分布或低估方差)、**回归填充/多重插补 (Multiple Imputation)** (基于变量间关系进行更复杂的估计，是较为推荐的方法，如 MICE 算法 (van Buuren & Groothuis-Oudshoorn, 2011))、或将缺失本身作为一种信息进行**标记**。选择何种方法取决于缺失的比例、模式以及后续分析的需求。
- **处理异常值/离群点 (Handling Outliers):** 异常值是指与数据集中其他观测值显著不同的数据点。它们可能源于测量错误、输入错误或代表了真实但极端的情况。检测技术包括基于统计分布的方法 (如 Z 分数、IQR 法则)、可视化方法 (如箱线图、散点图) 或基于模型的检测方法 (Aggarwal, 2017)。处理方式可以是**删除** (如果确定是错误)、**转换** (如对数转换、缩尾处理以减小其影响)、**分箱**，或者在某些情况下**保留** (如果代表真实且重要的现象)。
- **处理错误与不一致数据 (Handling Errors and Inconsistencies):** 这包括纠正明显的录入错误 (如年龄为 200 岁)、统一不一致的度量单位或编码 (如将“男性”、“M”、“1”统一

为相同的编码)、解决逻辑冲突(如毕业日期早于出生日期)。这通常需要结合领域知识和数据字典进行。

- **去重 (Deduplication):** 识别并移除数据集中重复的记录, 这些重复可能源于数据收集过程或数据合并过程。

2. 数据转换 (Data Transformation): 数据转换是将数据从一种格式或结构转变为另一种, 以使其更适合分析或建模。

- **特征工程 (Feature Engineering):** 这是数据预处理中最具创造性和领域知识依赖性的部分。它涉及从原始数据中创建新的、更能捕捉现象本质或提升模型性能的变量(特征)。方法包括:**衍生指标**(如从交易记录中计算用户的平均购买间隔、总消费金额)、对已有变量进行**数学变换**(如 \log 变换以处理偏态分布、幂变换、多项式特征)、**离散化/分箱 (Discretization/Binning)**(将连续变量转换为分类变量)、**文本特征提取**(如词袋模型、TF-IDF、词嵌入)(Aggarwal & Zhai, 2012)、**时间序列特征提取**(如趋势、季节性、滞后项)。好的特征工程往往能显著改善模型效果。
- **数据类型转换 (Data Type Conversion):** 确保每个变量的数据类型(如数值型、字符型、日期型、布尔型)与其含义和后续分析要求相符。
- **归一化/标准化 (Normalization/Standardization):** 当不同变量的取值范围差异很大时, 某些依赖距离或梯度的算法(如K-均值聚类、支持向量机、神经网络)可能会受到主导性变量的影响。归一化(如最小-最大归一化)通常将数据缩放到 $[0,1]$ 或 $[-1,1]$ 区间, 标准化(如Z分数标准化)则将数据转换为均值为0、标准差为1的分布。
- **编码 (Encoding):** 将分类变量(尤其是名义型变量)转换为数值形式, 以便机器学习模型处理。常用方法有**标签编码 (Label Encoding)**(为每个类别分配一个整数, 可能引入不必要的序关系)、**独热编码 (One-Hot Encoding)**(为每个类别创建一个新的二元虚拟变量, 避免序关系但可能导致高维稀疏)(Géron, 2019)。对于有序分类变量, 可以使用序数编码。

3. 数据集成与融合 (Data Integration and Fusion): 计算社会科学研究常常需要整合来自不同来源、不同格式、不同时间点的数据集, 以获得更全面、更丰富的分析视角(Doan, Halevy, & Ives, 2012)。数据集成面临诸多挑战:


- **模式对齐/映射 (Schema Alignment/Mapping):** 不同数据源对同一实体或属性可能有不同的命名、定义或数据类型, 需要进行识别和统一。
- **实体识别/链接 (Entity Resolution/Linkage):** 识别并链接指向现实世界中同一实体的不同记录(例如, 不同数据库中的同一个人或同一个组织, 但其标识符或名称可能存在差异)。这通常需要复杂的字符串匹配算法、机器学习方法、LLM识别或人工校验(Christen, 2012)。

- **处理数据冲突 (Handling Data Conflicts)**: 当不同数据源对同一实体的同一属性给出不同值时, 需要制定冲突解决策略 (如信任特定来源、取平均值、保留所有值等)。

4. 数据规整与结构化 (Data Tidying and Structuring): 为了便于后续使用特定分析工具或遵循某些分析范式, 数据需要被整理成规范的格式。一个重要的原则是“**Tidy Data**”, 即满足以下条件的数据表: 每个变量是一列, 每个观测是一行, 每种观测单元构成一张表。这有助于简化数据操作和可视化。此外, 针对特定分析任务, 可能需要将数据构建成特定的数据结构, 例如: 将事件序列数据转换为适合**时间序列分析**的格式; 将个体及其关系数据构建成**网络/图对象** (Kolaczyk & Csárdi, 2020); 将大量文本组织成适合**自然语言处理**的**语料库 (corpus)**。

5. 数据子集划分 (Data Subsetting/Splitting): 在进行预测性建模时, 通常需要将数据集划分为**训练集 (training set)** (用于拟合模型参数)、**验证集 (validation set)** (用于调整模型超参数和初步评估模型性能) 和**测试集 (test set)** (用于最终评估模型的泛化能力, 测试集在模型训练和调优过程中应保持“不可见”)。划分比例和方式 (如随机划分、按时间划分、分层抽样) 取决于数据量、数据特性和研究目标 (Hastie, Tibshirani, & Friedman, 2009)。


整个数据预处理与转换过程, 每一步都应当**详细记录 (documenting preprocessing steps)**, 包括所做的决策、选择的参数、使用的代码或工具。这不仅是为了确保研究过程的透明性和**可重复性 (reproducibility)**, 也是为了在后续分析出现问题时能够有效地追溯和调试。许多数据分析软件 (如 R, Python 的 Pandas 库) 都提供了强大的数据操作功能, 而文字化编程工具 (如 Jupyter Notebook, R Markdown) 则有助于将代码、解释和结果整合在一起, 形成清晰的预处理报告。




本小节参考文献:

- Bruns, Axel, and Stefan Stieglitz. 2013. "Towards More Systematic Twitter Analysis: Metrics for Tweeting Activities." *International Journal of Social Research Methodology*.
<https://www.tandfonline.com/doi/abs/10.1080/13645579.2012.756095> (March 14, 2025).
- Couper, Mick P. "Review: Web Surveys: A Review of Issues and Approaches*." <https://dx.doi.org/10.1086/318641> (March 14, 2025).
- Gitelman, Lisa, ed. 2013. *Raw Data Is an Oxymoron*. Cambridge (Mass.): MIT Pr.
- Kitchin, Rob. 2014. "Big Data, New Epistemologies and Paradigm Shifts." *Big Data & Society* 1(1): 2053951714528481. doi:10.1177/2053951714528481.
- Kohavi, Ron, Diane Tang, and Ya Xu. 2020. *Trustworthy Online Controlled Experiments: A Practical Guide to A/B Testing*. Cambridge: Cambridge University Press. doi:10.1017/9781108653985.
- Little, Roderick J. A., and Donald B. Rubin. 2002. "Missing Data in Experiments." In *Statistical Analysis with Missing Data*, John Wiley & Sons, Ltd, 24–40. doi:10.1002/9781119013563.ch2.
- Pipino, Leo L., Yang W. Lee, and Richard Y. Wang. 2002. "Data Quality Assessment." *Commun. ACM* 45(4): 211–18. doi:10.1145/505248.506010.
- Wang, Richard Y., and Diane M. and Strong. 1996. "Beyond Accuracy: What Data Quality Means to Data Consumers." *Journal of Management Information Systems* 12(4): 5–33. doi:10.1080/07421222.1996.11518099.
- Aggarwal, Charu C. 2017. "An Introduction to Outlier Analysis." In *Outlier Analysis*, ed. Charu C. Aggarwal. Cham: Springer International Publishing, 1–34. doi:10.1007/978-3-319-47578-3_1.
- Aggarwal, Charu C., and ChengXiang Zhai. 2012. "A Survey of Text Classification Algorithms." In *Mining Text Data*, eds. Charu C. Aggarwal and ChengXiang Zhai. Boston, MA: Springer US, 163–222. doi:10.1007/978-1-4614-3223-4_6.
- Buuren, Stef van, and Karin Groothuis-Oudshoorn. 2011. "Mice: Multivariate Imputation by Chained Equations in R." *Journal of Statistical Software* 45: 1–67. doi:10.18637/jss.v045.i03.
- Christen, Peter. 2012. "The Data Matching Process." In *Data Matching: Concepts and Techniques for Record Linkage, Entity Resolution, and Duplicate Detection*, ed. Peter Christen. Berlin, Heidelberg: Springer, 23–35. doi:10.1007/978-3-642-31164-2_2.
- Dasu, Tamraparni, and Theodore Johnson. 2003. *Exploratory Data Mining and Data Cleaning*. Hoboken, NJ: Wiley-Interscience.
- Doan, AnHai, Alon Halevy, and Zachary Ives. 2012. *Principles of Data Integration*. 1st edition. Waltham, MA: Morgan Kaufmann.
- Han, Jiawei, Jian Pei, and Hanghang Tong. 2023. *Data Mining: Concepts and Techniques*. Cambridge, MA, United States: Morgan Kaufmann.
- Hastie, Trevor, Robert Tibshirani, and Jerome Friedman. 2009. "Overview of Supervised Learning." In *The Elements of Statistical Learning: Data*

Mining, Inference, and Prediction, eds. Trevor Hastie, Robert Tibshirani, and Jerome Friedman. New York, NY: Springer, 9–41.

doi:10.1007/978-0-387-84858-7_2 .

Kolaczyk, Eric D., and Gábor Csárdi. 2020. “Visualizing Network Data.” In *Statistical Analysis of Network Data with R*, eds. Eric D. Kolaczyk and Gábor Csárdi. Cham: Springer International Publishing, 29–41.

doi:10.1007/978-3-030-44129-6_3 .

阶段三：探索性分析与模型构建

在数据经过细致的获取、评估和预处理，达到“分析就绪”状态后，研究便进入了探索性数据分析（EDA）与模型构建的核心阶段。这一阶段的目标是深入挖掘数据中蕴含的模式与洞见，并基于研究问题和数据特性，选择、设计、实现和校准合适的计算模型。这是一个充满创造性、也极具挑战性的过程，需要在理论指引、数据驱动和方法创新之间寻求平衡。

探索性数据分析

探索性数据分析（Exploratory Data Analysis, EDA）是一种以开放、好奇的心态，通过多种统计和可视化技术来审视数据，以期发现其主要特征、模式、异常、潜在关系以及检验初步假设的方法论取向。与传统的验证性数据分析（Confirmatory Data Analysis, CDA）不同，EDA 不以严格检验预设假设为首要目标，而是更侧重于从数据本身出发，“让数据说话”，从而形成对数据的直观理解，并为后续的建模或假设构建提供指导。

探索性数据分析（EDA）并非一个孤立的步骤，而是贯穿于数据理解到模型构建整个过程的一种哲学和实践。其**核心目标与作用 (goals and functions)** 体现得尤为突出：

1. **深化数据理解 (Deepening Data Understanding)**：EDA超越了预处理阶段对数据质量的初步评估，致力于从更深层次理解数据的内在结构和分布特征。这包括细致考察单个变量的分布形态（是正态、偏态、双峰还是均匀分布？）、集中趋势（均值、中位数、众数哪个更能代表典型值？）、离散程度（方差、标准差、四分位距反映了多大的变异性？），以及不同变量之间的两两关系或多变量间的复杂互动。对于计算社会科学中常见的数字痕迹数据，EDA有助于揭示用户行为的异质性、时间动态性以及不同数据维度间的潜在关联 (Adamic & Glance, 2005; Golder & Macy, 2014)。
2. **模式发现与假设生成 (Pattern Discovery and Hypothesis Generation)**：EDA的一个核心魅力在于其能够帮助研究者从数据中**发现未预期的模式 (unexpected patterns)**、**识别**

有趣的异常现象 (interesting anomalies), 以及**揭示潜在的结构或关联 (latent structures or relationships)** (Cook & Swayne, 2007)。这些发现往往能够激发新的研究灵感, 催生新的理论假设, 或者对已有的研究问题提供新的视角。例如, 通过对社交媒体数据的EDA, 可能会发现特定类型信息的传播呈现出与理论预期不符的模式, 从而引导研究者探究其背后的新机制。

3. **模型假设的初步检验 (Preliminary Check of Model Assumptions)**: 许多统计模型和机器学习算法都建立在特定的数据假设之上, 例如线性关系、正态分布、同方差性 (误差方差恒定)、变量独立性等 (Gelman & Hill, 2006)。EDA通过可视化和初步统计检验, 可以帮助研究者评估这些假设在当前数据上的合理性。如果发现假设被严重违背, 就需要考虑对数据进行转换, 或者选择对这些假设不那么敏感的模式。
4. **特征工程的指导 (Guidance for Feature Engineering)**: EDA的结果, 特别是变量间的关系和变量对目标结果的潜在影响, 能够为后续的特征工程 (创建新变量) 提供重要线索。例如, 如果发现两个原始变量的交互效应对结果有显著影响, 就可以考虑创建一个代表这种交互的新特征。如果某个变量的分布极度偏斜, EDA会提示对其进行对数转换或分箱处理。
5. **异常值与极端值的深入探究 (In-depth Exploration of Outliers and Extreme Values)**: 虽然在数据预处理阶段已经对异常值进行了初步处理, 但EDA提供了更深入审视这些特殊数据点的机会。结合领域知识, 研究者需要判断这些异常值是真正的错误, 还是代表了真实但罕见的社会现象, 后者可能蕴含着重要的研究价值 (Aggarwal, 2017)。
6. **评估后续分析的复杂性与可行性 (Assessing Complexity and Feasibility of Further Analysis)**: 通过对数据维度、变量关系复杂性、潜在信号强弱的初步感知, EDA有助于研究者判断后续建模工作的难度和可能遇到的挑战, 从而调整预期或补充资源。

为了实现这些目标, EDA依赖于一套丰富的技术与方法, 这些方法可以大致分为描述性统计和数据可视化两大类, 并常常结合使用。**描述性统计 (Descriptive Statistics)** 在EDA中扮演着基础角色, 它通过数值概括来总结数据的核心特征。对于**单变量 (univariate)** 分析, 常用的指标包括:

- **集中趋势度量 (Measures of Central Tendency)**: 均值 (mean)、中位数 (median)、众数 (mode), 它们描述了数据的“中心”位置。
- **离散程度度量 (Measures of Dispersion)**: 方差 (variance)、标准差 (standard deviation)、极差 (range)、四分位距 (Interquartile Range, IQR), 它们描述了数据的变异程度或离合程度。
- **分布形态度量 (Measures of Distribution Shape)**: 偏度 (skewness) 描述了数据分布的不对称性, 峰度 (kurtosis) 描述了数据分布的尖锐程度或尾部厚度。
- 对于**双变量 (bivariate)** 分析, 描述性统计则关注两个变量之间的关系:

- **列联表 (Contingency Tables) / 交叉列表 (Cross-tabulations)**: 用于展示两个或多个分类变量的频数分布及其联合分布, 常结合卡方检验 (Chi-squared test) 来判断变量间是否存在关联。
- **相关系数 (Correlation Coefficients)**: 用于度量两个数值变量之间线性关联的强度和方向。常用的有皮尔逊积矩相关系数 (Pearson's r) (适用于线性关系和正态分布数据)、斯皮尔曼等级相关系数 (Spearman's ρ) 和肯德尔tau系数 (Kendall's τ) (适用于非线性关系或非正态分布数据, 基于变量的秩次) (Cohen, Cohen, West, & Aiken, 2003)。
- **分组摘要统计 (Group-wise Summary Statistics)**: 例如, 计算不同类别 (如性别、地区) 下某个数值变量 (如收入、观点得分) 的均值、中位数等, 以比较组间差异。

数据可视化 (Data Visualization) 是EDA的灵魂, 它将抽象的数字转化为直观的图形, 极大地增强了人类识别模式、发现异常和理解复杂关系的能力 (Healy, 2019)。有效的可视化是EDA成功的关键。常用的可视化技术包括:

- **单变量可视化 (Univariate Visualization)**:
 - **直方图 (Histograms) 和 核密度估计图 (Kernel Density Plots)**: 展示数值变量的频数分布和概率密度形态。
 - **箱线图 (Box Plots) (或称盒须图)**: 简洁地展示数值变量的五个关键统计量 (最小值、下四分位数 Q_1 、中位数 Q_2 、上四分位数 Q_3 、最大值) 以及潜在的异常值。
 - **小提琴图 (Violin Plots)**: 结合了箱线图和核密度估计图的特点, 既能展示分布的密度形态, 又能标出关键分位数。
 - **Q-Q图 (Quantile-Quantile Plots)**: 用于检验数据是否服从某种理论分布 (如正态分布)。
 - **条形图 (Bar Charts)**: 展示分类变量各个类别的频数或比例。
- **双变量可视化 (Bivariate Visualization)**:
 - **散点图 (Scatter Plots)**: 展示两个数值变量之间的关系模式 (线性、非线性、聚集、离散等)。可以叠加回归线 (如普通最小二乘回归线 OLS) 或局部加权回归平滑曲线 (LOESS/LOWESS) 来辅助观察趋势。
 - **分组条形图 (Grouped Bar Charts) 或 堆叠条形图 (Stacked Bar Charts)**: 比较不同类别下另一个分类变量的分布。
 - **分组箱线图/小提琴图 (Grouped Box/Violin Plots)**: 比较不同类别下某个数值变量的分布。
 - **热力图 (Heatmaps)**: 通常用于可视化相关系数矩阵、列联表的频数或高维数据的模式, 通过颜色的深浅表示数值的大小。

- **多变量可视化 (Multivariate Visualization)**: 当需要同时考察三个或更多变量的关系时, 可视化变得更具挑战性。常用方法包括:
 - **散点图矩阵 (Scatter Plot Matrices)**: 展示数据集中所有数值变量两两之间的散点图。
 - **平行坐标图 (Parallel Coordinate Plots)**: 将每个观测值表示为一条穿过多个平行坐标轴 (每个轴代表一个变量) 的折线, 用于识别高维数据中的聚类或模式。
 - **雷达图 (Radar Charts) / 蜘蛛图 (Spider Charts)**: 将多个变量的值表示在从中心点发散的多个轴上, 形成一个多边形, 用于比较不同观测在多个维度上的表现。
 - 在二维图的基础上利用**颜色、形状、大小**等视觉通道来编码第三个或第四个变量。
- **针对特定数据类型的可视化**:
 - **网络/图可视化 (Network/Graph Visualization)**: 对于社交网络、引文网络、互动网络等图数据, 可视化是理解其结构特征 (如节点中心性、社群结构、连接模式) 的关键手段。常用的布局算法有力导向布局 (force-directed layout)、圆形布局 (circular layout) 等 (Brandes et al., 2008; Bastian, Heymann, & Jacomy, 2009)。网络图可以直接展示节点间的关系, 而邻接矩阵的热力图则可以从另一个角度呈现网络结构。
 - **地理空间数据可视化 (Geospatial Data Visualization)**: 对于包含地理位置信息的数据 (如GPS轨迹、带有地理标签的社交媒体帖子), 地图是核心的可视化工具。常用方法包括**分级统计图 (Choropleth Maps)** (用颜色深浅表示区域统计值)、**点密度图 (Point Maps)**、**地理热力图 (Spatial Heatmaps)**、**流向图 (Flow Maps)** 等 (Anselin, 1995; Slocum et al., 2009)。
 - **文本数据可视化 (Text Data Visualization)**: 例如**词云 (Word Clouds)** (展示文本中高频词)、**主题共现网络 (Topic Co-occurrence Networks)** (展示主题模型发现的主题之间的关联)、**文档相似性图 (Document Similarity Maps)** (通过降维将文档投影到二维空间, 可视化其相似性)。

在进行可视化时, 研究者需要遵循**有效数据可视化的原则**, 如确保图形的清晰性、准确性、信息密度、避免误导性呈现等。选择合适的图表类型、恰当的视觉编码 (颜色、形状、大小等)、清晰的标签和图例, 对于能否从可视化中获得真实洞见至关重要。**交互式可视化 (Interactive Visualization)** 工具 (如Plotly Dash, R Shiny, Tableau) 允许用户动态地探索数据, 例如通过缩放、平移、筛选、高亮 (brushing and linking) 等操作, 可以进一步增强EDA的效率和深度。

除了描述性统计和可视化, EDA有时也会初步运用一些更复杂的分析技术, 例如:

- **初步的降维 (Preliminary Dimensionality Reduction)**: 当数据变量过多时, 可以使用主成分分析 (Principal Component Analysis, PCA) (Jolliffe, 2002) 来识别数据中的主要变异方向, 或使用t-分布随机邻域嵌入 (t-SNE) (van der Maaten & Hinton, 2008) 或均匀流形逼近与投影 (UMAP) (McInnes, Healy, & Melville, 2018) 等非线性降维方法将高维数据投影到二维或三维空间进行可视化, 以观察潜在的聚类结构。
- **初步的聚类分析 (Preliminary Clustering Analysis)**: 使用如K-均值 (K-Means) 算法或层次聚类 (Hierarchical Clustering) (Jain, Murty, & Flynn, 1999) 等方法, 尝试将数据中的观测值划分为若干具有内部相似性的群组, 以发现潜在的异质性或数据分段。

EDA本质上是一个**迭代的过程 (iterative process)**。一个发现可能会引出新的问题, 需要进行新一轮的数据操作或可视化。例如, 发现某个变量分布异常, 可能需要返回到数据预处理阶段检查其来源或进行转换; 观察到两个变量间存在非线性关系, 可能会引导研究者在后续建模时考虑非线性模型或对变量进行多项式扩展。EDA的结果深刻地影响着后续的模型选择、特征工程乃至研究问题的重新聚焦。

对EDA过程中的重要发现、所做的图表、观察到的模式以及由此产生的初步洞察进行**系统性的记录与解读 (systematic recording and interpretation)** 非常重要。这可以写入研究日志、代码注释或专门的EDA报告中。解读时需要保持审慎, 区分探索性发现与验证性结论, 避免对EDA中观察到的相关性进行过度因果推断。EDA的目标是启发思考、形成假设, 而不是提供最终答案。它为后续更严格的统计建模和理论检验提供了坚实的基础和方向指引。一个成功的EDA能够让研究者真正“触摸”到数据, 建立起对数据的直觉和深刻理解, 这是任何自动化分析流程都难以替代的。

模型/方法选择与设计

在通过探索性数据分析 (EDA) 对数据特性、潜在模式和变量关系有了深入理解之后, 研究便进入了模型或分析方法的选择与设计阶段。这是一个承上启下的关键步骤, 它将研究问题、理论框架、数据特征与具体的计算工具联系起来, 旨在构建一个能够有效回答研究问题、并具有良好的解释力或预测力的形式化结构。此阶段要求研究者不仅熟悉各种可选模型的原理与适用条件, 更要能够基于研究的特定目标和约束进行审慎的权衡与决策。

首先, 需要**重申研究的核心认知目标与数据的基本特性 (reiterating research objectives and data characteristics)**。模型是服务于特定目的的工具 (Box, 1976), 因此, 选择模型的首要依据是研究旨在实现什么: 是**描述 (description)** 现象的模式? 是**预测 (prediction)** 未来的结果? 是**解释 (explanation)** 现象背后的因果机制? 还是**生成/模拟 (generation/simulation)** 复杂系统的动态过程以探索可能性? 不同的认知目标对模型的要

求截然不同。例如，以预测为主要目标的任务可能更倾向于选择预测精度高但可解释性可能较差的复杂机器学习模型；而以因果解释为核心的研究则可能需要依赖于结构化的统计模型（如回归模型、路径分析、结构方程模型）或专门的因果推断方法（如工具变量法、断点回归、双重差分法），并对模型的假设和参数的可解释性有较高要求 (Angrist & Pischke, 2008)。同时，数据的特性，如变量类型（连续、分类、有序）、数据结构（截面、时间序列、面板、网络、文本、图像）、数据规模、是否存在缺失或异常、变量间是否存在多重共线性等，都会极大地约束可选模型的范围。EDA的结果在此提供了重要输入。

在此基础上，研究者需要进行**候选模型/方法的系统比较与筛选**。计算社会科学可用的模型和方法库非常庞大，涵盖了从传统统计学到现代机器学习，再到特定领域的分析技术，这些方法我们将在后续进行介绍，此处主要陈述方法论观点。

在比较候选模型/方法时，研究者需要综合考虑以下因素：

- **理论基础与解释力 (Theoretical Grounding and Interpretability)**：模型是否与研究的理论框架相符？其参数和内部机制是否具有社会科学意义上的可解释性？
- **数据结构与规模的匹配度 (Fit with Data Structure and Scale)**：模型是否能有效处理当前数据的类型（如文本、网络、时序）、规模（大规模数据可能需要更高效的算法）和复杂性？
- **计算可行性与资源需求 (Computational Feasibility and Resource Requirements)**：模型的训练和运行是否在可接受的时间和计算资源内完成？
- **预期性能 (Expected Performance)**：根据类似研究或初步实验，模型在相关评估指标（如准确率、 R^2 、AUC）上可能达到何种水平？
- **模型的假设与局限 (Assumptions and Limitations of the Model)**：每个模型都有其内在的假设条件（如线性、独立性、分布形态），研究者需要评估这些假设在当前研究情境下的合理性，并认识到模型的固有局限性。
- **模型的复杂度与简洁性 (Model Complexity vs. Parsimony)**：遵循奥卡姆剃刀原则，在解释力或预测力相当的情况下，应优先选择更简洁的模型。过于复杂的模型可能难以理解、容易过拟合，并且需要更多数据来稳定估计 (Forster & Sober, 1994)。
- **模型的复杂度与可解释性 (Model Complexity vs. Interpretability)**。例如，深度神经网络通常具有强大的拟合能力和预测精度，但其内部运作机制难以直观解释 (Goodfellow, Bengio, & Courville, 2016)。而简单的线性回归模型虽然可能在预测上稍逊一筹，但其系数的含义清晰，易于理论解读。选择哪一端，取决于研究的主要目标。如果目标是纯粹的预测，那么可解释性可能次要；但如果目标是理解机制或提供政策建议，那么可解释性就至关重要。近年来，发展可解释人工智能 (Explainable AI, XAI) 的努力，如 SHAP (SHapley Additive exPlanations) 和 LIME (Local Interpretable Model-agnostic Explanations)，试图在复杂模型和可解释性之间架起桥梁。

在选定模型或方法类型后，还需要进一步进行**具体的设计**。例如，如果选择随机森林，需要决定树的数量、最大深度、节点分裂标准等超参数；如果选择主题模型，需要确定主题数量；如果设计ABM，则需要详细规定主体的属性、行为规则、互动网络拓扑结构等。这些设计决策同样需要基于理论、EDA发现和研究目标来做出。

最后，至关重要是预先**确定模型的评估指标与验证策略 (defining evaluation metrics and validation strategy)**。在模型构建之前就明确如何衡量模型的“好坏”，是保证评估客观性的前提。评估指标应与研究目标和模型类型相匹配。该话题将在下面一部分进行详细阐述。

模型/方法选择与设计是一个充满权衡与迭代的过程。初步选定的模型可能在后续的实现或评估阶段发现不适用或性能不佳，这时就需要返回此阶段重新思考，甚至可能需要重新审视研究问题或数据。拥有广博的模型知识储备、深刻的理论洞察力以及对数据特征的敏锐把握，是成功完成这一阶段任务的关键。此阶段的产出通常是一个详细的模型设计方案，包括所选模型的理论依据、数学形式（如果适用）、关键假设、参数设定、超参数范围以及评估计划。

模型实现与参数校准

在审慎地选择了合适的模型或分析方法并完成了初步设计之后，研究便进入了模型实现与参数校准的阶段。这一阶段的核心任务是将抽象的模型构想转化为具体的、可执行的计算机代码，并通过数据拟合或理论约束来确定模型的参数值。这是一个技术性与分析性并重的过程，要求研究者既具备扎实的编程能力，又对模型的统计或计算原理有深入理解。

首先，**选择合适的编程语言、库与工具 (selecting appropriate programming languages, libraries, and tools)** 是模型实现的第一步。计算社会科学领域主流的编程语言是Python和R。Python以其强大的通用性、丰富的第三方库以及在机器学习和深度学习领域的领先地位而广受欢迎。R语言则在统计分析、数据可视化和特定社会科学计量方法（如混合效应模型、生存分析、结构方程模型）方面拥有深厚的积累和庞大的社区支持（如 `lme4`, `survival`, `lavaan`, `igraph`, `ggplot2` 等包）。选择哪种语言通常取决于研究者的熟悉程度、特定模型或方法的现有实现以及团队协作的需求。除了Python和R，某些特定类型的模型可能需要专门的软件或平台，例如，NetLogo广泛用于主体建模，Gephi用于网络可视化与分析，Mplus用于复杂的结构方程模型和潜变量分析。熟悉并善用这些工具对于高效实现模型至关重要。

接下来是**模型代码的编写与调试 (model code writing and debugging)**。这要求研究者将模型设计的逻辑（无论是统计方程、机器学习算法流程，还是模拟规则）准确地翻译成计算

机指令。编写高质量的代码是确保研究结果可靠性和可重复性的基础。这包括遵循良好的编程规范（如代码模块化、添加清晰注释、使用有意义的变量名）、进行版本控制、以及进行单元测试和集成测试以确保代码的正确性。调试是编程过程中不可避免的一环，需要耐心和细致地定位并修复代码中的逻辑错误或语法错误。对于复杂的模型，实现过程可能需要参考相关的学术论文、官方文档或开源代码库。

当模型代码初步完成后，便进入了**参数估计/模型训练 (parameter estimation / model training)**的核心环节。这一过程的目标是利用已准备好的**训练数据集 (training dataset)**来确定模型中的未知参数，使其能够最好地拟合数据或学习数据中的模式。

- 对于**统计模型**，参数估计通常涉及最优化某个目标函数。例如，在线性回归中，目标是找到使残差平方和最小的回归系数；在逻辑回归中，是找到使观测数据的似然函数最大的系数。这通常通过解析解或数值优化算法（如梯度下降、牛顿法）来实现。
- 对于**机器学习模型**，模型训练是一个通过迭代优化来调整模型内部权重或结构的过程，以最小化在训练数据上的损失函数 (loss function) 或最大化某个性能指标。
- 对于**网络模型**，如指数随机图模型 (ERGM)，参数估计通常采用马尔可夫链蒙特卡洛最大似然估计 (MCMC MLE) 或贝叶斯方法 (Lusher, Koskinen, & Robins, 2013)。
- 对于**主题模型**，如LDA，参数（如每个主题的词分布、每篇文档的主题分布）通常通过吉布斯采样 (Gibbs sampling) 或变分推断 (variational inference) 等算法进行估计 (Blei, Ng, & Jordan, 2003)。

在许多机器学习模型中，除了通过训练数据学习的参数（如回归系数、神经网络权重）外，还存在一类需要在模型训练之前手动设定的参数，称为**超参数 (hyperparameters)**。例如，随机森林中的树的数量、支持向量机中的惩罚系数C和核函数类型、K近邻算法中的K值、神经网络的层数和每层的神经元数量、学习率等。**超参数调优 (hyperparameter tuning)**是寻找最优超参数组合的过程，以使模型在未见过的验证数据上表现最佳。常用的超参数调优方法包括：

- **网格搜索 (Grid Search)**：对预先定义的超参数候选值进行穷举组合，逐一评估。计算量大，但易于实现。
- **随机搜索 (Random Search)**：在预定义的超参数分布中随机采样组合进行评估。通常比网格搜索更高效，尤其当某些超参数影响较小时。
- **贝叶斯优化 (Bayesian Optimization)**：构建一个关于超参数与模型性能之间关系的概率模型（通常是高斯过程），并利用该模型智能地选择下一个要评估的超参数组合，以期更快地找到最优值。

- **基于梯度的优化 (Gradient-based Optimization)**: 对于某些可微分的超参数, 可以直接使用梯度方法进行优化。
- **进化算法 (Evolutionary Algorithms)**: 如遗传算法, 模拟自然选择过程来搜索最优超参数组合。


超参数调优通常在独立的**验证集 (validation set)**上进行, 以避免在测试集上调优导致对模型泛化能力的过高估计。

对于某些类型的模型, 特别是**基于主体的模拟模型 (Agent-Based Models, ABM)**, 参数的确定过程可能不完全依赖于数据拟合, 而是更多地依赖于理论设定、文献参考或一种称为**校准 (calibration)**的过程。校准的目标是调整ABM中的微观参数 (如主体的行为规则、互动概率、决策阈值等), 使得模型在宏观层面生成的输出 (如某种分布、动态模式、关键统计量) 能够与已知的经验数据或“**典型化事实**” (stylized facts) 相匹配。校准过程可能涉及:

- **直接估计 (Direct Estimation)**: 如果某些微观参数可以直接从经验数据 (如调查、实验) 中获得, 则直接使用。
- **模式导向建模 (Pattern-Oriented Modeling, POM)**: 识别目标系统中的多个关键宏观模式, 然后系统地调整模型参数, 直到模型能够同时复现这些模式。
- **手动调参/专家判断 (Manual Tuning / Expert Judgment)**: 基于研究者对系统和模型的理解, 手动调整参数并观察其效果。
- **自动化校准算法 (Automated Calibration Algorithms)**: 使用类似超参数调优的优化算法来搜索能够最好拟合经验模式的参数组合。

校准是一个复杂且具挑战性的过程, 因为ABM往往具有高维度参数空间、非线性行为和随机性, 可能存在参数“等效性”(equifinality) 问题 (即不同的参数组合可能产生相似的宏观输出)。

无论采用何种方法进行参数估计、模型训练或校准, 都需要详细记录所用的算法、软件版本、超参数设置、训练/验证/测试集的划分方式以及最终确定的参数值。这对于后续的模式评估、结果解释和研究复现至关重要。模型实现与参数校准是连接理论设计与经验验证的桥梁, 其质量直接决定了模型能否有效地从数据中学习并揭示有意义的社会科学洞见。



本小节参考文献:

- Adamic, Lada A., and Natalie Glance. 2005. "The Political Blogosphere and the 2004 U.S. Election: Divided They Blog." In Proceedings of the 3rd International Workshop on Link Discovery, LinkKDD '05, New York, NY, USA: Association for Computing Machinery, 36–43. doi:10.1145/1134271.1134277.
- Aggarwal, Charu C. 2017. "An Introduction to Outlier Analysis." In Outlier Analysis, ed. Charu C. Aggarwal. Cham: Springer International Publishing, 1–34. doi:10.1007/978-3-319-47578-3_1.
- Anselin, Luc. 1995. "Local Indicators of Spatial Association—LISA." Geographical Analysis 27(2): 93–115. doi:10.1111/j.1538-4632.1995.tb00338.x.
- Bastian, Mathieu, Sebastien Heymann, and Mathieu Jacomy. 2009. "Gephi: An Open Source Software for Exploring and Manipulating Networks." Proceedings of the International AAI Conference on Web and Social Media 3(1): 361–62. doi:10.1609/icwsm.v3i1.13937.
- Blei, David M., Andrew Y. Ng, and Michael I. Jordan. 2003. "Latent Dirichlet Allocation." J. Mach. Learn. Res. 3(null): 993–1022.
- Brandes, Alba A., Enrico Franceschi, Alicia Tosoni, Valeria Blatt, Annalisa Pession, Giovanni Tallini, Roberta Bertorelle, et al. 2008. "MGMT Promoter Methylation Status Can Predict the Incidence and Outcome of Pseudoprogression after Concomitant Radiochemotherapy in Newly Diagnosed Glioblastoma Patients." Journal of Clinical Oncology: Official Journal of the American Society of Clinical Oncology 26(13): 2192–97. doi:10.1200/JCO.2007.14.8163.
- Cohen, Jacob, Patricia Cohen, Stephen G. West, and Leona S. Aiken. 2003. Applied Multiple Regression/Correlation Analysis for the Behavioral Sciences, 3rd Ed. Mahwah, NJ, US: Lawrence Erlbaum Associates Publishers.
- Fagiolo, Giorgio, Alessio Moneta, and Paul Windrum. 2007. "A Critical Guide to Empirical Validation of Agent-Based Models in Economics: Methodologies, Procedures, and Open Problems." Computational Economics 30(3): 195–226. doi:10.1007/s10614-007-9104-4.
- Forster, Malcolm R., and Elliott Sober. 1994. "How to Tell When Simpler, More Unified, or Less a D Hoc Theories Will Provide More Accurate Predictions." British Journal for the Philosophy of Science 45(1): 1–35. doi:10.1093/bjps/45.1.1.
- Gitelman, Lisa, ed. 2013. Raw Data Is an Oxymoron. Cambridge (Mass.): MIT Pr.
- Golder, Scott A., and Michael W. Macy. 2014. "Digital Footprints: Opportunities and Challenges for Online Social Research." Annual Review of Sociology 40: 129–52. doi:10.1146/annurev-soc-071913-043145.
- Goodfellow, Ian, Yoshua Bengio, and Aaron Courville. 2016. Deep Learning. Cambridge, Mass: The MIT Press.
- Healy, Kieran. 2019. Data Visualization: A Practical Introduction. Princeton NJ Oxford: Princeton University Press.
- Jain, A. K., M. N. Murty, and P. J. Flynn. 1999. "Data Clustering: A

Jain, A. K., M. N. Murty, and P. J. Flynn. 1999. "Data Clustering: A Review." *ACM Comput. Surv.* 31(3): 264-323. doi:10.1145/331499.331504.

Maaten, Laurens van der, and Geoffrey Hinton. 2008. "Visualizing Data Using T-SNE." *Journal of Machine Learning Research* 9(86): 2579-2605.

Slocum, Terry A., Robert B. McMaster, Fritz C. Kessler, and Hugh H. Howard. 2009. *Thematic Cartography and Geovisualization*, 3rd Edition. Upper Saddle River, NJ: Pearson.

阶段四：评估、解释与迭代优化

模型实现与参数校准完成后，计算社会科学研究进入了至关重要的评估、解释与迭代优化阶段。这一阶段的核心任务是系统性地检验模型的性能、稳健性和有效性，深入解读模型结果的社会科学含义，并根据评估结果对模型或研究设计进行必要的调整和改进。这是一个反思性、批判性且高度迭代的过程，旨在确保研究结论的可靠性、理论贡献的深刻性以及实践意义的价值。

模型评估与验证

模型评估与验证是科学研究严谨性的核心体现，它旨在回答“我们构建的模型在多大程度上是好的？”以及“我们对模型的信任应该有多少？”这一根本问题。一个未经严格评估的模型，其结论往往是不可靠的，甚至可能产生误导。评估是一个多维度的工作，涉及模型的预测性能、诊断检验、稳健性分析以及与研究目标的契合度等多个方面。

1. 性能评估 (Performance Assessment): 这是模型评估最直接的方面，关注模型在完成其预设任务（如分类、回归、聚类、主题识别、模式生成）方面的表现如何。

- **在独立的测试集上进行评估:** 为了获得对模型泛化能力 (**generalization ability**) 的无偏估计，即模型在未见过的数据上的表现，最终的性能评估必须在严格独立的**测试集 (test set)** 上进行。测试集在整个模型训练和超参数调优过程中都应保持“隔离”状态 (Hastie, Tibshirani, & Friedman, 2009)。如果在验证集（用于调参）或训练集（用于拟合）上评估性能，结果往往会过于乐观，导致**过拟合 (overfitting)** 的误判。
- **使用恰当的评估指标 (appropriate evaluation metrics):** 如前文在模型选择阶段所述，需要根据模型的研究目标选择合适的量化指标。例如：
 - **分类模型:** 准确率、精确率、召回率、F1 分数、混淆矩阵 (Confusion Matrix)、AUC-ROC、精确率-召回率曲线 (Precision-Recall Curve, PRC) 等 (Fawcett, 2006)。对于类别

不平衡的数据，准确率可能具有误导性，此时应更关注 AUC-ROC、PRC 或平衡 F1 分数等指标。

- **回归模型**：均方误差 (Mean Squared Error, MSE)、均方根误差 (RMSE)、平均绝对误差 (MAE)、决定系数 (R^2)、调整 R^2 (Adjusted R^2) 等 (James et al., 2013)。
- **聚类模型**：轮廓系数、Calinski-Harabasz 指数、Davies-Bouldin 指数 (DBI) (内部评估，无需真实标签)；调整兰德指数 (Adjusted Rand Index, ARI)、调整互信息 (Adjusted Mutual Information, AMI) (外部评估，需要真实标签) (Rousseeuw, 1987; Hubert & Arabie, 1985)。
- **主题模型**：困惑度 (Perplexity) (衡量模型对未见文档的预测能力，越低越好，但有时与人类判断不一致)、主题一致性/可解释性指标 (Topic Coherence/Interpretability) (如 UMass Coherence, NPMI Coherence, 衡量主题内词语的语义相关性，越高越好) (Newman et al., 2010; Röder, Both, & Hinneburg, 2015)。
- **网络模型**：拟合优度检验 (Goodness-of-fit tests), 如比较模拟网络与观测网络的度分布、聚类系数、最短路径长度等统计量 (Hunter, Goodreau, & Handcock, 2008)。
- **基线模型比较 (Comparison with Baseline Models)**：将所构建模型的性能与一些简单的基线模型 (如随机猜测、仅预测最常见类别、平均值预测、简单线性回归) 或领域内已有的标准模型进行比较，以判断模型的增益是否显著。

2. 模型诊断 (Model Diagnostics)：除了整体性能指标，还需要深入检查模型的内部行为，识别其可能存在的系统性偏差、方差来源或假设违背情况。

- **残差分析 (Residual Analysis)**：对于回归模型，检查残差 (观测值与预测值之差) 的分布是否随机、是否符合正态性、是否存在异方差性 (残差方差随预测值变化)、是否存在自相关 (对于时间序列数据) 等。残差图是重要的诊断工具 (Cook & Weisberg, 1982)。
- **影响点与杠杆点分析 (Analysis of Influential Points and Leverage Points)**：识别那些对模型参数估计或预测结果有异常大影响的个别观测点。
- **检验模型假设**：回顾模型构建时所做的核心假设 (如线性关系、变量独立性、误差分布形态)，并利用统计检验或可视化方法评估这些假设在当前数据和模型下的合理性。例如，对于线性回归，可以使用方差膨胀因子 (Variance Inflation Factor, VIF) 来检测多重共线性。
- **学习曲线 (Learning Curves)**：通过绘制模型在训练集和验证集上的性能随训练样本量变化的曲线，可以判断模型是否存在高偏差 (欠拟合) 或高方差 (过拟合) 问题 (Domingos, 2012)。

- **错误分析 (Error Analysis)**: 仔细检查模型预测错误的案例, 分析其特征和原因, 这有助于发现模型的系统性弱点或数据中存在的特殊情况, 为模型改进提供线索。

3. 稳健性与敏感性分析 (Robustness and Sensitivity Analysis): 一个好的模型, 其核心结论不应过于依赖于某些特定的、可能不确定的假设、参数选择或数据输入的微小变动。稳健性和敏感性分析旨在评估模型结论的“坚固”程度。

- **对数据扰动的稳健性**: 例如, 通过自助法 (Bootstrap) 重抽样来估计参数的置信区间或预测的稳定性; 使用不同的数据子集 (如按时间、按区域划分) 重新训练和评估模型, 看结果是否一致; 在输入数据中引入少量噪音, 观察模型输出的变化。
- **对模型假设变化的稳健性 (Robustness to Model Specification)**: 尝试略微改变模型的结构 (如增加或删除某些变量、改变函数形式), 观察核心结论是否发生显著变化。
- **参数敏感性分析 (Parameter Sensitivity Analysis)**: 对于模型中的关键参数 (尤其是那些非数据驱动设定或存在不确定性的参数, 如 ABM 中的某些行为规则参数), 系统地改变其取值, 观察模型输出对这些变化的敏感程度。如果模型结果对某个参数的微小变化高度敏感, 则该参数的设定需要特别谨慎, 或者模型本身可能不够稳健 (Saltelli et al., 2008)。
- **交叉验证 (Cross-Validation)**: 如 K 折交叉验证 (K-fold Cross-Validation), 将数据随机分成 K 个子集, 轮流使用 K-1 个子集进行训练, 剩下的 1 个子集进行验证, 重复 K 次并平均结果。这是一种评估模型泛化能力和稳定性的常用方法, 尤其适用于数据量有限的情况。

4. (对于因果模型) 因果有效性评估 (Assessment of Causal Validity): 如果研究旨在进行因果推断, 那么评估的核心在于模型所断言的因果关系是否真实可信。这需要超越统计关联, 深入考虑:

- **混淆变量 (Confounding Variables)**: 是否充分控制了所有可能同时影响自变量和因变量的共同原因? 遗漏重要的混淆变量会导致虚假因果关系。
- **选择偏差 (Selection Bias)**: 样本的选择过程或数据的生成机制是否导致了自变量与误差项相关? 例如, 在研究教育回报时, 能力既影响教育选择也影响收入, 不加控制会导致偏差。
- **内生性 (Endogeneity)**: 除了混淆和选择偏差, 还可能存在互为因果 (simultaneity) 或测量误差等问题。
- **反事实思考 (Counterfactual Reasoning)**: 模型能否支持关于“如果 X 没有发生, Y 会怎样”的反事实推断? (Pearl, 2009; Morgan & Winship, 2014)。

评估因果有效性通常需要结合理论知识、研究设计（如随机实验、准实验设计）、专门的因果推断方法（如工具变量法、倾向得分匹配、回归断点设计）以及对潜在偏见来源的细致分析。统计显著性本身并不等同于因果关系。

5.（对于模拟模型）行为空间探索与模式复现 (Exploration of Behavioral Space and Pattern Replication): 对于 ABM 等生成性模型，评估的重点可能不在于精确点预测，而在于：

- **模型能否复现已知的宏观模式或典型化事实？** (Emergent pattern replication) (Gilbert & Troitzsch, 2005)。
- **模型参数对宏观输出的影响是怎样的？** (Sensitivity analysis of emergent outcomes to micro-parameters)。
- **模型是否能产生非预期的、有趣的或理论上重要的涌现行为？** (Discovery of novel emergent phenomena)。
- **模型的行为空间 (behavioral space) 是否足够丰富且与现实系统的复杂性相称？**

验证模拟模型通常是一个多方面、迭代的过程，可能包括与经验数据（如果可用）的定量比较、与理论预期的一致性检验、专家判断以及对模型内部动态的深入分析 (Sargent, 2013; Grimm & Railsback, 2005)。

6. 与其他模型比较 (Benchmarking against Alternative Models): 将当前模型的性能或特性与文献中已有的其他相关模型，或者与研究者自己构建的其他候选模型进行系统比较。这有助于客观评估当前模型的相对优势和劣势。

模型评估与验证是一个持续的过程，其结果直接反馈到研究的各个环节。如果评估结果不理想（如预测精度低、模型不稳定、假设被严重违背、无法解释关键现象），就需要返回到模型选择、特征工程、数据预处理甚至问题定义阶段进行调整。这是一个不断试错、学习和改进的循环，直至研究者对模型的质量和结论的可靠性达到满意的程度。清晰、透明地报告评估过程和结果，包括模型的局限性，是负责任的科学实践不可或缺的一部分。

结果解释与理论关联

在对模型进行了系统性的评估与验证之后，接下来的核心任务是对模型产生的结果进行深入的社会科学意义解读，并将其与相关的理论框架进行富有成效的对话。这一步骤是将技术性的分析输出转化为有价值的知识洞见的桥梁，是计算社会科学研究实现其智识贡献的

关键环节。仅仅报告统计显著性或预测准确率是远远不够的，研究者必须阐明这些结果对于理解社会现象、检验或发展社会理论意味着什么。

1. 社会科学意义解读 (Interpretation of Results in Social Science Terms):

- **将统计结果翻译为实质性结论:** 模型输出的可能是回归系数、边际效应、预测概率、聚类标签、主题词分布、网络中心性得分、模拟轨迹等。研究者需要将这些量化结果用清晰、准确、易于理解的社会科学语言重新表述。例如，一个正向显著的回归系数意味着什么？一个特定的主题模型包含了哪些核心概念，它反映了文本数据中怎样的社会议题或话语模式？一个高介数中心性的节点在社会网络中扮演了怎样的角色？
- **回答最初的研究问题:** 模型结果在多大程度上直接回答了研究开始时提出的核心问题？它们是否支持或否定了最初的假设（如果适用）？结果的强度和方向如何？
- **量化效应大小与实际重要性 (Quantifying Effect Sizes and Practical Significance):** 除了统计显著性（如 p 值），更要关注效应的大小和实际重要性 (Cohen, 1988; Wasserstein & Lazar, 2016)。一个统计上显著但效应量极小的结果，其理论或实践意义可能有限。需要评估结果在现实世界中的影响程度是否值得关注。
- **考虑结果的异质性 (Considering Heterogeneity of Effects):** 模型结果是否对所有子群体或情境都一致？是否存在某些特定条件下效应更强或更弱，甚至方向相反的情况？探索和解释这种效应异质性，往往能带来更细致和深刻的洞察。
- **可视化辅助解释 (Utilizing Visualizations for Interpretation):** 如前所述，图表是传达复杂模型结果和洞察的有力工具。例如，绘制回归系数的点图及其置信区间、预测概率随关键变量变化的曲线图、主题模型中主题-词语关系的词云或网络图、模拟结果随参数变化的相图等，都能帮助读者（和研究者自己）更好地理解结果的含义 (Healy, 2018)。

2. 与理论对话 (Engaging with Theory): 计算社会科学研究的最终目标之一是贡献于社会科学理论的积累与发展。因此，将模型发现与现有理论进行深入对话至关重要。

- **检验理论 (Theory Testing):** 如果研究始于明确的理论假设，模型结果可以直接用于检验这些假设。结果是支持了理论的预测？还是与理论预期相悖？如果相悖，是理论本身存在问题，还是模型的构建或数据的测量有缺陷？
- **修正或拓展理论 (Theory Refinement or Extension):** 模型结果可能揭示了现有理论的不足之处，或者发现了理论未能预料到的新现象或关系。这为修正理论的边界条件、补充新的作用机制或整合不同理论视角提供了契机。例如，一个基于大规模网络数据的研究可能发现，传统社会资本理论需要考虑线上弱连接的独特作用。
- **生成新理论或概念 (Theory Generation or Concept Development):** 对于探索性较强或基于数据驱动发现的研究，模型结果（如新发现的模式、聚类、主题）可能成为构建

新理论或提出新概念的起点 (Glaser & Strauss, 1967; Timmermans & Tavory, 2012)。例如，通过对在线社群互动数据的分析，可能识别出一种新的集体行为模式，并为其建立初步的理论解释。

- **阐明机制 (Elucidating Mechanisms)**: 如果模型（特别是因果模型或模拟模型）旨在揭示现象背后的作用机制，那么结果解释应重点阐述这些机制是如何运作的，以及模型是如何支持对这些机制的理解的 (Hedström & Ylikoski, 2010)。
- **比较不同理论的解释力 (Comparing Explanatory Power of Competing Theories)**: 如果研究涉及对同一现象的多种理论解释，模型结果可以帮助评估哪种理论提供了更充分或更简洁的解释。

3. 局限性分析 (Acknowledging Limitations): 负责任的结果解释必须坦诚地讨论研究中存在的各种局限性，这不仅体现了科学的审慎，也为未来的研究指明了方向。

- **数据局限 (Data Limitations)**: 回顾数据的来源、覆盖范围、潜在偏差（如样本代表性问题、测量误差、数字鸿沟）、缺失数据的影响等，并说明这些局限可能如何影响研究结论的可靠性和普适性 (boyd & Crawford, 2012; Lazer et al., 2014)。
- **方法局限 (Methodological Limitations)**: 讨论所选模型或分析方法的内在假设和局限性。例如，相关性不等于因果关系；特定机器学习模型的可解释性问题；模拟模型中简化假设的潜在影响。
- **模型假设的潜在影响 (Impact of Model Assumptions)**: 明确模型构建过程中所做的关键假设，并讨论如果这些假设不成立，结论可能会有何不同。
- **结论的适用范围与推广边界 (Scope and Generalizability of Conclusions)**: 基于数据和方法的局限，清晰界定研究结论适用于哪些特定的人群、情境、时间段或平台。避免对结果进行过度泛化。
- **替代性解释 (Alternative Explanations)**: 思考是否存在其他可能的理论或机制也能解释观察到的结果，并说明为什么当前研究选择的解释更具说服力，或者承认其他解释的可能性。

4. 识别非预期发现与新问题 (Identifying Unexpected Findings and New Questions): 研究过程往往充满意外。模型结果中可能会出现与预期完全不同甚至相反的发现，或者揭示出一些全新的、未被注意到的现象。对这些**意外之喜 (serendipitous findings)** 进行深入思考和解读，往往能开辟新的研究路径，产生更具原创性的贡献。同时，一项研究的结束往往是另一项研究的开始。基于当前研究的发现和局限，可以提出未来值得进一步探索的新研究问题。

迭代与优化

社会科学的研究过程并非一条笔直的单行道，而更像是一个不断循环、反馈和优化的螺旋式上升过程。迭代与优化不仅是研究生命周期中的一个特定阶段，更是一种贯穿始终的思维方式和模式。在模型的评估与解释之后，基于所获得的反馈信息，研究者常常需要返回到之前的某个或多个阶段，对研究设计、数据处理、模型选择或实现进行调整和改进，以期获得更可靠、更深刻、更有价值的研究成果。

基于评估结果的反馈循环 是迭代的核心驱动力。模型评估与验证阶段可能会揭示出各种问题，这些问题直接指示了需要进行迭代的方向：

- **模型性能不佳 (Poor Model Performance)**：如果模型的预测准确率低、拟合优度差，或者无法复现关键的经验模式，这可能表明：
 - **问题定义层面**：研究问题是否过于宽泛、模糊，或者设定的目标不切实际？是否需要重新聚焦或分解问题？
 - **数据层面**：
 - **数据质量问题**：数据中是否存在未被充分处理的噪音、错误、缺失或偏差？
 - **数据代表性或相关性不足**：当前数据是否真的包含了回答研究问题所需的关键信息？是否需要获取更多样、更大规模或不同类型的数据？
 - **特征工程不足**：原始变量是否未能有效捕捉现象的关键驱动因素？是否需要创建更有信息量的新特征？
 - **EDA 层面**：在探索性分析中是否遗漏了某些重要的变量关系、数据结构或异常模式，导致对数据的理解出现偏差？
 - **模型选择/设计层面**：
 - **模型假设不符**：所选模型的内在假设是否与数据的实际特征严重不符（如对非线性关系使用了线性模型）？
 - **模型复杂度不当**：模型是否过于简单（欠拟合）而无法捕捉数据中的复杂性，或者过于复杂（过拟合）而导致泛化能力差？
 - **尝试其他模型类型**：当前模型是否是解决该类问题的最优选择？是否应该考虑其他类型的模型或分析方法？
 - **模型实现/校准层面**：
 - **代码实现错误**：模型代码中是否存在逻辑错误或计算错误？
 - **参数设置/超参数调优不当**：模型的参数估计是否收敛？超参数是否经过了充分的优化？
 - **（对于模拟模型）校准不足**：模拟模型的参数是否未能使其行为与经验事实充分匹配？


- **模型结果难以解释或与理论冲突**：即使模型在统计性能上表现尚可，但如果其结果难以从社会科学理论的角度进行合理解释，或者与广泛接受的理论或经验发现严重冲突，这也提示需要进行迭代。这可能意味着：
 - **对模型的理解存在偏差**：是否正确理解了模型参数的含义或模型输出的逻辑？
 - **理论框架选择不当或理解不深**：当前理论是否是解释该现象的最佳视角？是否存在其他更合适的理论？
 - **操作化问题**：核心概念的操作化（从理论构念到可测量变量的转换）是否存在问题，导致模型测量的并非研究者意图研究的内容？
 - **模型可能揭示了理论的局限或需要修正之处**：有时，与理论的冲突并非模型的问题，而是理论本身需要被挑战或完善。这需要更深入的理论思辨。
- **模型稳健性不足 (Lack of Model Robustness)**：如果模型结果对数据或参数的微小变动高度敏感，那么其结论的可靠性就值得怀疑。这可能需要：
 - **改进数据预处理**以减少噪音和异常值的影响。
 - **采用更稳健的估计方法或模型类型**。
 - **更仔细地校准或设定关键参数**。

迭代优化不仅仅是对模型本身的调整，有时也可能涉及到**研究问题的重新审视和调整**。在研究过程中，随着对数据和现象的理解不断加深，研究者可能会发现最初设定的研究问题过于宏大、难以操作，或者存在更重要、更有趣的子问题值得优先探索。灵活地调整研究焦点，是成熟研究者的标志之一。

迭代过程是一个**持续学习和改进的过程**。每一次迭代，无论是成功还是失败，都能为研究者提供宝贵的经验和教训。失败的尝试有助于排除不合适的路径，而成功的改进则会增强对模型和数据的信心。这个过程可能需要研究者学习新的技术、查阅更多的文献、与同行进行深入的讨论，甚至挑战自己固有的观念。

在计算社会科学中，由于数据的复杂性、模型的多样性以及理论与经验之间关系的微妙性，迭代往往不是一次性的，而是可能需要经历**多次循环**。研究者需要在追求完美与项目时间和资源限制之间取得平衡。何时停止迭代并没有一个固定的标准，通常取决于研究者是否认为当前的模型和结果已经足够回答研究问题、具有足够的可靠性、并能做出有意义的理论或实践贡献。

有效的迭代需要良好的**项目管理和文档记录**。清晰地记录每次迭代所做的更改、更改的理由、以及更改后的评估结果，有助于避免重复错误，并能系统地追踪研究的进展。版本控制系统（如 Git）对于管理代码和分析脚本的迭代尤为重要。



本小节参考文献:

- Cohen, Jacob. 2009. *Statistical Power Analysis for the Behavioral Sciences*. New York, NY: Routledge.
- Domingos, Pedro. 2012. "A Few Useful Things to Know about Machine Learning." *Commun. ACM* 55(10): 78–87. doi:10.1145/2347736.2347755.
- Fawcett, Tom. 2006. "An Introduction to ROC Analysis." *Pattern Recognition Letters* 27(8): 861–74. doi:10.1016/j.patrec.2005.10.010.
- Gilbert, Nigel. *Simulation for the Social Scientist [Paperback] [2005] 2 Ed.* Nigel Gilbert, Klaus Troitzsch. Open University Press.
- Glaser, Barney G., and Anselm L. Strauss. 1980. *The Discovery of Grounded Theory: Strategies for Qualitative Research*. New York: Aldine Pub. Co.
- Grimm, Volker. *Individual-Based Modeling and Ecology: (Princeton Series in Theoretical and Computational Biology)* by Grimm, Volker, Railsback, Steven F. (2005) Paperback. Princeton University Press.
- Hastie, Trevor, Robert Tibshirani, and Jerome Friedman. 2009. "Basis Expansions and Regularization." In *The Elements of Statistical Learning: Data Mining, Inference, and Prediction*, eds. Trevor Hastie, Robert Tibshirani, and Jerome Friedman. New York, NY: Springer, 139–89. doi:10.1007/978-0-387-84858-7_5.
- Healy, Kieran. 2019. *Data Visualization: A Practical Introduction*. Princeton NJ Oxford: Princeton University Press.
- Hedström, Peter, and Petri Ylikoski. 2010. "Causal Mechanisms in the Social Sciences." *Annual Review of Sociology* 36(Volume 36, 2010): 49–67. doi:10.1146/annurev.soc.012809.102632.
- Hubert, Lawrence, and Phipps Arabie. 1985. "Comparing Partitions." *Journal of Classification* 2(1): 193–218. doi:10.1007/BF01908075.
- Hunter, David R., Steven M. Goodreau, and Mark S. Handcock. 2008. "Goodness of Fit of Social Network Model." *Journal of the American Statistical Association* 103(481): 248–58.
- "Introduction to Sensitivity Analysis." 2007. In *Global Sensitivity Analysis. The Primer*, John Wiley & Sons, Ltd, 1–51. doi:10.1002/9780470725184.ch1.
- James, Gareth, Daniela Witten, Trevor Hastie, and Robert Tibshirani. 2013. *An Introduction to Statistical Learning: With Applications in R*. 1st ed. 2013, Corr. 7th printing 2017 edition. New York: Springer.
- Newman, David, Jey Han Lau, Karl Grieser, and Timothy Baldwin. 2010. "Automatic Evaluation of Topic Coherence." In *Human Language Technologies: The 2010 Annual Conference of the North American Chapter of the Association for Computational Linguistics*, eds. Ron Kaplan, Jill Burstein, Mary Harper, and Gerald Penn. Los Angeles, California: Association for Computational Linguistics, 100–108. <https://aclanthology.org/N10-1012/> (May 14, 2025).
- Pearl, Judea. 2009. *Causality: Models, Reasoning and Inference*. 2nd edition. Cambridge, U.K. ; New York: Cambridge University Press.
- Röder, Michael, Andreas Both, and Alexander Hinneburg. 2015. "Exploring the Space of Topic Coherence Measures." In *Proceedings of the Eighth*

ACM International Conference on Web Search and Data Mining, WSDM '15, New York, NY, USA: Association for Computing Machinery, 399–408.

doi:10.1145/2684822.2685324

Rousseeuw, Peter J. 1987. "Silhouettes: A Graphical Aid to the Interpretation and Validation of Cluster Analysis." *Journal of Computational and Applied Mathematics* 20: 53–65. doi:10.1016/0377-0427(87)90125-7

S. Cook, R. Dennis;Weisberg. 1995. *Residuals and Influence in Regression*. New York: Chapman & Hall.

Sargent, Thomas J. 2013. *Rational Expectations and Inflation* (Third Edition). Princeton University Press.

<https://www.jstor.org/stable/j.ctt2jc97n> (May 12, 2025).

Wasserstein, Ronald L., and Nicole A. and Lazar. 2016. "The ASA Statement on P-Values: Context, Process, and Purpose." *The American Statistician* 70(2): 129–33. doi:10.1080/00031305.2016.1154108

阶段五：沟通、影响与知识贡献

当研究经过了反复的迭代与优化，模型和结果达到了研究者认为满意和可靠的程度后，便进入了研究生命周期的最后一个核心阶段：沟通、影响与知识贡献。这一阶段的目标是将研究过程和成果有效地传递给学术共同体乃至更广泛的社会，确保研究的可重复性和透明度，反思研究的伦理意涵和社会影响，并将所获得的知识妥善存档，为未来的科学探索奠定基础。这是将个体研究融入人类知识宝库，并使其产生实际价值的关键环节。

知识封装与成果沟通

研究的价值最终体现在其能否被他人理解、接受和使用。因此，将复杂的研究过程和发现有效地封装并清晰地沟通出去，是研究者的核心责任之一。

- **撰写研究报告/学术论文**：这是学术成果沟通最主要的形式。一篇高质量的研究论文需要系统地呈现研究的各个方面，通常包括：
 - **引言 (Introduction)**：阐述研究背景、研究问题的重要性、理论框架、研究目标和主要贡献。
 - **文献综述 (Literature Review)**：回顾相关领域的核心理论和已有研究，明确本研究的定位和创新点。
 - **方法 (Methodology)**：详细描述数据来源、数据收集过程、预处理步骤、所选模型或分析方法的原理、实现细节、参数设定以及评估标准。这部分需要达到足够的透

明度，以便他人理解和评判研究的严谨性。

- **结果 (Results)**: 客观、准确地呈现模型的主要发现，通常结合图表和统计数据。避免在结果部分进行过多的解释或推断。
 - **讨论 (Discussion)**: 深入解读结果的社会科学含义，将其与理论进行对话（支持、修正或挑战），分析研究的优势与局限，并指出未来研究方向。
 - **结论 (Conclusion)**: 简要总结研究的核心发现及其意义。
 - **参考文献 (References) 和 附录 (Appendices)**（可能包含更详细的技术细节、补充图表等）。撰写过程需要遵循学术规范，语言力求精确、客观、逻辑清晰 (Booth, Colomb, & Williams, 2008)。
- **数据可视化叙事**: 除了在论文中嵌入图表，研究者还可以利用更具动态性和交互性的可视化工具（如制作在线交互图表、数据故事板、短视频等）来向不同受众生动地展示研究发现，增强沟通效果 (Knafllic, 2015)。
 - **面向不同受众的沟通策略**: 学术论文主要面向同行专家。但计算社会科学的许多研究成果也可能对政策制定者、行业从业者、媒体记者或社会公众具有重要价值。针对不同受众，需要采用不同的沟通方式和语言风格。例如，为政策制定者撰写简洁明了的政策简报，为公众撰写科普文章或参与公开演讲，为行业提供可操作的洞察报告。
 - **学术发表与会议交流**: 将研究成果提交给同行评议的学术期刊或会议，是获得学术认可、接受同行检验、并促进学术交流的重要途径。选择合适的发表平台，认真对待审稿人的意见，是提升研究质量和影响力的关键。在学术会议上口头报告或海报展示研究成果，也是与同行进行实时互动和思想碰撞的宝贵机会。

有效的知识封装与沟通，不仅能提升研究本身的可见度和影响力，也有助于推动学科的发展和知识的传播。

可重复性、可复制性与开放科学

在计算社会科学这一高度依赖数据和计算方法的领域，确保研究的透明度和可靠性至关重要。可重复性、可复制性和开放科学的理念与实践，正日益成为衡量研究质量和科研诚信的核心标准。

- **确保研究的可重复性 (Reproducibility)**: 可重复性是指其他研究者使用作者提供的原始数据、计算代码和分析步骤，能够独立地重现出与原研究报告中相同的结果。这是检验研究结果是否源于真实的分析而非偶然错误或特定操作的基础。为了实现可重复性，研究者需要：
 - **详细记录和报告方法**: 清晰、完整地描述所有数据处理、模型构建和分析步骤。

- **共享数据**：在符合伦理规范和数据隐私保护的前提下（例如，对数据进行充分匿名化处理，或提供模拟数据生成脚本），将用于分析的原始数据或经过处理的分析数据集公开共享（如通过 Figshare, Zenodo, Dataverse 等数据存储库）。
- **共享代码**：公开用于数据处理、模型实现、分析和可视化的完整计算机代码。代码应包含清晰的注释，并指明所用的软件版本和依赖库。
- **使用版本控制系统**：如 Git 和 GitHub/GitLab 等平台，用于追踪代码和分析脚本的修改历史，方便他人获取特定版本的代码，并促进协作。
- **采用文字化编程工具**：如 Jupyter Notebook, R Markdown，它们允许将代码、数据、文本解释和可视化结果整合在一个动态文档中，极大地增强了研究过程的透明度和可重复性 (Knuth, 1984)。
- **促进研究的可复制性 (Replicability)**：可复制性是指其他研究者使用新的数据（可能来自不同样本、不同时间或不同情境）和相似的方法，能够得到与原研究核心结论相一致的结果 (Goodman, Fanelli, & Ioannidis, 2016)。可复制性是衡量研究发现稳健性和普适性的更高标准。虽然一项研究本身无法完全保证其可复制性（因为这依赖于其他独立研究的验证），但通过清晰的方法报告、稳健的分析设计（如进行敏感性分析、考虑异质性）以及对结论适用范围的审慎界定，可以为后续的复制研究提供便利。
- **拥抱开放科学实践**：开放科学是一场旨在使科学研究过程和成果更加透明、可及和协作的运动 (Nosek et al., 2015; Munafo et al., 2017)。除了共享数据和代码，开放科学还倡导：
 - **预注册研究方案 (Preregistration of Research Plans)**：在数据收集或分析开始之前，将研究问题、假设、方法和分析计划在一个公开平台（如 Open Science Framework, AsPredicted.org）进行注册。这有助于区分探索性发现与验证性结论，减少发表偏倚 (publication bias) 和“假设在结果已知后提出”(HARKing) 的问题 (Chambers, 2013)。
 - **开放获取发表 (Open Access Publishing)**：将研究论文发表在开放获取期刊或通过预印本服务器（如 arXiv, SocArXiv, PsyArXiv）共享，使研究成果能够被更广泛的读者免费获取。
 - **开放同行评议 (Open Peer Review)**：使同行评议过程更加透明，例如公开审稿人身份和审稿意见。
 - **开放教育资源 (Open Educational Resources)**：共享教学材料、课程等。

伦理反思与社会影响评估

在研究项目完成、成果即将发布之际，对整个研究过程中的伦理实践进行一次全面的回顾与反思，并审慎评估研究发现可能带来的社会影响，是负责任的计算社会科学研究不可或

缺的一环。这并非对初始伦理规划的简单重复，而是基于完整的实践经验和研究结果进行的更深层次考量。

- **回顾伦理合规性与实践：**重新审视在数据收集、处理、分析和存储过程中，是否始终遵守了伦理原则（如尊重自主、行善、不伤害、公正）和相关法规（如数据隐私保护条例）？知情同意的获取是否充分？数据匿名化和安全措施是否有效？在研究过程中是否出现了未曾预料到的伦理困境，以及是如何应对的？
- **评估研究发现的潜在社会影响：**
 - **正面影响：**研究成果是否可能为理解重要社会问题提供新视角？是否能为政策制定提供有益参考？是否能促进社会福祉或公平正义？
 - **负面影响/误用风险：**研究结果是否可能被误解、滥用或用于不良目的？例如，关于人群行为预测的模型是否可能被用于不当监控或歧视？揭示的社会脆弱性是否可能被利用？
 - **对不同社群的公平性：**研究的受益者和潜在受损者分别是谁？研究结果是否可能不成比例地影响特定弱势群体？模型中是否存在未被充分解决的偏见问题？
- **研究者对研究过程和结果的社会责任：**作为知识的生产者，研究者对自己的研究成果可能产生的社会后果负有何种责任？如何积极地促进成果的良性应用，并努力减缓其潜在的负面影响？这可能包括主动与政策制定者、公众沟通，参与伦理规范的讨论等。
- **透明化局限与不确定性：**在向社会发布研究成果时，清晰地阐明研究的局限性、结论的不确定性以及潜在的偏见来源，是防止误用和过度解读的重要伦理责任。

知识存档与未来研究展望

一项研究的完成并非知识探索的终点，而是更广阔学术图景中的一个节点。妥善保存研究成果，并为未来的研究提供启示，是确保知识积累和科学进步连续性的重要环节。

- **系统性存档研究资料：**将研究过程中产生的所有重要资料，包括最终版本的分析数据集（在符合伦理和隐私的前提下）、完整的分析代码、模型参数、详细的方法文档、研究报告、以及相关的元数据等，进行系统性的、有组织的存档。理想情况下，这些资料应存储在稳定、可长期访问的公共或机构存储库中，并附有清晰的说明，以便其他研究者（或未来的自己）能够理解和使用。
- **将研究成果融入更广泛的知识体系：**思考本研究的发现如何与学科内外的相关知识进行连接和整合。它是否验证、补充或挑战了现有理论？它是否能为其他领域的研究提供借鉴或启发？

- **提出未来值得进一步探索的研究方向：**基于当前研究的局限性（如未解决的问题、未能充分探讨的方面）、非预期发现或研究过程中涌现的新问题，明确提出未来值得进一步深入研究的具体方向和潜在议题。这不仅为其他研究者提供了思路，也可能为自己后续的研究奠定基础。
- **考虑研究成果的教育和培训价值：**研究过程和成果是否可以作为案例，用于培养新的计算社会科学研究者？相关的代码、数据和方法论思考是否可以转化为教学材料？

结语：研究的迭代循环与研究者的成长

计算社会科学的研究生命周期远非一个简单的线性流程，而是一个以问题为导向、以数据为基础、以模型为工具、以理论为指引，充满动态反馈和持续优化的**迭代循环 (iterative loop)**。从最初的研究启动与规划，到数据获取与准备，再到探索分析与模型构建，直至最终的评估解释与成果沟通，每一个阶段都可能因为后续的发现或挑战而需要被重新审视和调整。这种螺旋式上升的探究过程，正是科学发现的常态。


在这个复杂的生命周期中，对研究者而言，至关重要的是在每一个环节都保持**批判性思维 (critical thinking)** 和**方法论自觉 (methodological self-awareness)**。这意味着要不断反思研究问题的重要性、数据的质量与局限、模型的假设与适用性、结果解释的合理性以及研究的伦理意涵。同时，也需要拥抱不确定性，勇于尝试新的方法，从失败中学习，并根据实际情况灵活调整研究策略。


计算社会科学的研究过程，不仅是生产新知识的过程，更是研究者自身技能、认知能力和伦理素养不断提升的过程。通过亲身经历这个完整的迭代生命周期，研究者能够逐步培养出在理论、数据、方法和现实问题之间进行有效穿梭和创造性联结的能力。这不仅要求掌握具体的技术操作，更要求具备一种整体性的、系统性的研究视野和深刻的认识论反思。唯有如此，我们才能真正驾驭计算社会科学的强大潜力，为理解和改善我们日益复杂的世界贡献有意义的洞见。

本小节参考文献:

Booth, Wayne C., Gregory G. Colomb, and Joseph M. Williams. 2008. *The Craft of Research*, Third Edition. Third edition. Chicago: University of Chicago Press.


Chambers, Deborah. 2013. "Introduction." In *Social Media and Personal Relationships: Online Intimacies and Networked Friendship*, ed. Deborah Chambers. London: Palgrave Macmillan UK, 1-20.


doi:10.1057/9781137314444_1 .

Goodman, Steven N., Daniele Fanelli, and John P. A. Ioannidis. 2016. "What Does Research Reproducibility Mean?" *Science Translational Medicine* 8(341): 341ps12-341ps12. doi:10.1126/scitranslmed.aaf5027 .


Knaflic, Cole Nussbaumer. 2015. *Storytelling with Data: A Data Visualization Guide for Business Professionals*. Hoboken, New Jersey: Wiley.

Knuth, D. E. "Literate Programming."

<https://dx.doi.org/10.1093/comjnl/27.2.97>  (March 14, 2025).

Munafò, Marcus R., Brian A. Nosek, Dorothy V. M. Bishop, Katherine S. Button, Christopher D. Chambers, Nathalie Percie du Sert, Uri Simonsohn, et al. 2017. "A Manifesto for Reproducible Science." *Nature Human Behaviour* 1(1): 1-9. doi:10.1038/s41562-016-0021 .

Open Science Collaboration. 2015. "Estimating the Reproducibility of Psychological Science." *Science* 349(6251): aac4716.

doi:10.1126/science.aac4716 .